

**TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
TRƯỜNG CÔNG NGHỆ SỐ VÀ TRÍ TUỆ NHÂN TẠO**



NAM CAN THO UNIVERSITY

VÕ THỊ MỸ DUYÊN

**XÂY DỰNG MÔ HÌNH AI HỖ TRỢ CHẨN ĐOÁN VÀ
GIẢI THÍCH BỆNH PHỔI TỪ ẢNH X-QUANG**

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Kỹ thuật phần mềm

Mã số ngành: 7480103

Tháng 7 năm 2026

TRƯỜNG ĐẠI HỌC NAM CẦN THƠ
TRƯỜNG CÔNG NGHỆ SỐ VÀ TRÍ TUỆ
NHÂN TẠO



VÕ THỊ MỸ DUYÊN

MSSV: 224719

XÂY DỰNG MÔ HÌNH AI HỖ TRỢ CHẨN ĐOÁN VÀ
GIẢI THÍCH BỆNH PHỔI TỪ ẢNH X-QUANG

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC

Ngành: Kỹ thuật phần mềm

Mã số ngành: 7480103

GIẢNG VIÊN HƯỚNG DẪN

TRẦN VĂN THIỆN

CHẤP THUẬN HỘI ĐỒNG

Khóa luận “Xây dựng mô hình AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang”, do sinh viên Võ Thị Mỹ Duyên thực hiện dưới sự hướng dẫn của Giảng viên Trần Văn Thiện. Khóa luận tốt nghiệp đã báo cáo và được Hội đồng chấm Khóa luận thông qua ngày ... tháng ... năm 2026.

Ủy viên
(Ký tên)

Thư ký
(Ký tên)

.....

.....

Phản biện 1
(Ký tên)

Phản biện 2
(Ký tên)

.....

.....

Cán bộ hướng dẫn
(Ký tên)

Chủ tịch Hội đồng
(Ký tên)

.....

.....

LỜI CẢM TẠ

Trước hết, em xin bày tỏ lòng biết ơn chân thành và sâu sắc đến trường Đại học Nam Cần Thơ – ngôi trường đã tạo điều kiện học tập, rèn luyện và cung cấp nền tảng kiến thức vững chắc để em hoàn thành chương trình học cũng như thực hiện luận văn tốt nghiệp này.

Em xin gửi lời cảm ơn trân trọng đến Quý thầy cô Trường Công nghệ số và trí tuệ nhân tạo, những người đã tận tình giảng dạy, truyền đạt kiến thức và kinh nghiệm quý báu trong suốt thời gian em theo học tại trường. Những bài học và sự hướng dẫn tận tâm của quý thầy cô chính là hành trang quý giá giúp em có được kết quả như ngày hôm nay.

Đặc biệt, em xin bày tỏ lòng biết ơn sâu sắc đến thầy Trần Văn Thiện, người đã trực tiếp hướng dẫn, đồng hành cùng em trong suốt quá trình thực hiện luận văn. Thầy không chỉ tận tình định hướng, góp ý chuyên môn mà còn luôn động viên, khích lệ em vượt qua những khó khăn trong quá trình nghiên cứu. Sự tận tâm và nhiệt huyết của thầy là nguồn động lực to lớn giúp em hoàn thành tốt luận văn này.

Dù luận văn vẫn còn những hạn chế nhất định, nhưng em đã cố gắng thực hiện với tinh thần nghiêm túc và nỗ lực cao nhất. Em kính mong nhận được sự góp ý của quý thầy cô để có thể hoàn thiện hơn về kiến thức và kỹ năng trong tương lai.

Em xin chân thành cảm ơn!

Cần Thơ, ngày 3 tháng 7 năm 2026

Người thực hiện

Võ Thị Mỹ Duyên

LỜI CAM ĐOAN

Em xin cam kết Khóa luận này được hoàn thành dựa trên kết quả nghiên cứu của em và các kết quả này chưa được dùng cho bất cứ khóa luận cùng cấp nào khác.

Cần Thơ, ngày 3 tháng 7 năm 2026

Người thực hiện

Võ Thị Mỹ Duyên

TÓM TẮT

Trong bối cảnh trí tuệ nhân tạo ngày càng được ứng dụng rộng rãi trong lĩnh vực y tế, việc hỗ trợ phân tích ảnh chẩn đoán đóng vai trò quan trọng, đặc biệt đối với ảnh X-quang ngực. Ảnh X-quang là phương pháp chẩn đoán hình ảnh phổ biến, có chi phí thấp và thường được sử dụng trong phát hiện các bệnh lý liên quan đến phổi. Tuy nhiên, quá trình đọc ảnh phụ thuộc nhiều vào kinh nghiệm chuyên môn của bác sĩ và có thể gặp khó khăn trong các trường hợp tổn thương nhỏ, dấu hiệu bệnh không rõ ràng hoặc số lượng ảnh cần xử lý lớn. Vì vậy, đề tài tập trung xây dựng hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực.

Đề tài sử dụng bộ dữ liệu ảnh X-quang ngực gồm bốn lớp: COVID-19, Normal, Pneumonia và Tuberculosis. Trước khi đưa vào mô hình, ảnh được tiền xử lý thông qua các bước thay đổi kích thước, chuẩn hóa dữ liệu và tăng cường dữ liệu nhằm cải thiện khả năng học của mô hình. Mô hình chính được sử dụng là ResNet101 pretrained trên ImageNet, tận dụng học chuyển giao để trích xuất đặc trưng hình ảnh và phân loại ảnh X-quang vào một trong bốn lớp bệnh đã xác định.

Bên cạnh khả năng dự đoán, đề tài tích hợp các kỹ thuật Explainable AI nhằm tăng tính minh bạch cho mô hình học sâu. Bốn kỹ thuật được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Các kỹ thuật này giúp trực quan hóa hoặc phân tích những vùng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình. Nhờ đó, hệ thống không chỉ đưa ra nhãn bệnh và xác suất phân loại mà còn hỗ trợ người dùng quan sát vùng ảnh mà mô hình tập trung khi đưa ra kết quả.

Kết quả thực nghiệm cho thấy mô hình ResNet101 đạt hiệu quả tốt trong bài toán phân loại ảnh X-quang phổi bốn lớp. Trên tập kiểm thử, mô hình đạt Accuracy là 0.948119, Precision là 0.963359, Recall là 0.956805 và F1-score là 0.959712. Các chỉ số này cho thấy mô hình có khả năng phân loại tương đối tốt giữa các nhóm COVID-19, Normal, Pneumonia và Tuberculosis.

Ngoài mô hình AI, đề tài còn xây dựng giao diện demo dạng web nhằm mô phỏng quy trình sử dụng hệ thống. Giao diện cho phép người dùng tải ảnh X-quang, xem kết quả dự đoán bệnh, quan sát xác suất của từng lớp, theo dõi các hình ảnh giải thích mô hình và xem lại lịch sử chẩn đoán. Hệ thống được định hướng như một công cụ hỗ trợ tham khảo trong quá trình phân tích ảnh X-quang, không thay thế vai trò chẩn đoán của bác sĩ. Đề tài góp phần minh họa tiềm năng ứng dụng của học sâu và trí tuệ nhân tạo có khả năng giải thích trong lĩnh vực hỗ trợ phân tích ảnh y tế.

MỤC LỤC

DANH SÁCH BẢNG	i
DANH SÁCH HÌNH	ii
DANH MỤC TỪ VIẾT TẮT.....	iii
CHƯƠNG 1 GIỚI THIỆU	1
1.1 ĐẶT VẤN ĐỀ NGHIÊN CỨU	1
1.2 LÝ DO CHỌN ĐỀ TÀI.....	2
1.3 MỤC TIÊU NGHIÊN CỨU	3
1.3.1 Mục tiêu chung.....	3
1.3.2 Mục tiêu cụ thể	3
1.4 PHẠM VI NGHIÊN CỨU	4
1.4.1 Không gian	4
1.4.2 Thời gian	4
1.4.3 Đối tượng nghiên cứu.....	5
1.5 BỐ CỤC CỦA LUẬN VĂN	5
1.6 Ý NGHĨA KHOA HỌC VÀ THỰC TIỄN CỦA ĐỀ TÀI	6
1.7 PHƯƠNG PHÁP NGHIÊN CỨU	7
1.8 TỔNG KẾT CHƯƠNG	8
CHƯƠNG 2 CƠ SỞ LÝ LUẬN VÀ CÁC NGHIÊN CỨU LIÊN QUAN.....	10
2.1 CƠ SỞ LÝ LUẬN.....	10
2.1.1 Tổng quan về hệ thống	10
2.1.2 Lịch sử hình thành và phát triển của hệ thống	11
2.1.3 Môi trường phát triển – Kaggle & Visual Studio Code	12
2.1.4 Dataset.....	13
2.1.5 Mô hình ResNet101	15
2.1.6 Các kỹ thuật giải thích mô hình	16
2.2 CÁC BÀI BÁO LIÊN QUAN	18
2.3 TỔNG KẾT CHƯƠNG	21
CHƯƠNG 3 PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG	22
3.1 PHÂN TÍCH YÊU CẦU.....	22
3.1.1 Yêu cầu chức năng	22
3.1.2 Yêu cầu phi chức năng.....	23
3.2 KIẾN TRÚC TỔNG THỂ HỆ THỐNG	24

3.3	PHÂN TÍCH DỮ LIỆU VÀ QUY TRÌNH XỬ LÝ	27
3.3.1	Bộ dữ liệu sử dụng	27
3.3.2	Quy trình tiền xử lý dữ liệu	29
3.4	THIẾT KẾ MÔ HÌNH RESNET101	31
3.4.1	Kiến trúc mô hình ResNet101	31
3.4.2	Đầu vào và đầu ra của mô hình	33
3.4.3	Quy trình huấn luyện mô hình	34
3.5	THIẾT KẾ CÁC KỸ THUẬT GIẢI THÍCH	36
3.5.1	Quy trình chung khi áp dụng kỹ thuật giải thích	36
3.5.2	Kỹ thuật Grad-CAM	37
3.5.3	Kỹ thuật Grad-CAM++	38
3.5.4	Kỹ thuật Integrated Gradients	38
3.5.5	Kỹ thuật Occlusion	39
3.5.6	Thiết kế đầu ra của các kỹ thuật giải thích	39
3.5.7	Ý nghĩa của việc tích hợp Explainable AI	40
3.6	THIẾT KẾ HỆ THỐNG WEB	40
3.6.1	Thiết kế Backend	40
3.6.2	Thiết kế Frontend	41
3.6.3	Quy trình tương tác giữa người dùng và hệ thống	42
3.7	TỔNG KẾT CHƯƠNG	43
CHƯƠNG 4	TRIỂN KHAI VÀ KẾT QUẢ THỰC NGHIỆM	42
4.1	GIỚI THIỆU CHƯƠNG	42
4.2	KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH RESNET101	42
4.2.1	Các chỉ số đánh giá mô hình	42
4.2.2	Kết quả đánh giá trên tập kiểm thử	44
4.2.3	Ma trận nhầm lẫn	45
4.2.4	Nhận xét kết quả phân loại	47
4.3	KẾT QUẢ GIẢI THÍCH MÔ HÌNH BẰNG XAI	48
4.3.1	Kết quả giải thích bằng Grad-CAM	49
4.3.2	Kết quả giải thích bằng Grad-CAM++	50
4.3.3	Kết quả giải thích bằng Integrated Gradients	51
4.3.4	Kết quả giải thích bằng Occlusion	52
4.3.5	Kết quả giải thích bằng Grad-CAM	53
4.4	KẾT QUẢ TRIỂN KHAI HỆ THỐNG PHẦN MỀM	54
4.4.1	Tổng quan hệ thống web	54

4.4.2	Giao diện tải ảnh X-quang	55
4.4.3	Giao diện hiển thị kết quả dự đoán	56
4.4.4	Giao diện hiển thị xác suất phân loại	57
4.4.5	Giao diện hiển thị kết quả giải thích mô hình	58
4.4.6	Giao diện lịch sử chẩn đoán	59
4.4.7	Quy trình xử lý thực tế trên hệ thống web	60
4.5	THẢO LUẬN VÀ PHÂN TÍCH TỔNG HỢP	61
4.5.1	Hiệu quả của mô hình ResNet101 trong bài toán phân loại bệnh phổi.....	61
4.5.2	Vai trò của các kỹ thuật Explainable AI trong hệ thống.....	62
4.5.3	Đóng góp của hệ thống web trong quá trình triển khai.....	63
4.5.4	Phân tích kết quả dự đoán và xác suất phân loại.....	64
4.5.5	Phân tích kết quả giải thích mô hình bằng XAI.....	65
4.5.6	Ý nghĩa thực tiễn của hệ thống	66
4.6	TỔNG KẾT CHƯƠNG	67
	CHƯƠNG 5 KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	70
5.1	GIỚI THIỆU CHƯƠNG.....	70
5.2	TỔNG KẾT KẾT QUẢ NGHIÊN CỨU	70
5.2.1	Đối chiếu mục tiêu và kết quả đạt được.....	70
5.2.2	Tổng kết kết quả thực nghiệm cốt lõi.....	71
5.2.3	Mức độ hoàn thành các chức năng của hệ thống	71
5.3	CÁC ĐÓNG GÓP CỦA ĐỀ TÀI	72
5.3.1	Đóng góp về mặt học thuật	72
5.3.2	Đóng góp về mặt thực tiễn	73
5.4	HẠN CHẾ CỦA NGHIÊN CỨU	73
5.4.1	Hạn chế về dữ liệu.....	73
5.4.2	Hạn chế về mô hình.....	74
5.4.3	Hạn chế về kỹ thuật giải thích mô hình	74
5.4.4	Hạn chế về hệ thống triển khai.....	74
5.5	HƯỚNG PHÁT TRIỂN.....	75
5.5.1	Mở rộng bộ dữ liệu và số lớp bệnh	75
5.5.2	Cải thiện chất lượng tiền xử lý và kiểm tra ảnh đầu vào	75
5.5.3	Tối ưu mô hình và nâng cao hiệu quả phân loại	75
5.5.4	Nâng cấp các kỹ thuật giải thích mô hình	76
5.5.5	Hoàn thiện hệ thống web và lịch sử chẩn đoán.....	76
5.5.6	Định hướng ứng dụng trong môi trường thực tế	77

5.6 KẾT LUẬN CHUNG	77
TÀI LIỆU THAM KHẢO	79

DANH SÁCH BẢNG

Bảng 2.1 Các công trình nghiên cứu liên quan	20
Bảng 3.1 Thống kê số lượng ảnh trong bộ dữ liệu	29
Bảng 3.2. Tham số huấn luyện mô hình.....	35
Bảng 4.1. Ý nghĩa các chỉ số đánh giá mô hình	44
Bảng 4.2. Kết quả đánh giá mô hình ResNet101 trên tập kiểm thử	44
Bảng 4.3. Diễn giải kết quả đánh giá mô hình	45

DANH SÁCH HÌNH

Hình 2.1. Các lớp dữ liệu trong bộ ảnh X-quang phổi	14
Hình 2.2. Các kỹ thuật giải thích	18
Hình 3.1. Mô hình tổng quan của hệ thống	25
Hình 3.2. Quy trình tiền xử lý dữ liệu	31
Hình 3.3. Kiến trúc mô hình ResNet101	33
Hình 3.4. Đầu ra và đầu vào của mô hình	34
Hình 3.5. Quy trình huấn luyện mô hình.....	36
Hình 3.6. Thiết kế các kỹ thuật giải thích.....	37
Hình 4.1: Ma trận nhầm lẫn của mô hình ResNet101	46
Hình 4.2: Kết quả giải thích mô hình bằng các kỹ thuật XAI.....	48
Hình 4.3: Kết quả giải thích bằng Grad-CAM	50
Hình 4.4: Kết quả giải thích bằng Grad-CAM++.....	51
Hình 4.5: Kết quả giải thích bằng Integrated Gradients.....	52
Hình 4.6: Kết quả giải thích bằng Occlusion	53
Hình 4.7: Giao diện tổng quan của hệ thống web	55
Hình 4.8: Giao diện tải ảnh X-quang ngực lên hệ thống.....	56
Hình 4.9: Giao diện hiển thị kết quả dự đoán bệnh phổi.....	57
Hình 4.10. Giao diện hiển thị xác suất phân loại của bốn lớp bệnh.....	58
Hình 4.11. Giao diện hiển thị kết quả giải thích mô hình bằng Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion.....	59
Hình 4.12. Giao diện lịch sử chẩn đoán	60
Hình 4.13. Quy trình xử lý thực tế trên hệ thống web.....	61

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Cụm từ đầy đủ	Ý nghĩa
AI	Artificial Intelligence	Trí tuệ nhân tạo
ML	Machine Learning	Học máy
DL	Deep Learning	Học sâu
CNN	Convolutional Neural Network	Mạng nơ-ron tích chập
ResNet	Residual Network	Mạng nơ-ron dư
ResNet101	Residual Network 101 layers	Mạng ResNet gồm 101 lớp
XAI	Explainable Artificial Intelligence	
CXR	Chest X-ray	Ảnh X-quang ngực
X-Ray	X-radiation	Ảnh X-quang
COVID-19	Coronavirus Disease 2019	Bệnh viêm đường hô hấp do vi-rút SARS-CoV-2 gây ra
TB	Tuberculosis	Bệnh lao
Grad-CAM	Gradient-weighted Class Activation Mapping	Bản đồ kích hoạt lớp có trọng số gradient
Grad-CAM++	Improved Gradient-weighted Class Activation Mapping	Phiên bản cải tiến của Grad-CAM
IG	Integrated Gradients	Tích hợp gradient
FC	Fully Connected	Lớp kết nối đầy đủ
RGB	Red, Green, Blue	Hệ màu gồm ba kênh đỏ, xanh lá và xanh dương
API	Application Programming Interface	Giao diện lập trình ứng dụng
UI	User Interface	Giao diện người dùng
HTML	HyperText Markup Language	Ngôn ngữ đánh dấu siêu văn bản
CSS	Cascading Style Sheets	Ngôn ngữ định dạng giao diện web
JS	JavaScript	Ngôn ngữ lập trình dùng cho giao diện web
JSON	JavaScript Object Notation	Định dạng trao đổi dữ liệu
Flask	Flask Web Framework	Framework web viết bằng Python
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
CPU	Central Processing Unit	Bộ xử lý trung tâm
JPG/JPEG	Joint Photographic Experts Group	Định dạng ảnh nén
PNG	Portable Network Graphics	Định dạng ảnh không mất dữ liệu
TP	True Positive	Số mẫu dương tính được dự đoán đúng

FN	False Negative	Số mẫu âm tính bị dự đoán sai thành dương tính
TN	True Negative	Số mẫu dương tính bị dự đoán sai thành âm tính
FP	False Positive	Số mẫu âm tính được dự đoán đúng

CHƯƠNG 1

GIỚI THIỆU

1.1 ĐẶT VẤN ĐỀ NGHIÊN CỨU

Trong những năm gần đây, trí tuệ nhân tạo đã và đang được ứng dụng mạnh mẽ trong nhiều lĩnh vực của đời sống, đặc biệt là lĩnh vực y tế. Trong đó, chẩn đoán hình ảnh là một trong những hướng ứng dụng nổi bật nhờ khả năng xử lý, phân tích và nhận dạng đặc trưng hình ảnh của các mô hình học sâu. Ảnh X-quang ngực là một kỹ thuật chẩn đoán hình ảnh phổ biến, có chi phí thấp, thời gian thực hiện nhanh và được sử dụng rộng rãi trong quá trình phát hiện các bệnh lý liên quan đến phổi.

Tuy nhiên, việc đọc và phân tích ảnh X-quang ngực vẫn phụ thuộc nhiều vào kinh nghiệm chuyên môn của bác sĩ. Trong thực tế, một số tổn thương trên ảnh có thể có kích thước nhỏ, biểu hiện mờ hoặc xuất hiện ở những vị trí khó quan sát. Điều này có thể gây khó khăn trong quá trình nhận diện và đánh giá tình trạng bệnh. Bên cạnh đó, tại các cơ sở y tế có số lượng bệnh nhân lớn, khối lượng ảnh cần xử lý nhiều cũng tạo áp lực cho đội ngũ bác sĩ chẩn đoán hình ảnh. Vì vậy, việc nghiên cứu các hệ thống hỗ trợ phân tích ảnh X-quang bằng trí tuệ nhân tạo là hướng tiếp cận có ý nghĩa thực tiễn.

Các mô hình học sâu, đặc biệt là mạng nơ-ron tích chập, đã chứng minh được hiệu quả trong nhiều bài toán phân loại và nhận dạng hình ảnh y tế. Đối với ảnh X-quang phổi, các mô hình như CNN, ResNet, DenseNet và EfficientNet thường được sử dụng để phân loại các bệnh lý liên quan đến phổi. Trong quá trình nghiên cứu, đề tài lựa chọn ResNet101 làm mô hình chính để xây dựng hệ thống phân loại ảnh X-quang ngực. ResNet101 là một kiến trúc mạng học sâu có khả năng học các đặc trưng phức tạp của ảnh thông qua cơ chế kết nối tắt, giúp cải thiện quá trình huấn luyện mô hình sâu và hạn chế tình trạng suy giảm hiệu quả khi số lớp tăng lên.

Mặc dù các mô hình học sâu có thể đạt kết quả tốt trong phân loại hình ảnh, một hạn chế lớn của chúng là tính “hộp đen”. Mô hình có thể đưa ra kết quả dự đoán nhưng người dùng khó biết được mô hình dựa vào vùng ảnh nào để đưa ra quyết định. Trong lĩnh vực y tế, vấn đề này đặc biệt quan trọng vì kết quả dự đoán không chỉ cần có độ chính xác mà còn cần có khả năng giải thích để hỗ trợ kiểm tra và tham khảo.

Xuất phát từ vấn đề trên, đề tài “Tìm hiểu và xây dựng mô hình AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang” được thực hiện nhằm xây dựng một hệ thống hỗ trợ phân loại ảnh X-quang phổi bằng mô hình ResNet101, đồng thời tích hợp các kỹ thuật Explainable AI gồm Grad-CAM, Grad-CAM++, LIME và SHAP. Các kỹ thuật này giúp trực quan hóa hoặc phân tích những vùng ảnh có ảnh hưởng đến quyết định của mô hình, từ đó hỗ trợ người dùng hiểu rõ hơn về kết quả dự đoán.

Đề tài không hướng đến việc thay thế vai trò của bác sĩ trong chẩn đoán y khoa, mà tập trung xây dựng một công cụ hỗ trợ tham khảo. Hệ thống có thể giúp minh họa quy trình ứng dụng học sâu và trí tuệ nhân tạo có khả năng giải thích trong phân tích ảnh X-quang ngực, góp phần nâng cao tính trực quan và minh bạch trong quá trình sử dụng mô hình AI.

1.2 LÝ DO CHỌN ĐỀ TÀI

Việc lựa chọn đề tài xuất phát từ nhu cầu thực tiễn trong lĩnh vực y tế và xu hướng phát triển mạnh mẽ của trí tuệ nhân tạo trong chẩn đoán hình ảnh. Ảnh X-quang ngực là loại dữ liệu y tế phổ biến, được sử dụng thường xuyên trong quá trình thăm khám và phát hiện các bệnh lý về phổi. Tuy nhiên, quá trình phân tích ảnh X-quang đòi hỏi kiến thức chuyên môn, kinh nghiệm lâm sàng và sự tập trung cao. Trong một số trường hợp, các bất thường trên ảnh có thể khó nhận biết bằng mắt thường, đặc biệt khi tổn thương nhỏ hoặc biểu hiện không rõ ràng.

Bên cạnh đó, các bệnh lý về phổi như COVID-19, viêm phổi và lao phổi là những vấn đề sức khỏe có ảnh hưởng lớn đến cộng đồng. Việc hỗ trợ phân loại ảnh X-quang thành các nhóm như COVID-19, Normal, Pneumonia và Tuberculosis có thể giúp mô phỏng một hệ thống hỗ trợ nhận diện ban đầu các bất thường liên quan đến phổi. Mặc dù kết quả từ hệ thống AI không thể thay thế kết luận chuyên môn của bác sĩ, nhưng có thể đóng vai trò là nguồn thông tin tham khảo trong quá trình phân tích và học tập.

Sự phát triển của học sâu đã mở ra nhiều cơ hội trong việc xây dựng các hệ thống hỗ trợ phân tích ảnh y tế. Các mô hình học sâu có khả năng tự động học đặc trưng từ dữ liệu ảnh, từ đó hỗ trợ phân loại và dự đoán một cách hiệu quả. Trong đề tài này, ResNet101 được lựa chọn làm mô hình chính nhờ khả năng học đặc trưng sâu, tận dụng học chuyển giao từ mô hình đã được huấn luyện trước và phù hợp với bài toán phân loại ảnh X-quang phổi.

Một lý do quan trọng khác là vấn đề giải thích kết quả của mô hình AI. Trong lĩnh vực y tế, người dùng không chỉ cần biết mô hình dự đoán ảnh thuộc lớp nào, mà còn cần biết mô hình đã tập trung vào vùng ảnh nào để đưa ra kết quả. Các kỹ thuật Explainable AI như Grad-CAM, Grad-CAM++, LIME và SHAP giúp tăng khả năng giải thích cho mô hình học sâu. Grad-CAM và Grad-CAM++ tạo bản đồ nhiệt thể hiện vùng ảnh quan trọng, LIME phân tích ảnh theo các vùng nhỏ có ảnh hưởng đến dự đoán, còn SHAP đánh giá mức độ đóng góp của các vùng ảnh đối với kết quả phân loại.

Ngoài giá trị ứng dụng, đề tài còn giúp người thực hiện củng cố kiến thức về xử lý ảnh, học sâu, mạng nơ-ron tích chập, học chuyển giao, phân loại ảnh y tế và giải thích mô hình AI. Đồng thời, đề tài tạo điều kiện để vận dụng các công cụ và

thư viện hiện đại như Python, TensorFlow/Keras, OpenCV, Kaggle và các thư viện hỗ trợ trực quan hóa mô hình. Từ đó, sinh viên có thể phát triển tư duy nghiên cứu, khả năng thực nghiệm và kỹ năng xây dựng hệ thống phần mềm có tích hợp trí tuệ nhân tạo.

Từ những lý do trên, đề tài được lựa chọn nhằm xây dựng một hệ thống hỗ trợ phân tích ảnh X-quang phổi, vừa có khả năng dự đoán bệnh lý, vừa có khả năng giải thích vùng ảnh mà mô hình quan tâm khi đưa ra kết quả.

1.3 MỤC TIÊU NGHIÊN CỨU

1.3.1 Mục tiêu chung

Mục tiêu tổng quát của đề tài là tìm hiểu và xây dựng một hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực. Hệ thống sử dụng mô hình học sâu ResNet101 để phân loại ảnh X-quang phổi thành bốn lớp: COVID-19, Normal, Pneumonia và Tuberculosis. Đồng thời, đề tài áp dụng các kỹ thuật giải thích mô hình gồm Grad-CAM, Grad-CAM++, LIME và SHAP nhằm trực quan hóa hoặc phân tích các vùng ảnh có ảnh hưởng đến kết quả dự đoán.

Thông qua đề tài, hệ thống được định hướng như một công cụ hỗ trợ tham khảo trong quá trình phân tích ảnh X-quang. Người dùng có thể tải ảnh X-quang lên hệ thống, xem kết quả dự đoán, quan sát xác suất của từng lớp bệnh và theo dõi các vùng ảnh được mô hình chú ý thông qua các kỹ thuật giải thích. Mục tiêu của đề tài không phải thay thế bác sĩ, mà nhằm hỗ trợ quá trình tham khảo, học tập, nghiên cứu và minh họa khả năng ứng dụng của trí tuệ nhân tạo có khả năng giải thích trong y tế.

1.3.2 Mục tiêu cụ thể

Để đạt được mục tiêu chung, đề tài tập trung thực hiện các mục tiêu cụ thể sau:

Thứ nhất, tìm hiểu cơ sở lý thuyết về trí tuệ nhân tạo, học sâu, mạng nơ-ron tích chập, học chuyển giao và các mô hình phân loại ảnh y tế. Trong đó, đề tài tập trung vào kiến trúc ResNet101 và khả năng ứng dụng của mô hình này trong phân tích ảnh X-quang ngực.

Thứ hai, tìm hiểu bộ dữ liệu ảnh X-quang phổi gồm bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis. Dữ liệu được sử dụng để huấn luyện, kiểm thử và đánh giá mô hình trong bài toán phân loại đa lớp.

Thứ ba, xây dựng quy trình tiền xử lý ảnh X-quang, bao gồm đọc ảnh, thay đổi kích thước ảnh về chuẩn đầu vào của mô hình, chuẩn hóa dữ liệu và tăng cường dữ liệu nhằm cải thiện khả năng học của mô hình.

Thứ tư, xây dựng, huấn luyện và đánh giá mô hình ResNet101 pretrained cho

bài toán phân loại ảnh X-quang phổi. Mô hình được đánh giá thông qua các chỉ số Accuracy, Precision, Recall và F1-score. Trong đó, F1-score được xem là chỉ số quan trọng vì phản ánh sự cân bằng giữa Precision và Recall, phù hợp với bài toán phân loại bệnh lý y tế.

Thứ năm, triển khai các kỹ thuật Explainable AI gồm Grad-CAM, Grad-CAM++, LIME và SHAP để giải thích kết quả dự đoán của mô hình. Các kỹ thuật này giúp người dùng quan sát hoặc phân tích những vùng ảnh có ảnh hưởng lớn đến quyết định của mô hình.

Thứ sáu, xây dựng giao diện demo dạng web cho hệ thống, bao gồm các chức năng như tải ảnh X-quang, hiển thị kết quả dự đoán, hiển thị xác suất của từng lớp bệnh và trình bày kết quả giải thích mô hình. Giao diện giúp mô phỏng quy trình hoạt động của hệ thống và hỗ trợ trình bày kết quả nghiên cứu một cách trực quan.

1.4 PHẠM VI NGHIÊN CỨU

1.4.1 Không gian

Đề tài được thực hiện trong phạm vi nghiên cứu và xây dựng hệ thống thử nghiệm phục vụ cho mục đích học tập, nghiên cứu khoa học và báo cáo khóa luận. Hệ thống tập trung vào dữ liệu ảnh X-quang phổi gồm bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis, chưa triển khai trực tiếp trong môi trường bệnh viện thực tế.

Phần mô hình AI được thực nghiệm trên nền tảng Kaggle nhằm tận dụng tài nguyên tính toán GPU phục vụ quá trình huấn luyện và đánh giá mô hình. Ngoài ra, giao diện demo dạng web được xây dựng và chạy trên máy tính cá nhân, phục vụ mục đích mô phỏng quy trình phân tích ảnh X-quang và hiển thị kết quả dự đoán.

Hệ thống hướng đến việc minh họa quy trình phân tích ảnh X-quang ngực bằng mô hình học sâu kết hợp giải thích trực quan bằng Explainable AI. Đề tài chưa kết nối với hệ thống quản lý bệnh viện hoặc hệ thống lưu trữ ảnh y tế thực tế như PACS, cũng chưa được kiểm định để sử dụng trong môi trường y khoa chính thức.

1.4.2 Thời gian

Thời gian thực hiện đề tài được chia thành nhiều giai đoạn, bao gồm tìm hiểu tài liệu, khảo sát các nghiên cứu liên quan, chuẩn bị dữ liệu, xây dựng mô hình, huấn luyện mô hình, đánh giá kết quả, triển khai các kỹ thuật giải thích mô hình và xây dựng giao diện demo.

Ở giai đoạn đầu, đề tài tập trung tìm hiểu cơ sở lý thuyết về ảnh X-quang ngực, mô hình học sâu, mạng ResNet101 và các phương pháp giải thích mô hình như Grad-CAM, Grad-CAM++, LIME và SHAP. Tiếp theo, dữ liệu ảnh X-quang được khảo sát, xử lý và đưa vào quy trình huấn luyện. Sau đó, mô hình được đánh

giá bằng các chỉ số phù hợp với bài toán phân loại đa lớp. Giai đoạn cuối tập trung xây dựng giao diện demo, hoàn thiện phần trình bày kết quả, nhận xét thực nghiệm và đề xuất hướng phát triển.

1.4.3 Đối tượng nghiên cứu

Đối tượng nghiên cứu chính của đề tài là ảnh X-quang ngực và các nhóm bệnh lý phổi được biểu diễn thông qua nhãn dữ liệu. Đề tài tập trung vào bài toán phân loại đa lớp với bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis.

Bên cạnh dữ liệu ảnh, đề tài còn nghiên cứu mô hình ResNet101 pretrained và cách tinh chỉnh mô hình cho bài toán phân loại ảnh X-quang. Ngoài ra, các phương pháp giải thích mô hình như Grad-CAM, Grad-CAM++, LIME và SHAP cũng là đối tượng nghiên cứu quan trọng, nhằm làm rõ vùng ảnh hoặc đặc trưng ảnh mà mô hình tập trung khi đưa ra dự đoán.

Phạm vi nghiên cứu không bao gồm việc chẩn đoán y khoa chính thức, không đưa ra kết luận điều trị và không thay thế quyết định chuyên môn của bác sĩ. Hệ thống chỉ đóng vai trò hỗ trợ tham khảo và minh họa khả năng ứng dụng của AI trong phân tích ảnh X-quang.

1.5 BỐ CỤC CỦA LUẬN VĂN

Luận văn được cấu trúc thành sáu chương, mỗi chương tập trung vào một nội dung cụ thể nhằm trình bày một cách hệ thống và logic về quá trình nghiên cứu, xây dựng, thực nghiệm cũng như đánh giá hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang.

Chương 1 – Giới thiệu: Trình bày tổng quan về đề tài, nêu rõ bối cảnh nghiên cứu, lý do lựa chọn đề tài, mục tiêu nghiên cứu, phạm vi nghiên cứu và đối tượng nghiên cứu của luận văn. Ngoài ra, chương này cũng đề cập đến ý nghĩa khoa học, ý nghĩa thực tiễn của đề tài và bố cục tổng thể của luận văn.

Chương 2 – Cơ sở lý luận và phương pháp nghiên cứu: Trình bày các kiến thức nền tảng liên quan đến đề tài như trí tuệ nhân tạo, học sâu, mạng nơ-ron tích chập, học chuyển giao, ảnh X-quang ngực và bài toán phân loại ảnh y tế. Bên cạnh đó, chương này giới thiệu mô hình ResNet101 và các kỹ thuật giải thích mô hình Explainable AI như Grad-CAM, Grad-CAM++, LIME và SHAP. Đồng thời, chương cũng làm rõ các phương pháp nghiên cứu được sử dụng trong quá trình thực hiện đề tài.

Chương 3 – Phương pháp nghiên cứu: Trình bày chi tiết quy trình thực hiện đề tài, bao gồm quá trình thu thập và chuẩn bị dữ liệu ảnh X-quang, tiền xử lý dữ liệu, xây dựng mô, lựa chọn tham số huấn luyện và phương pháp đánh giá mô hình. Chương này cũng mô tả cách áp dụng các kỹ thuật giải thích mô hình nhằm trực quan hóa và phân tích những vùng ảnh có ảnh hưởng đến kết quả dự đoán.

Chương 4 – Thực nghiệm: Mô tả quá trình thực nghiệm mô hình trên môi trường Kaggle, bao gồm thiết lập môi trường huấn luyện, chia dữ liệu, huấn luyện mô hình ResNet101 và kiểm thử mô hình trên tập dữ liệu ảnh X-quang. Chương này cũng trình bày quá trình áp dụng các kỹ thuật Grad-CAM, Grad-CAM++, LIME và SHAP để giải thích kết quả dự đoán của mô hình.

Chương 5 – Kết quả nghiên cứu và đánh giá hệ thống: Trình bày các kết quả đạt được sau quá trình huấn luyện và kiểm thử mô hình. Các kết quả được đánh giá thông qua các chỉ số Accuracy, Precision, Recall, F1-score, Classification Report và Confusion Matrix. Đồng thời, chương này phân tích ưu điểm, hạn chế của mô hình, đánh giá khả năng phân loại bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis, cũng như trình bày giao diện demo dạng web của hệ thống.

Chương 6 – Kết luận và hướng phát triển: Tóm tắt những nội dung chính đã thực hiện trong luận văn, đánh giá hiệu quả của mô hình ResNet101 trong bài toán phân loại ảnh X-quang phổi và vai trò của các kỹ thuật Explainable AI trong việc tăng tính minh bạch cho hệ thống. Chương này cũng đề xuất một số hướng phát triển trong tương lai như mở rộng dữ liệu, cải thiện khả năng nhận diện lớp Normal, tối ưu mô hình, tích hợp backend để kết nối mô hình với giao diện web và nâng cao khả năng ứng dụng của hệ thống trong thực tế.

1.6 Ý NGHĨA KHOA HỌC VÀ THỰC TIỄN CỦA ĐỀ TÀI

Về mặt khoa học, đề tài góp phần nghiên cứu và minh họa khả năng ứng dụng của học sâu trong phân tích ảnh X-quang ngực. Việc sử dụng mô hình ResNet101 pretrained cho bài toán phân loại ảnh X-quang phổi giúp người thực hiện hiểu rõ hơn về quy trình xây dựng mô hình AI trong lĩnh vực ảnh y tế, từ khâu chuẩn bị dữ liệu, tiền xử lý ảnh, huấn luyện mô hình đến đánh giá kết quả thực nghiệm.

Đề tài cũng góp phần làm rõ vai trò của Explainable AI trong các hệ thống AI y tế. Thông qua Grad-CAM, Grad-CAM++, LIME và SHAP, mô hình không chỉ đưa ra kết quả dự đoán mà còn cung cấp thông tin trực quan hoặc phân tích định lượng về những vùng ảnh có ảnh hưởng đến quyết định của mô hình. Điều này giúp giảm bớt tính “hộp đen” của mô hình học sâu và tăng tính minh bạch trong quá trình phân tích.

Về mặt thực tiễn, đề tài có thể được sử dụng như một mô hình tham khảo cho việc xây dựng các hệ thống hỗ trợ phân tích ảnh X-quang trong môi trường học tập, nghiên cứu hoặc thử nghiệm. Giao diện demo dạng web giúp người dùng dễ dàng hình dung quy trình hoạt động của hệ thống, từ bước tải ảnh đầu vào đến bước nhận kết quả dự đoán và quan sát kết quả giải thích mô hình.

Ngoài ra, đề tài còn có ý nghĩa trong việc hỗ trợ sinh viên ngành Công nghệ thông tin tiếp cận các bài toán liên ngành giữa AI và y tế. Thông qua quá trình thực

hiện, sinh viên có thể rèn luyện kỹ năng xử lý dữ liệu ảnh, xây dựng mô hình học sâu, đánh giá kết quả thực nghiệm, thiết kế giao diện và trình bày kết quả nghiên cứu một cách khoa học.

Mặc dù hệ thống chưa đủ điều kiện để sử dụng trong chẩn đoán y khoa thực tế, đề tài vẫn mang lại giá trị ứng dụng trong việc minh họa tiềm năng của AI có khả năng giải thích trong hỗ trợ phân tích ảnh y tế. Đây là hướng nghiên cứu có ý nghĩa trong bối cảnh trí tuệ nhân tạo ngày càng được quan tâm trong lĩnh vực chăm sóc sức khỏe.

1.7 PHƯƠNG PHÁP NGHIÊN CỨU

Để thực hiện đề tài “Tìm hiểu và xây dựng mô hình AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang”, luận văn sử dụng kết hợp nhiều phương pháp nghiên cứu khác nhau, bao gồm nghiên cứu tài liệu, thu thập và xử lý dữ liệu, tiền xử lý ảnh, thực nghiệm mô hình học sâu, đánh giá kết quả và giải thích mô hình. Các phương pháp này được triển khai theo từng giai đoạn nhằm đảm bảo quá trình xây dựng hệ thống có tính hệ thống, khoa học và phù hợp với mục tiêu nghiên cứu.

Thứ nhất, đề tài sử dụng phương pháp nghiên cứu tài liệu nhằm tổng hợp các kiến thức nền tảng liên quan đến trí tuệ nhân tạo, học sâu, mạng nơ-ron tích chập, học chuyển giao và bài toán phân loại ảnh X-quang phổi. Bên cạnh đó, đề tài cũng tìm hiểu mô hình ResNet101 và các kỹ thuật Explainable AI như Grad-CAM, Grad-CAM++, LIME và SHAP. Việc nghiên cứu tài liệu giúp hình thành cơ sở lý luận cho quá trình xây dựng mô hình, lựa chọn phương pháp thực nghiệm và đánh giá kết quả.

Thứ hai, đề tài tiến hành thu thập và xử lý dữ liệu ảnh X-quang phổi. Bộ dữ liệu được sử dụng gồm bốn lớp chính là COVID-19, Normal, Pneumonia và Tuberculosis. Dữ liệu được tổ chức theo từng thư mục tương ứng với từng lớp bệnh, phục vụ cho quá trình huấn luyện, kiểm thử và đánh giá mô hình. Việc kiểm tra cấu trúc dữ liệu, số lượng ảnh của từng lớp và cách phân chia dữ liệu là bước quan trọng nhằm đảm bảo mô hình có thể học và đánh giá đúng trên các tập dữ liệu.

Thứ ba, đề tài thực hiện tiền xử lý ảnh trước khi đưa vào mô hình học sâu. Các ảnh X-quang được thay đổi kích thước về cùng một chuẩn đầu vào phù hợp với mô hình ResNet101, đồng thời được chuẩn hóa dữ liệu để hỗ trợ quá trình huấn luyện. Ngoài ra, một số kỹ thuật tăng cường dữ liệu như xoay nhẹ, phóng to hoặc dịch chuyển ảnh được áp dụng nhằm giúp mô hình học được nhiều đặc trưng hơn và hạn chế tình trạng quá khớp. Tuy nhiên, các kỹ thuật tăng cường dữ liệu được sử dụng ở mức phù hợp để tránh làm thay đổi quá nhiều đặc điểm tự nhiên của ảnh X-quang.

Thứ tư, đề tài xây dựng và thực nghiệm mô hình ResNet101 cho bài toán

phân loại ảnh X-quang phổi. Mô hình được sử dụng theo hướng học chuyển giao, tận dụng trọng số đã được huấn luyện trước, sau đó tinh chỉnh trên bộ dữ liệu ảnh X-quang của đề tài. Trong quá trình huấn luyện, một số tầng đầu của mô hình được đóng băng nhằm giữ lại các đặc trưng tổng quát đã học, trong khi các tầng sau được cho phép học tiếp để thích nghi với dữ liệu ảnh X-quang phổi. Quá trình thực nghiệm được thực hiện trên môi trường Kaggle nhằm tận dụng tài nguyên GPU cho việc huấn luyện và đánh giá mô hình.

Thứ năm, đề tài sử dụng các chỉ số đánh giá như Accuracy, Precision, Recall, F1-score, Classification Report và Confusion Matrix để phân tích hiệu quả của mô hình. Các chỉ số này giúp đánh giá khả năng phân loại tổng thể cũng như hiệu quả dự đoán trên từng lớp bệnh. Trong đó, F1-score được xem là một chỉ số quan trọng vì phản ánh sự cân bằng giữa Precision và Recall, đặc biệt phù hợp với bài toán phân loại bệnh lý y tế. Ngoài ra, ma trận nhầm lẫn được sử dụng để quan sát các trường hợp mô hình dự đoán sai, từ đó nhận xét những lớp còn dễ bị nhầm lẫn.

Thứ sáu, đề tài áp dụng các kỹ thuật Explainable AI gồm Grad-CAM, Grad-CAM++, LIME và SHAP nhằm giải thích kết quả dự đoán của mô hình. Grad-CAM và Grad-CAM++ được sử dụng để tạo bản đồ nhiệt thể hiện vùng ảnh mà mô hình tập trung khi đưa ra dự đoán. LIME giúp phân tích các vùng nhỏ trong ảnh có ảnh hưởng đến kết quả phân loại, trong khi SHAP hỗ trợ đánh giá mức độ đóng góp của các vùng ảnh đối với quyết định của mô hình. Việc kết hợp các kỹ thuật giải thích giúp hệ thống không chỉ đưa ra kết quả dự đoán mà còn hỗ trợ người dùng hiểu rõ hơn cơ sở đưa ra quyết định của mô hình.

Cuối cùng, đề tài xây dựng giao diện demo dạng web nhằm mô phỏng quy trình sử dụng hệ thống. Giao diện được phát triển bằng Visual Studio Code với các công nghệ HTML, CSS và JavaScript. Giao diện cho phép người dùng tải ảnh X-quang, xem ảnh đầu vào, quan sát kết quả dự đoán, xác suất của từng lớp bệnh và các phần minh họa giải thích mô hình. Việc xây dựng giao diện giúp trình bày kết quả nghiên cứu một cách trực quan, đồng thời mô phỏng cách hệ thống có thể được sử dụng trong môi trường thực tế với vai trò là công cụ hỗ trợ tham khảo.

1.8 TỔNG KẾT CHƯƠNG

Trong chương 1, đề tài đã trình bày tổng quan về vấn đề nghiên cứu, lý do chọn đề tài, mục tiêu, phạm vi, đối tượng nghiên cứu, bố cục luận văn và ý nghĩa khoa học, thực tiễn của hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang.

Nội dung chương đã làm rõ nhu cầu ứng dụng trí tuệ nhân tạo trong phân tích ảnh X-quang ngực, đồng thời chỉ ra hạn chế của các mô hình học sâu khi thiếu khả năng giải thích. Từ đó, đề tài đề xuất hướng tiếp cận kết hợp mô hình ResNet101 với các kỹ thuật Explainable AI gồm Grad-CAM, Grad-CAM++, LIME và SHAP

nhằm vừa hỗ trợ phân loại ảnh X-quang phổi, vừa trực quan hóa hoặc phân tích vùng ảnh mà mô hình quan tâm.

Chương này cũng xác định rõ phạm vi nghiên cứu của đề tài là xây dựng hệ thống thử nghiệm phục vụ mục đích học tập và nghiên cứu, không thay thế bác sĩ trong chẩn đoán y khoa. Các nội dung tiếp theo của luận văn sẽ lần lượt trình bày cơ sở lý thuyết, phương pháp nghiên cứu, thiết kế hệ thống, kết quả thực nghiệm và hướng phát triển trong tương lai.

CHƯƠNG 2

CƠ SỞ LÝ LUẬN VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1 CƠ SỞ LÝ LUẬN

2.1.1 Tổng quan về hệ thống

Trong bối cảnh trí tuệ nhân tạo đang được ứng dụng ngày càng rộng rãi trong lĩnh vực y tế, việc sử dụng các mô hình học sâu để hỗ trợ phân tích hình ảnh chẩn đoán ngày càng trở nên cần thiết. Ảnh X-quang ngực là một trong những phương pháp chẩn đoán hình ảnh phổ biến, có chi phí thấp, thời gian thực hiện nhanh và được sử dụng thường xuyên trong quá trình phát hiện các bệnh lý liên quan đến phổi. Tuy nhiên, việc đọc và phân tích ảnh X-quang vẫn phụ thuộc nhiều vào kinh nghiệm chuyên môn của bác sĩ. Trong một số trường hợp, các dấu hiệu bệnh lý có thể xuất hiện không rõ ràng, tổn thương có kích thước nhỏ hoặc hình ảnh bị ảnh hưởng bởi chất lượng chụp, từ đó gây khó khăn trong quá trình nhận diện và đánh giá. Vì vậy, việc xây dựng hệ thống AI hỗ trợ phân tích ảnh X-quang phổi có ý nghĩa quan trọng trong việc cung cấp thêm thông tin tham khảo, hỗ trợ quá trình phát hiện bất thường và nâng cao tính trực quan trong phân tích hình ảnh y tế.

Mục tiêu khi xây dựng hệ thống là cung cấp một công cụ hỗ trợ phân loại ảnh X-quang phổi theo hướng đơn giản, dễ sử dụng nhưng vẫn đảm bảo khả năng xử lý và hiển thị kết quả một cách rõ ràng. Hệ thống tập trung vào bài toán phân loại ảnh X-quang thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Trong đề tài này, mô hình ResNet101 được sử dụng làm mô hình chính nhờ khả năng học đặc trưng sâu từ ảnh và tận dụng hiệu quả học chuyển giao từ mô hình đã được huấn luyện trước. Ảnh đầu vào sau khi được tải lên hệ thống sẽ được tiền xử lý, đưa vào mô hình để dự đoán lớp bệnh và hiển thị xác suất tương ứng của từng lớp. Bên cạnh đó, hệ thống còn tích hợp các kỹ thuật Explainable AI như Grad-CAM, Grad-CAM++, LIME và SHAP nhằm giải thích kết quả dự đoán, giúp người dùng quan sát các vùng ảnh có ảnh hưởng lớn đến quyết định của mô hình. Về mặt chức năng, hệ thống cần cho phép người dùng tải ảnh X-quang, xem kết quả phân loại, theo dõi độ tin cậy của dự đoán và quan sát bản đồ giải thích trực quan. Về yêu cầu phi chức năng, hệ thống cần có giao diện dễ sử dụng, phản hồi nhanh, trình bày thông tin rõ ràng và phù hợp với mục đích học tập, nghiên cứu.

Bên cạnh mục tiêu kỹ thuật, hệ thống còn mang ý nghĩa thực tiễn trong việc minh họa khả năng ứng dụng trí tuệ nhân tạo vào lĩnh vực hỗ trợ chẩn đoán hình ảnh y tế. Trong thực tế, số lượng ảnh X-quang cần phân tích tại các cơ sở y tế có thể rất lớn, trong khi việc đánh giá ảnh đòi hỏi sự tập trung và kinh nghiệm chuyên môn cao. Một hệ thống AI hỗ trợ phân tích ảnh có thể giúp mô phỏng quy trình dự đoán tự động, cung cấp thêm góc nhìn tham khảo và hỗ trợ người dùng hiểu rõ hơn về vùng ảnh mà mô hình quan tâm. Đặc biệt, việc kết hợp mô hình ResNet101 với các

kỹ thuật giải thích như Grad-CAM, Grad-CAM++, LIME và SHAP giúp giảm bớt tính “hộp đen” của mô hình học sâu, từ đó tăng tính minh bạch trong quá trình dự đoán. Tuy nhiên, hệ thống không có chức năng thay thế bác sĩ hoặc đưa ra kết luận y khoa chính thức, mà chỉ đóng vai trò là công cụ hỗ trợ tham khảo trong học tập, nghiên cứu và trình bày khả năng ứng dụng của AI trong phân tích ảnh X-quang phổi.

2.1.2 Lịch sử hình thành và phát triển của hệ thống

Việc ứng dụng công nghệ vào hỗ trợ chẩn đoán hình ảnh y tế đã xuất hiện từ khá sớm, khi các hệ thống máy tính bắt đầu được sử dụng để lưu trữ, xử lý và phân tích dữ liệu hình ảnh. Ban đầu, quá trình chẩn đoán hình ảnh chủ yếu phụ thuộc vào bác sĩ chuyên khoa, trong đó ảnh X-quang, CT, MRI hoặc siêu âm được đọc và đánh giá bằng kinh nghiệm lâm sàng. Ở giai đoạn này, vai trò của máy tính chủ yếu là hỗ trợ lưu trữ hình ảnh, quản lý hồ sơ bệnh nhân và hiển thị ảnh trên các thiết bị chuyên dụng. Việc phân tích nội dung ảnh vẫn được thực hiện thủ công, do đó có thể gặp khó khăn khi số lượng ảnh lớn, chất lượng ảnh không đồng đều hoặc dấu hiệu bệnh lý không rõ ràng.

Trong giai đoạn tiếp theo, các hệ thống hỗ trợ chẩn đoán bằng máy tính, thường được gọi là Computer-Aided Diagnosis, bắt đầu được nghiên cứu và ứng dụng. Các hệ thống này sử dụng những phương pháp xử lý ảnh truyền thống như lọc nhiễu, tăng cường độ tương phản, phân đoạn vùng ảnh và trích xuất đặc trưng thủ công để hỗ trợ phát hiện bất thường. Đối với ảnh X-quang ngực, các kỹ thuật này được áp dụng nhằm nhận diện một số dấu hiệu liên quan đến phổi như vùng mờ, tổn thương, nốt bất thường hoặc các thay đổi trong cấu trúc mô phổi. Tuy nhiên, hiệu quả của các phương pháp truyền thống phụ thuộc nhiều vào chất lượng đặc trưng được thiết kế thủ công, đồng thời khó thích nghi với sự đa dạng của dữ liệu ảnh y tế trong thực tế.

Sự phát triển mạnh mẽ của học máy và đặc biệt là học sâu đã tạo ra bước chuyển quan trọng trong lĩnh vực phân tích ảnh y tế. Thay vì phải thiết kế đặc trưng thủ công, các mô hình học sâu có khả năng tự động học đặc trưng trực tiếp từ dữ liệu ảnh. Trong đó, mạng nơ-ron tích chập được xem là một trong những kiến trúc quan trọng nhất đối với bài toán nhận dạng và phân loại hình ảnh. Các mô hình CNN có thể học được các đặc trưng từ mức thấp như cạnh, đường biên, vùng sáng tối đến các đặc trưng phức tạp hơn liên quan đến cấu trúc bệnh lý trên ảnh. Nhờ đó, CNN được ứng dụng rộng rãi trong nhiều bài toán ảnh y tế như phân loại ảnh X-quang, phát hiện tổn thương phổi, phân loại khối u, phân tích ảnh võng mạc và nhiều dạng ảnh y khoa khác.

Cùng với sự phát triển của các mô hình học sâu, nhiều kiến trúc mạng hiện đại đã được đề xuất nhằm cải thiện độ chính xác và khả năng học đặc trưng của mô

hình. Các mô hình như VGG, ResNet, DenseNet và EfficientNet đã được ứng dụng trong nhiều nghiên cứu về phân loại ảnh y tế. Trong đó, ResNet là một kiến trúc nổi bật nhờ sử dụng các kết nối tắt, giúp mô hình học sâu hơn nhưng vẫn hạn chế được vấn đề suy giảm hiệu quả khi số tầng tăng lên. Phiên bản ResNet101 được sử dụng trong đề tài này có khả năng học các đặc trưng phức tạp từ ảnh X-quang phổi, đồng thời tận dụng học chuyển giao từ mô hình đã được huấn luyện trước trên tập dữ liệu lớn. Điều này giúp rút ngắn thời gian huấn luyện và cải thiện hiệu quả khi dữ liệu y tế có giới hạn.

Trong những năm gần đây, bên cạnh yêu cầu về độ chính xác, khả năng giải thích của mô hình AI ngày càng được quan tâm, đặc biệt trong lĩnh vực y tế. Các mô hình học sâu thường bị xem là “hộp đen” vì người dùng khó biết được mô hình dựa vào yếu tố nào để đưa ra kết quả dự đoán. Để khắc phục hạn chế này, các kỹ thuật Explainable AI đã được phát triển nhằm giúp trực quan hóa hoặc phân tích quyết định của mô hình. Những phương pháp như Grad-CAM, Grad-CAM++, LIME và SHAP cho phép người dùng quan sát vùng ảnh có ảnh hưởng lớn đến kết quả phân loại hoặc đánh giá mức độ đóng góp của các vùng ảnh đối với dự đoán. Đối với ảnh X-quang phổi, các kỹ thuật này có ý nghĩa quan trọng vì giúp người dùng không chỉ biết mô hình dự đoán bệnh gì, mà còn có thể quan sát vùng phổi mà mô hình tập trung khi đưa ra kết quả.

Như vậy, quá trình phát triển của các hệ thống AI hỗ trợ chẩn đoán hình ảnh y tế đã chuyển từ các phương pháp phân tích thủ công sang các hệ thống xử lý ảnh truyền thống, sau đó phát triển mạnh với học sâu và hiện nay đang hướng đến các mô hình có khả năng giải thích. Sự kết hợp giữa mô hình ResNet101 và các kỹ thuật Explainable AI trong đề tài phản ánh xu hướng xây dựng hệ thống AI không chỉ có khả năng phân loại ảnh X-quang phổi, mà còn hỗ trợ minh bạch hóa quá trình dự đoán. Đây là hướng tiếp cận phù hợp với nhu cầu ứng dụng trí tuệ nhân tạo trong y tế, nơi kết quả của mô hình cần được trình bày rõ ràng, có khả năng kiểm tra trực quan và chỉ đóng vai trò hỗ trợ tham khảo cho người dùng.

2.1.3 Môi trường phát triển – Kaggle & Visual Studio Code

Trong quá trình thực hiện đề tài, hai môi trường phát triển chính được sử dụng là Kaggle và Visual Studio Code. Mỗi môi trường đảm nhận một vai trò khác nhau trong quá trình xây dựng hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang. Kaggle được sử dụng cho quá trình xử lý dữ liệu, huấn luyện, kiểm thử và đánh giá mô hình học sâu. Trong khi đó, Visual Studio Code được sử dụng để xây dựng giao diện demo dạng web nhằm mô phỏng quy trình sử dụng hệ thống.

Kaggle là một nền tảng trực tuyến hỗ trợ thực nghiệm các bài toán về khoa học dữ liệu, học máy và học sâu. Nền tảng này cung cấp môi trường Notebook có thể chạy mã Python, hỗ trợ nhiều thư viện phổ biến như TensorFlow, Keras, NumPy,

Pandas, Matplotlib, Scikit-learn và OpenCV. Một ưu điểm quan trọng của Kaggle là khả năng sử dụng tài nguyên GPU, giúp quá trình huấn luyện các mô hình học sâu diễn ra nhanh hơn so với việc chỉ chạy trên máy tính cá nhân. Trong đề tài này, Kaggle được sử dụng để lưu trữ và đọc bộ dữ liệu ảnh X-quang, tiền xử lý ảnh, xây dựng mô hình ResNet101, huấn luyện mô hình, lưu trọng số tốt nhất và đánh giá kết quả thông qua các chỉ số như Accuracy, Precision, Recall, F1-score, Classification Report và Confusion Matrix.

Bên cạnh việc huấn luyện mô hình, Kaggle còn được sử dụng để thực hiện các kỹ thuật giải thích mô hình. Sau khi mô hình ResNet101 được huấn luyện và đánh giá, các kỹ thuật Explainable AI như Grad-CAM, Grad-CAM++, LIME và SHAP được áp dụng nhằm trực quan hóa hoặc phân tích những vùng ảnh có ảnh hưởng đến quyết định của mô hình. Nhờ đó, kết quả dự đoán không chỉ dừng lại ở nhãn phân loại mà còn có thể được giải thích thông qua bản đồ nhiệt hoặc các vùng ảnh quan trọng.

Visual Studio Code là môi trường soạn thảo mã nguồn được sử dụng để xây dựng phần giao diện demo dạng web của hệ thống. Công cụ này hỗ trợ tốt các công nghệ web như HTML, CSS và JavaScript, đồng thời có thể mở rộng chức năng thông qua các tiện ích như Live Server. Trong đề tài, Visual Studio Code được dùng để thiết kế giao diện cho phép người dùng tải ảnh X-quang, xem ảnh đầu vào, quan sát kết quả dự đoán, xác suất của từng lớp bệnh và các phần minh họa giải thích mô hình. Giao diện web giúp mô phỏng quy trình hoạt động của hệ thống một cách trực quan, thuận tiện cho việc trình bày kết quả nghiên cứu.

Việc kết hợp Kaggle và Visual Studio Code giúp phân chia rõ ràng giữa phần xử lý mô hình và phần giao diện hệ thống. Kaggle đảm nhận vai trò môi trường thực nghiệm AI, phục vụ huấn luyện và đánh giá mô hình ResNet101. Visual Studio Code đảm nhận vai trò phát triển giao diện demo, giúp người dùng dễ dàng hình dung cách hệ thống hoạt động trong thực tế. Sự kết hợp này phù hợp với phạm vi nghiên cứu của đề tài, trong đó hệ thống được xây dựng nhằm phục vụ học tập, nghiên cứu và minh họa khả năng ứng dụng trí tuệ nhân tạo có khả năng giải thích trong phân tích ảnh X-quang phổi.

2.1.4 Dataset

Dataset là thành phần quan trọng trong quá trình xây dựng và đánh giá mô hình học sâu, đặc biệt đối với các bài toán phân loại ảnh y tế. Chất lượng, cấu trúc và cách tổ chức dữ liệu có ảnh hưởng trực tiếp đến khả năng học đặc trưng, độ chính xác và khả năng tổng quát hóa của mô hình. Trong đề tài này, dữ liệu được sử dụng là bộ ảnh X-quang phổi gồm bốn lớp phân loại chính: COVID-19, Normal, Pneumonia và Tuberculosis. Đây là các nhóm ảnh đại diện cho một số tình trạng phổ biến liên quan đến phổi, bao gồm ảnh phổi bình thường và các ảnh có dấu hiệu


bệnh lý.

Bộ dữ liệu được tổ chức theo cấu trúc thư mục, trong đó mỗi thư mục con tương ứng với một lớp ảnh cụ thể. Cấu trúc này phù hợp với cách đọc dữ liệu của các thư viện học sâu như TensorFlow/Keras thông qua hàm `flow_from_directory`. Dữ liệu được chia thành các tập train, validation và test. Tập train được sử dụng để huấn luyện mô hình, tập validation được dùng để theo dõi quá trình học và điều chỉnh mô hình trong quá trình huấn luyện, còn tập test được sử dụng để đánh giá hiệu quả cuối cùng của mô hình sau khi huấn luyện hoàn tất.

Trong bài toán này, mỗi ảnh X-quang đầu vào chỉ thuộc về một trong bốn lớp: COVID-19, Normal, Pneumonia hoặc Tuberculosis. Do đó, đề tài tiếp cận bài toán theo hướng phân loại đa lớp. Mô hình ResNet101V2 nhận ảnh X-quang đã được tiền xử lý làm đầu vào và đưa ra xác suất dự đoán cho từng lớp. Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán cuối cùng của mô hình.

Dữ liệu ảnh X-quang có một số đặc điểm cần được quan tâm trong quá trình xử lý. Thứ nhất, ảnh có thể khác nhau về kích thước, độ sáng, độ tương phản và chất lượng chụp. Vì vậy, trước khi đưa vào mô hình, ảnh cần được thay đổi kích thước về cùng một chuẩn đầu vào, đồng thời được chuẩn hóa để phù hợp với quá trình huấn luyện. Thứ hai, số lượng ảnh giữa các lớp có thể không hoàn toàn cân bằng, điều này có thể khiến mô hình học thiên lệch về những lớp có nhiều ảnh hơn. Do đó, trong quá trình đánh giá, đề tài không chỉ sử dụng Accuracy mà còn kết hợp các chỉ số Precision, Recall, F1-score và Confusion Matrix để đánh giá chi tiết hiệu quả phân loại trên từng lớp.

Bộ dữ liệu trong đề tài được sử dụng nhằm phục vụ mục tiêu nghiên cứu và thực nghiệm mô hình AI hỗ trợ chẩn đoán ảnh X-quang phổi. Mặc dù dữ liệu có thể hỗ trợ mô hình học được các đặc trưng liên quan đến từng lớp bệnh, kết quả dự đoán của hệ thống chỉ mang tính chất tham khảo, không được sử dụng để thay thế kết luận chẩn đoán của bác sĩ. Việc sử dụng dataset trong đề tài chủ yếu nhằm minh họa quy trình xây dựng mô hình học sâu, đánh giá hiệu quả phân loại và áp dụng các kỹ thuật giải thích mô hình trong lĩnh vực ảnh y tế.



Hình 2.1 Các lớp dữ liệu trong bộ ảnh X-quang phổi

2.1.5 Mô hình ResNet101

ResNet, viết tắt của Residual Network, là một kiến trúc mạng nơ-ron tích chập sâu được sử dụng phổ biến trong các bài toán nhận dạng và phân loại hình ảnh. Mô hình này được xây dựng nhằm giải quyết một hạn chế thường gặp khi huấn luyện các mạng nơ-ron có nhiều tầng, đó là hiện tượng suy giảm hiệu quả khi số lớp của mạng tăng lên. Trong các mô hình mạng sâu truyền thống, khi tăng số lượng tầng, mô hình có thể gặp khó khăn trong quá trình học, dẫn đến độ chính xác không được cải thiện như mong muốn. ResNet khắc phục vấn đề này thông qua cơ chế kết nối tắt, hay còn gọi là residual connection, giúp thông tin được truyền qua mạng hiệu quả hơn.

Ý tưởng chính của ResNet là thay vì để các tầng học trực tiếp một ánh xạ đầu ra, mô hình sẽ học phần sai khác giữa đầu vào và đầu ra mong muốn. Cơ chế này cho phép đầu vào của một khối mạng được cộng trực tiếp với đầu ra sau một số lớp tích chập. Nhờ đó, gradient có thể lan truyền tốt hơn trong quá trình huấn luyện, giúp mô hình học được các đặc trưng sâu mà không bị suy giảm hiệu quả quá mạnh. Đây là một trong những lý do khiến ResNet có thể xây dựng được các mạng rất sâu như ResNet50, ResNet101 hoặc ResNet152.

Trong đề tài này, mô hình ResNet101V2 được lựa chọn làm mô hình chính để phân loại ảnh X-quang phổi. ResNet101V2 là một phiên bản cải tiến của ResNet, có cấu trúc gồm 101 tầng và sử dụng cách tổ chức khối residual hiệu quả hơn so với phiên bản ResNet ban đầu. Mô hình có khả năng học các đặc trưng phức tạp trong ảnh, từ các đặc trưng đơn giản như đường biên, vùng sáng tối đến các đặc trưng liên quan đến cấu trúc bất thường trên ảnh X-quang. Điều này phù hợp với bài toán phân loại ảnh X-quang phổi, nơi các dấu hiệu bệnh lý có thể xuất hiện dưới dạng những vùng mờ, tổn thương hoặc thay đổi nhỏ trong cấu trúc phổi.

ResNet101V2 được sử dụng theo hướng học chuyển giao. Thay vì huấn luyện toàn bộ mô hình từ đầu, đề tài tận dụng mô hình đã được huấn luyện trước trên tập dữ liệu lớn. Các tầng đầu của mô hình thường học được những đặc trưng tổng quát của ảnh như cạnh, hình dạng và kết cấu. Vì vậy, trong quá trình huấn luyện, một số tầng đầu được đóng băng nhằm giữ lại các đặc trưng đã học, trong khi các tầng sau được cho phép tiếp tục học để thích nghi với dữ liệu ảnh X-quang phổi. Cách tiếp cận này giúp giảm thời gian huấn luyện, tận dụng được tri thức từ mô hình có sẵn và cải thiện hiệu quả khi dữ liệu y tế có giới hạn.

Trong bài toán của đề tài, ảnh X-quang phổi được phân loại thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Sau khi ảnh đầu vào được tiền xử lý và đưa về kích thước phù hợp, mô hình ResNet101V2 sẽ trích xuất đặc trưng từ ảnh và đưa ra xác suất dự đoán cho từng lớp. Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán cuối cùng. Để đánh giá hiệu quả của mô hình, đề tài

sử dụng các chỉ số như Accuracy, Precision, Recall, F1-score và Confusion Matrix. Các chỉ số này giúp phản ánh khả năng phân loại tổng thể cũng như hiệu quả nhận diện trên từng lớp bệnh.

Việc lựa chọn ResNet101V2 làm mô hình chính trong đề tài xuất phát từ khả năng học đặc trưng sâu, hiệu quả trong các bài toán phân loại hình ảnh và khả năng áp dụng tốt trong học chuyển giao. Bên cạnh đó, mô hình ResNet cũng phù hợp để kết hợp với các kỹ thuật giải thích mô hình như Grad-CAM, Grad-CAM++, LIME và SHAP. Nhờ đó, hệ thống không chỉ đưa ra kết quả phân loại ảnh X-quang mà còn có thể hỗ trợ trực quan hóa hoặc phân tích những vùng ảnh có ảnh hưởng đến quyết định của mô hình, góp phần tăng tính minh bạch trong quá trình dự đoán.

2.1.6 Các kỹ thuật giải thích mô hình

Trong các hệ thống trí tuệ nhân tạo ứng dụng vào lĩnh vực y tế, kết quả dự đoán của mô hình không chỉ cần đạt độ chính xác cao mà còn cần có khả năng giải thích. Các mô hình học sâu, đặc biệt là mạng nơ-ron tích chập, thường được xem là mô hình “hộp đen” vì người dùng khó biết được mô hình dựa vào đặc trưng nào hoặc vùng ảnh nào để đưa ra quyết định. Đối với bài toán phân loại ảnh X-quang phổi, khả năng giải thích càng trở nên quan trọng vì người dùng cần quan sát được khu vực ảnh có ảnh hưởng đến kết quả dự đoán, từ đó hỗ trợ quá trình kiểm tra và đánh giá trực quan.

Explainable AI là hướng nghiên cứu nhằm làm rõ cách thức mô hình AI đưa ra quyết định. Thay vì chỉ hiển thị nhãn dự đoán như COVID-19, Normal, Pneumonia hoặc Tuberculosis, các kỹ thuật giải thích giúp mô hình cung cấp thêm thông tin về những vùng ảnh hoặc đặc trưng ảnh có ảnh hưởng đến kết quả phân loại. Trong đề tài này, bốn kỹ thuật giải thích được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion Sensitivity. Các kỹ thuật này được áp dụng sau khi mô hình ResNet101V2 đưa ra kết quả dự đoán, nhằm hỗ trợ trực quan hóa và phân tích quyết định của mô hình.

Grad-CAM, viết tắt của Gradient-weighted Class Activation Mapping, là một kỹ thuật giải thích phổ biến đối với các mô hình mạng nơ-ron tích chập. Phương pháp này sử dụng thông tin gradient từ lớp dự đoán để xác định mức độ quan trọng của các vùng đặc trưng trong lớp tích chập cuối cùng. Kết quả của Grad-CAM thường được biểu diễn dưới dạng bản đồ nhiệt, trong đó các vùng có màu nổi bật thể hiện những khu vực ảnh mà mô hình quan tâm nhiều khi đưa ra dự đoán. Đối với ảnh X-quang phổi, Grad-CAM giúp người dùng quan sát vùng phổi có ảnh hưởng lớn đến kết quả phân loại, chẳng hạn các vùng mờ hoặc vùng có dấu hiệu bất thường.

Grad-CAM++ là phiên bản cải tiến của Grad-CAM, được phát triển nhằm cải


thiện khả năng định vị các vùng ảnh quan trọng. Trong một số trường hợp, ảnh có thể chứa nhiều vùng bất thường hoặc vùng tổn thương không tập trung tại một vị trí duy nhất. Grad-CAM++ giúp tạo ra bản đồ nhiệt chi tiết hơn, hỗ trợ làm rõ các vùng có liên quan đến quyết định của mô hình. Đối với bài toán phân loại ảnh X-quang phổi, kỹ thuật này có thể giúp tăng khả năng quan sát trực quan những khu vực mà mô hình xem là quan trọng khi phân loại ảnh vào các lớp bệnh.

Integrated Gradients là một kỹ thuật giải thích dựa trên gradient, được sử dụng để đánh giá mức độ đóng góp của từng điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán của mô hình. Phương pháp này thực hiện bằng cách so sánh ảnh đầu vào với một ảnh nền ban đầu, sau đó tính toán sự thay đổi gradient theo từng bước từ ảnh nền đến ảnh gốc. Thông qua đó, Integrated Gradients cho biết những vùng ảnh nào có ảnh hưởng mạnh đến quyết định phân loại của mô hình. Đối với ảnh X-quang phổi, kỹ thuật này giúp phân tích rõ hơn mức độ đóng góp của các vùng ảnh vào kết quả dự đoán như COVID-19, Normal, Pneumonia hoặc Tuberculosis.

Occlusion Sensitivity là kỹ thuật giải thích mô hình dựa trên việc che khuất từng vùng nhỏ của ảnh đầu vào và quan sát sự thay đổi trong xác suất dự đoán của mô hình. Nếu một vùng ảnh bị che đi làm xác suất dự đoán giảm mạnh, điều đó cho thấy vùng ảnh đó có vai trò quan trọng trong quyết định của mô hình. Ưu điểm của Occlusion Sensitivity là cách hoạt động dễ hiểu và trực quan, phù hợp để minh họa trong bài toán phân loại ảnh y tế. Đối với ảnh X-quang phổi, kỹ thuật này giúp xác định những khu vực mà mô hình phụ thuộc nhiều khi đưa ra kết quả phân loại.

Việc kết hợp bốn kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion Sensitivity giúp hệ thống có khả năng giải thích kết quả dự đoán dưới nhiều góc nhìn khác nhau. Grad-CAM và Grad-CAM++ tập trung vào trực quan hóa vùng ảnh quan trọng thông qua bản đồ nhiệt dựa trên lớp tích chập cuối của mô hình. Integrated Gradients phân tích mức độ đóng góp của các điểm ảnh hoặc vùng ảnh dựa trên sự thay đổi gradient. Trong khi đó, Occlusion Sensitivity đánh giá tầm quan trọng của từng vùng ảnh bằng cách che khuất lần lượt các khu vực và quan sát sự thay đổi kết quả dự đoán. Nhờ đó, hệ thống không chỉ đưa ra kết quả phân loại ảnh X-quang phổi mà còn giúp người dùng quan sát, kiểm tra và hiểu rõ hơn vùng ảnh mà mô hình quan tâm.

Trong phạm vi đề tài, các kỹ thuật giải thích mô hình được sử dụng nhằm tăng tính minh bạch cho hệ thống AI hỗ trợ chẩn đoán bệnh phổi từ ảnh X-quang. Tuy nhiên, các kết quả trực quan hóa và phân tích từ XAI chỉ mang tính chất hỗ trợ tham khảo, không được sử dụng để thay thế kết luận chuyên môn của bác sĩ. Việc áp dụng Explainable AI giúp đề tài minh họa rõ hơn tiềm năng của trí tuệ nhân tạo trong lĩnh vực y tế, đặc biệt là trong các bài toán yêu cầu sự minh bạch và khả năng giải thích khi đưa ra dự đoán.



Hình 2.2 Các kỹ thuật giải thích

2.2 CÁC BÀI BÁO LIÊN QUAN

Trong những năm gần đây, nhiều nghiên cứu đã tập trung vào việc ứng dụng học sâu trong phân tích ảnh X-quang ngực nhằm hỗ trợ phát hiện và phân loại các bệnh lý về phổi. Các nghiên cứu này cho thấy mô hình học sâu, đặc biệt là mạng nơ-ron tích chập, có khả năng trích xuất đặc trưng hình ảnh tự động và đạt hiệu quả cao trong các bài toán phân loại ảnh y khoa.

Khiem và cộng sự [1] đã nghiên cứu việc ứng dụng học sâu trong chẩn đoán và phân loại bệnh phổi thông qua ảnh X-quang. Công trình này cho thấy tiềm năng của các mô hình deep learning trong việc hỗ trợ nhận dạng các bất thường trên ảnh X-quang ngực. Nghiên cứu có ý nghĩa gần với đề tài hiện tại vì cùng hướng đến bài toán chẩn đoán bệnh phổi từ ảnh X-quang, sử dụng mô hình học sâu làm nền tảng xử lý và phân loại ảnh.

Kiche và cộng sự [2] đề xuất mô hình mạng nơ-ron tích chập để phân loại ảnh X-quang ngực thành các nhóm bệnh như pneumonia, tuberculosis và COVID-19. Nghiên cứu sử dụng các bước tiền xử lý ảnh, huấn luyện mô hình CNN và đánh giá kết quả bằng các chỉ số như accuracy, precision, recall, F1-score và confusion matrix. Đây là một nghiên cứu có liên quan trực tiếp đến đề tài vì cùng khai thác ảnh X-quang ngực để phân loại các bệnh lý hô hấp thường gặp.

Kabir và cộng sự [3] sử dụng phương pháp knowledge distillation để phát hiện COVID-19, pneumonia và tuberculosis từ ảnh X-quang. Mục tiêu của nghiên cứu là xây dựng mô hình có hiệu quả phân loại tốt nhưng vẫn giảm độ phức tạp để phù hợp hơn với môi trường triển khai thực tế. Công trình này cho thấy ngoài độ chính xác, khả năng triển khai và tối ưu mô hình cũng là yếu tố quan trọng trong các hệ thống AI y tế.

Jain và cộng sự [4] thực hiện nghiên cứu phát hiện COVID-19, pneumonia và tuberculosis bằng nhiều kiến trúc học sâu khác nhau, bao gồm các mô hình CNN và mô hình kết hợp. Kết quả nghiên cứu cho thấy các kiến trúc học sâu có khả năng đạt hiệu quả cao trong phân loại bệnh phổi từ ảnh X-quang. Công trình này cũng cho thấy việc so sánh nhiều mô hình là cần thiết để lựa chọn mô hình phù hợp cho bài toán cụ thể.

Bên cạnh các nghiên cứu tập trung vào phân loại, một số công trình gần đây đã nhấn mạnh vai trò của Explainable AI trong ảnh y khoa. Bhandari và cộng sự [5] đã thực hiện phân loại ảnh X-quang thành các nhóm COVID-19, pneumonia, tuberculosis và normal, đồng thời tích hợp các kỹ thuật giải thích mô hình như Grad-CAM, LIME và SHAP. Nghiên cứu này cho thấy việc cung cấp kết quả dự đoán thôi là chưa đủ, mà cần có thêm cơ chế giải thích nhằm hỗ trợ người dùng hiểu được lý do do mô hình đưa ra dự đoán.

Patel và cộng sự [6] đề xuất một framework học chuyển giao có khả năng giải thích cho bài toán phân loại nhiều bệnh phổi trên ảnh X-quang. Nghiên cứu này sử dụng các mô hình học sâu kết hợp với kỹ thuật XAI nhằm cải thiện tính minh bạch của hệ thống. Điều này phù hợp với định hướng của đề tài hiện tại, trong đó mô hình ResNet101 không chỉ được dùng để phân loại ảnh mà còn kết hợp với các kỹ thuật giải thích như Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion Sensitivity.

Sarker và cộng sự [7] xây dựng hệ thống phát hiện bệnh phổi bằng các mô hình học sâu kết hợp dữ liệu ảnh X-quang và Explainable AI. Nghiên cứu cho thấy việc kết hợp giữa mô hình phân loại và kỹ thuật giải thích giúp tăng khả năng quan sát hành vi của mô hình, đặc biệt trong bối cảnh y khoa, nơi người dùng cần hiểu cơ sở của kết quả dự đoán.

Shah và cộng sự [8] trình bày tổng quan về các phương pháp phân loại bệnh phổi có sử dụng Explainable AI. Công trình này nhấn mạnh rằng các mô hình học sâu thường đạt hiệu quả cao nhưng vẫn tồn tại hạn chế về khả năng diễn giải. Vì vậy, XAI đóng vai trò quan trọng trong việc tăng độ tin cậy, tính minh bạch và khả năng ứng dụng của hệ thống AI trong lĩnh vực y tế.

Ifity và cộng sự [9] nghiên cứu phân loại bệnh phổi từ ảnh X-quang bằng deep learning và XAI. Nghiên cứu này tập trung vào việc tạo ra các bản đồ giải thích trực quan nhằm xác định những vùng ảnh có ảnh hưởng đến kết quả phân loại. Tương tự, Naz và cộng sự [10] đề xuất một framework AI có khả năng giải thích để hỗ trợ diễn giải các bệnh phổi từ ảnh X-quang. Các nghiên cứu này đều cho thấy xu hướng hiện nay không chỉ dừng lại ở việc xây dựng mô hình chính xác mà còn cần làm rõ quá trình ra quyết định của mô hình.

Ngoài ra, Chatterjee và cộng sự [12] đã khảo sát một số kỹ thuật diễn giải mô hình cho bài toán phân loại COVID-19 từ ảnh X-quang, trong đó có các phương pháp dựa trên gradient và occlusion. Nghiên cứu này có liên quan đến đề tài vì các kỹ thuật như Integrated Gradients và Occlusion Sensitivity cũng được sử dụng trong hệ thống đề xuất nhằm phân tích mức độ ảnh hưởng của từng vùng ảnh đến kết quả

dự đoán.

Bảng 2.1 Các công trình nghiên cứu liên quan

Tác giả	Năm	Nội Dung	Phương Pháp	Liên quan
Khiem và cộng sự	2026	Chẩn đoán và phân loại bệnh phổi từ ảnh X-quang	Deep Learning	Cùng hướng nghiên cứu bệnh phổi từ ảnh X-quang
Kiche và cộng sự	2024	Phân loại pneumonia, tuberculosis và COVID-19 từ ảnh X-quang	CNN	Có cùng nhóm bệnh và dữ liệu ảnh X-quang
Kabir và cộng sự	2024	Phát hiện COVID-19, pneumonia và tuberculosis từ ảnh X-quang	Knowledge Distillation	Liên quan đến phân loại nhiều bệnh phổi từ ảnh X-quang
Jain và cộng sự	2025	Phát hiện COVID-19, pneumonia và tuberculosis bằng nhiều kiến trúc học sâu	CNN, Mô hình kết hợp	Cung cấp cơ sở so sánh hiệu quả các mô hình deep learning
Bhandari và cộng sự	2022	Phân loại COVID-19, pneumonia, tuberculosis và normal từ ảnh X-quang	Deep Learning, XAI	Gần với đề tài vì vừa phân loại 4 lớp vừa sử dụng XAI
Patel và cộng sự	2024	Phân loại nhiều bệnh phổi từ ảnh X-quang	Transfer Learning, XAI	Liên quan đến học chuyển giao và giải thích mô hình
Ifty và cộng sự	2024	Phân loại bệnh phổi từ ảnh X-quang có giải thích	Deep Learning, XAI	Tương tự hướng kết hợp mô hình phân loại và Explainable AI
Chatterjee và cộng sự	2024	Khảo sát kỹ thuật diễn giải trong phân loại COVID-19 từ ảnh X-quang	Integrated Gradients, Occlusion, Saliency	Liên quan trực tiếp đến các kỹ thuật XAI sử dụng trong đề tài

Từ các công trình đã khảo sát, có thể thấy rằng học sâu đã được ứng dụng rộng rãi trong phân loại bệnh phổi từ ảnh X-quang. Tuy nhiên, nhiều nghiên cứu vẫn chủ yếu tập trung vào độ chính xác của mô hình, trong khi phân giải thích kết quả dự đoán chưa được khai thác đầy đủ hoặc chỉ sử dụng một số kỹ thuật XAI nhất định. Do đó, đề tài này hướng đến việc xây dựng một hệ thống sử dụng ResNet101

để phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis, đồng thời tích hợp nhiều kỹ thuật Explainable AI nhằm hỗ trợ diễn giải kết quả dự đoán.

2.3 TỔNG KẾT CHƯƠNG

Chương 2 đã trình bày cơ sở lý thuyết và các nghiên cứu liên quan đến đề tài xây dựng hệ thống hỗ trợ chẩn đoán bệnh phổi từ ảnh X-quang bằng mô hình học sâu. Nội dung chương đã giới thiệu tổng quan về ảnh X-quang phổi, bài toán phân loại bệnh phổi, mô hình mạng nơ-ron tích chập, mô hình ResNet101 và các kỹ thuật Explainable AI được sử dụng trong đề tài.

Bên cạnh đó, chương cũng tổng hợp một số công trình nghiên cứu liên quan đến phân loại bệnh phổi từ ảnh X-quang, đặc biệt là các nghiên cứu về COVID-19, Pneumonia, Tuberculosis và Normal. Qua các nghiên cứu đã khảo sát, có thể thấy rằng deep learning đã đạt được nhiều kết quả tích cực trong phân tích ảnh y khoa. Tuy nhiên, nhiều mô hình vẫn còn hạn chế về khả năng giải thích kết quả dự đoán.

Từ những cơ sở trên, đề tài lựa chọn mô hình ResNet101 để thực hiện phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Đồng thời, các kỹ thuật Explainable AI như Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion Sensitivity được tích hợp nhằm hỗ trợ trực quan hóa vùng ảnh ảnh hưởng đến kết quả dự đoán. Đây là nền tảng quan trọng cho việc xây dựng phương pháp nghiên cứu và thiết kế hệ thống trong các chương tiếp theo.

CHƯƠNG 3

PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1 PHÂN TÍCH YÊU CẦU

3.1.1 Yêu cầu chức năng

Yêu cầu chức năng mô tả các chức năng mà hệ thống cần thực hiện nhằm đáp ứng mục tiêu hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực bằng mô hình học sâu ResNet101. Các chức năng này được xác định dựa trên quy trình tiếp nhận ảnh, tiền xử lý dữ liệu, dự đoán bệnh, hiển thị kết quả và giải thích quyết định của mô hình.

Trước hết, hệ thống cần có chức năng tiếp nhận ảnh X-quang ngực từ người dùng thông qua giao diện web. Người dùng có thể tải lên ảnh X-quang ở các định dạng ảnh phổ biến như JPG, JPEG hoặc PNG. Sau khi ảnh được tải lên, hệ thống thực hiện kiểm tra dữ liệu đầu vào nhằm đảm bảo ảnh đúng định dạng, có thể đọc được và phù hợp với yêu cầu xử lý của mô hình.

Sau khi tiếp nhận ảnh, hệ thống tiến hành tiền xử lý ảnh trước khi đưa vào mô hình ResNet101. Các bước tiền xử lý bao gồm thay đổi kích thước ảnh về chuẩn đầu vào của mô hình, chuẩn hóa giá trị điểm ảnh và chuyển đổi ảnh sang dạng dữ liệu phù hợp để mô hình có thể phân tích. Quá trình này giúp đảm bảo dữ liệu đầu vào có cấu trúc thống nhất, hạn chế sai lệch trong quá trình dự đoán.

Tiếp theo, hệ thống thực hiện chức năng phân loại bệnh phổi trên ảnh X-quang ngực bằng mô hình ResNet101 đã được huấn luyện trước. Mô hình có nhiệm vụ trích xuất đặc trưng từ ảnh X-quang và đưa ra kết quả dự đoán thuộc một trong bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Đây là bài toán phân loại đa lớp, trong đó mỗi ảnh đầu vào sẽ được mô hình dự đoán thuộc về lớp có xác suất cao nhất.

Bên cạnh việc đưa ra nhãn dự đoán, hệ thống cần hiển thị xác suất dự đoán của từng lớp bệnh. Chức năng này giúp người dùng quan sát mức độ tin cậy của mô hình đối với từng nhóm bệnh, thay vì chỉ nhận được một kết quả phân loại duy nhất. Kết quả hiển thị bao gồm ảnh X-quang đầu vào, tên lớp được dự đoán, xác suất tương ứng và bảng xác suất của các lớp còn lại.

Ngoài chức năng dự đoán bệnh, hệ thống còn tích hợp các kỹ thuật Explainable AI nhằm giải thích kết quả phân loại của mô hình. Các kỹ thuật được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Grad-CAM và Grad-CAM++ tạo bản đồ nhiệt thể hiện vùng ảnh mà mô hình tập trung khi đưa ra dự đoán. Integrated Gradients giúp biểu diễn mức độ đóng góp của các vùng ảnh đối với kết quả phân loại. Occlusion kiểm tra tầm quan trọng của từng vùng ảnh bằng cách che khuất một phần ảnh và quan sát sự thay đổi trong kết quả

dự đoán.

Hệ thống cần hỗ trợ hiển thị đồng thời ảnh X-quang gốc và các kết quả giải thích mô hình. Cụ thể, giao diện cần trình bày ảnh gốc, ảnh Grad-CAM, ảnh Grad-CAM++, ảnh Integrated Gradients và ảnh Occlusion để người dùng có thể so sánh trực quan. Nhờ đó, người dùng không chỉ biết mô hình dự đoán bệnh gì mà còn quan sát được những khu vực ảnh có ảnh hưởng đến quyết định của mô hình.

Ngoài ra, hệ thống cần có chức năng hiển thị kết quả đánh giá mô hình dựa trên các chỉ số thực nghiệm. Trong quá trình kiểm thử, mô hình ResNet101 đạt Accuracy là 0.94, Precision là 0.96, Recall là 0.95 và F1-score là 0.95. Các chỉ số này giúp đánh giá hiệu quả phân loại tổng thể của mô hình và phản ánh khả năng nhận diện bệnh phổi trên tập dữ liệu kiểm thử.

Hệ thống cũng có thể hỗ trợ xuất báo cáo kết quả phân tích dưới dạng PDF nhằm phục vụ cho việc lưu trữ và theo dõi. Báo cáo có thể bao gồm ảnh X-quang đầu vào, kết quả dự đoán, xác suất dự đoán, các hình ảnh giải thích mô hình và thời gian phân tích. Chức năng này giúp người dùng dễ dàng lưu lại kết quả để phục vụ mục đích học tập, nghiên cứu hoặc trình bày báo cáo.

Như vậy, các chức năng chính của hệ thống bao gồm: tiếp nhận ảnh X-quang ngực, kiểm tra dữ liệu đầu vào, tiền xử lý ảnh, phân loại bệnh phổi bằng mô hình ResNet101, hiển thị xác suất dự đoán, giải thích kết quả bằng Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion, hiển thị kết quả đánh giá mô hình và hỗ trợ xuất báo cáo phân tích.

3.1.2 Yêu cầu phi chức năng

Bên cạnh các yêu cầu chức năng, hệ thống cần đáp ứng các yêu cầu phi chức năng nhằm đảm bảo tính ổn định, hiệu quả và khả năng sử dụng trong quá trình nghiên cứu. Các yêu cầu này liên quan đến hiệu năng xử lý, độ chính xác của mô hình, khả năng giải thích, giao diện người dùng, khả năng mở rộng và tính an toàn của dữ liệu.

Về hiệu năng, hệ thống cần đảm bảo quá trình xử lý ảnh diễn ra trong thời gian phù hợp. Sau khi người dùng tải ảnh X-quang lên, hệ thống cần thực hiện tiền xử lý, dự đoán và hiển thị kết quả trong thời gian ngắn. Quá trình xử lý cần ổn định, hạn chế lỗi khi đọc ảnh, xử lý ảnh hoặc hiển thị kết quả phân tích.

Về độ chính xác, hệ thống cần đảm bảo mô hình ResNet101 có khả năng phân loại ảnh X-quang phổi với độ tin cậy phù hợp. Kết quả thực nghiệm cho thấy mô hình đạt Accuracy 0.94, Precision 0.96, Recall 0.95 và F1-score 0.95. Trong đó, F1-score là chỉ số quan trọng vì thể hiện sự cân bằng giữa Precision và Recall, đặc biệt phù hợp với bài toán phân loại bệnh lý y tế.

Về khả năng giải thích, hệ thống cần cung cấp các kết quả trực quan giúp

người dùng hiểu được cơ sở mà mô hình sử dụng khi đưa ra dự đoán. Các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion cần được trình bày rõ ràng, dễ quan sát và có khả năng hỗ trợ đối chiếu với ảnh X-quang gốc. Đây là yêu cầu quan trọng nhằm giảm tính “hộp đen” của mô hình học sâu trong lĩnh vực y tế

Về giao diện người dùng, hệ thống cần được thiết kế đơn giản, trực quan và dễ sử dụng. Người dùng có thể dễ dàng tải ảnh X-quang, xem ảnh đầu vào, quan sát kết quả dự đoán, theo dõi xác suất của từng lớp bệnh và xem các hình ảnh giải thích mô hình. Giao diện cần trình bày thông tin rõ ràng, tránh gây rối mắt và phù hợp với mục đích hỗ trợ học tập, nghiên cứu và trình bày khóa luận.

Về tính ổn định, hệ thống cần xử lý được các trường hợp đầu vào không hợp lệ như ảnh sai định dạng, ảnh bị lỗi hoặc ảnh không thể đọc được. Khi xảy ra lỗi, hệ thống cần hiển thị thông báo phù hợp để người dùng biết nguyên nhân và thực hiện lại thao tác. Điều này giúp cải thiện trải nghiệm sử dụng và hạn chế gián đoạn trong quá trình vận hành.


Về khả năng mở rộng và bảo trì, hệ thống cần được xây dựng theo hướng dễ nâng cấp trong tương lai. Kiến trúc hệ thống cần hỗ trợ việc thay đổi mô hình học sâu, bổ sung thêm dữ liệu huấn luyện, mở rộng số lượng lớp bệnh hoặc tích hợp thêm các kỹ thuật giải thích mô hình khác mà không ảnh hưởng lớn đến các thành phần hiện có.

Về tính an toàn và quản lý dữ liệu, hệ thống cần đảm bảo ảnh X-quang được sử dụng đúng mục đích trong phạm vi nghiên cứu. Dữ liệu ảnh đầu vào cần được quản lý hợp lý, tránh sử dụng sai mục đích hoặc công bố thông tin không phù hợp. Trong phạm vi đề tài, hệ thống chỉ đóng vai trò hỗ trợ tham khảo và minh họa khả năng ứng dụng AI trong phân tích ảnh X-quang phổi, không thay thế kết luận chẩn đoán của bác sĩ.

Nhìn chung, các yêu cầu phi chức năng giúp hệ thống không chỉ đáp ứng mục tiêu phân loại bệnh phổi từ ảnh X-quang bằng ResNet101 mà còn đảm bảo khả năng vận hành ổn định, dễ sử dụng, có khả năng giải thích và có thể mở rộng trong các nghiên cứu tiếp theo.

3.2 KIẾN TRÚC TỔNG THỂ HỆ THỐNG

Mô hình kiến trúc tổng quan của hệ thống được xây dựng nhằm mô tả toàn bộ quy trình hoạt động của hệ thống hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang.



Hình 3.1 Mô hình tổng quan của hệ thống

Dựa trên Hình 3.1, hệ thống được chia thành hai mức xử lý chính gồm: mức xây dựng và huấn luyện mô hình, mức suy luận và giải thích kết quả. Việc chia hệ thống thành hai mức giúp làm rõ sự khác biệt giữa quá trình huấn luyện mô hình trên bộ dữ liệu có sẵn và quá trình sử dụng mô hình đã huấn luyện để phân tích ảnh X-quang mới do người dùng cung cấp.

Mức thứ nhất là giai đoạn xây dựng và huấn luyện mô hình. Đây là giai đoạn nền tảng của hệ thống, có nhiệm vụ tạo ra mô hình học sâu có khả năng phân loại ảnh X-quang phổi. Dữ liệu đầu vào của giai đoạn này là bộ dữ liệu ảnh X-quang phổi gồm bốn lớp: COVID-19, Normal, Pneumonia và Tuberculosis. Trong đó, lớp COVID-19 biểu diễn các ảnh X-quang có dấu hiệu liên quan đến bệnh COVID-19, lớp Normal biểu diễn ảnh phổi bình thường, lớp Pneumonia biểu diễn ảnh viêm phổi và lớp Tuberculosis biểu diễn ảnh lao phổi. Các lớp dữ liệu này được sử dụng để mô hình học cách nhận diện sự khác biệt giữa ảnh bình thường và ảnh có dấu hiệu bệnh lý.

Sau khi chuẩn bị bộ dữ liệu, hệ thống thực hiện bước tiền xử lý ảnh. Đây là bước quan trọng nhằm đảm bảo dữ liệu đầu vào có định dạng thống nhất trước khi đưa vào mô hình. Trong sơ đồ, bước tiền xử lý bao gồm Resize 224x224, chuẩn hóa và Data Augmentation. Resize 224x224 giúp đưa toàn bộ ảnh về cùng kích thước phù hợp với đầu vào của mô hình ResNet101. Chuẩn hóa dữ liệu giúp đưa giá trị điểm ảnh về miền giá trị phù hợp, hỗ trợ mô hình học ổn định hơn trong quá trình huấn luyện. Data Augmentation được sử dụng để tạo thêm các biến thể ảnh từ dữ liệu gốc thông qua một số phép biến đổi phù hợp, giúp tăng tính đa dạng của dữ liệu và hạn chế hiện tượng quá khớp.

Sau bước tiền xử lý, dữ liệu được đưa vào mô hình ResNet101 pretrained để huấn luyện. ResNet101 là một mô hình mạng nơ-ron tích chập sâu, có khả năng trích xuất đặc trưng hình ảnh ở nhiều mức độ khác nhau. Các tầng đầu của mô hình thường học các đặc trưng đơn giản như cạnh, đường biên và vùng sáng tối, trong khi các tầng sâu hơn có khả năng học các đặc trưng phức tạp hơn liên quan đến cấu trúc phổi và dấu hiệu bất thường trên ảnh X-quang. Việc sử dụng mô hình pretrained giúp tận dụng các đặc trưng đã được học trước đó từ tập dữ liệu lớn, từ đó rút ngắn thời gian huấn luyện và cải thiện hiệu quả phân loại.

Trong quá trình huấn luyện, mô hình ResNet101 học cách ánh xạ ảnh X-quang đầu vào đến một trong bốn lớp bệnh đã xác định. Mỗi ảnh sau khi đi qua mô hình sẽ được biểu diễn dưới dạng các đặc trưng, sau đó được đưa qua các lớp phân loại để tạo ra xác suất tương ứng với từng lớp. Quá trình huấn luyện được thực hiện nhiều lần qua các epoch nhằm điều chỉnh trọng số của mô hình sao cho sai số giữa kết quả dự đoán và nhãn thực tế được giảm xuống. Sau khi quá trình huấn luyện hoàn tất, mô hình đạt kết quả tốt nhất sẽ được lưu lại dưới dạng mô hình đã huấn luyện. Đây là thành phần được sử dụng trực tiếp ở giai đoạn suy luận.

Mức thứ hai là giai đoạn suy luận và giải thích. Đây là giai đoạn mô phỏng quá trình người dùng sử dụng hệ thống để phân tích ảnh X-quang mới. Đầu tiên, người dùng cung cấp ảnh X-quang đầu vào cần chẩn đoán. Ảnh này có thể là ảnh thuộc một trong bốn nhóm: COVID-19, Normal, Pneumonia hoặc Tuberculosis. Sau khi ảnh được đưa vào hệ thống, ảnh tiếp tục trải qua bước tiền xử lý tương tự như trong giai đoạn huấn luyện. Việc sử dụng cùng quy trình tiền xử lý giúp đảm bảo ảnh đầu vào có cùng định dạng với dữ liệu mà mô hình đã học trước đó.

Sau khi tiền xử lý, ảnh được đưa vào mô hình ResNet101 đã huấn luyện. Trong sơ đồ, mũi tên từ khối “Mô hình đã huấn luyện” xuống khối “Tiền xử lý + mô hình ResNet101” thể hiện rằng mô hình được tạo ra ở mức thứ nhất sẽ được sử dụng lại trong mức thứ hai. Điều này cho thấy hệ thống không huấn luyện lại mô hình mỗi khi có ảnh mới, mà chỉ nạp mô hình đã huấn luyện để thực hiện dự đoán. Cách tổ chức này giúp quá trình suy luận diễn ra nhanh hơn và phù hợp với mục tiêu xây dựng một hệ thống hỗ trợ phân tích ảnh.

Khi ảnh đi qua mô hình ResNet101, hệ thống tạo ra kết quả dự đoán dưới dạng xác suất cho bốn lớp bệnh. Mỗi lớp sẽ có một giá trị xác suất thể hiện mức độ tin cậy của mô hình đối với lớp đó. Lớp có xác suất cao nhất được chọn làm nhãn dự đoán chính của ảnh đầu vào. Ví dụ, nếu lớp Pneumonia có xác suất cao nhất, hệ thống sẽ đưa ra kết quả dự đoán ảnh thuộc nhóm viêm phổi. Tuy nhiên, hệ thống vẫn cần hiển thị xác suất của các lớp còn lại để người dùng có thể quan sát toàn bộ kết quả phân tích, thay vì chỉ xem một nhãn kết luận duy nhất.

Sau khi có kết quả dự đoán, hệ thống tiếp tục thực hiện bước giải thích XAI.

Đây là một thành phần quan trọng trong mô hình tổng quan vì các mô hình học sâu thường khó giải thích trực tiếp. Nếu hệ thống chỉ đưa ra kết quả “Pneumonia” hoặc “COVID-19” mà không cho biết mô hình dựa vào đâu để đưa ra dự đoán, người dùng sẽ khó kiểm tra tính hợp lý của kết quả. Vì vậy, các kỹ thuật Explainable AI được tích hợp nhằm trực quan hóa hoặc phân tích những vùng ảnh có ảnh hưởng đến quyết định của mô hình.

Trong hệ thống, các kỹ thuật giải thích được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Grad-CAM tạo bản đồ nhiệt dựa trên thông tin gradient tại các lớp tích chập cuối của mô hình, giúp xác định vùng ảnh có ảnh hưởng lớn đến kết quả dự đoán. Grad-CAM++ là phiên bản cải tiến của Grad-CAM, có khả năng làm nổi bật vùng ảnh quan trọng chi tiết hơn trong một số trường hợp. Integrated Gradients đánh giá mức độ đóng góp của từng điểm ảnh hoặc từng vùng ảnh bằng cách phân tích sự thay đổi từ ảnh nền đến ảnh đầu vào. Occlusion hoạt động bằng cách che khuất từng vùng nhỏ trên ảnh và quan sát sự thay đổi của xác suất dự đoán, từ đó xác định vùng ảnh nào có vai trò quan trọng đối với mô hình.

Kết quả đầu ra cuối cùng của hệ thống bao gồm ảnh X-quang gốc, nhãn bệnh được dự đoán, xác suất dự đoán và bản đồ nhiệt giải thích. Ảnh gốc giúp người dùng đối chiếu trực tiếp với kết quả phân tích. Nhãn bệnh cho biết mô hình dự đoán ảnh thuộc lớp nào. Xác suất dự đoán giúp đánh giá mức độ tin cậy của mô hình đối với từng lớp bệnh. Bản đồ nhiệt và các hình ảnh giải thích giúp người dùng quan sát vùng ảnh mà mô hình tập trung khi đưa ra quyết định. Nhờ đó, hệ thống không chỉ thực hiện phân loại ảnh X-quang mà còn cung cấp thêm thông tin trực quan để hỗ trợ quá trình đánh giá.

Nhìn chung, mô hình tổng quan của hệ thống thể hiện quy trình hoạt động theo hướng đầy đủ và rõ ràng. Mức thứ nhất tập trung vào việc xây dựng mô hình ResNet101 thông qua bộ dữ liệu ảnh X-quang phổi đã được gán nhãn. Mức thứ hai sử dụng mô hình đã huấn luyện để phân tích ảnh X-quang mới, đưa ra kết quả dự đoán và giải thích kết quả bằng các kỹ thuật XAI. Cách thiết kế này giúp hệ thống vừa có khả năng phân loại bệnh phổi, vừa có khả năng minh họa vùng ảnh quan trọng trong quá trình dự đoán. Hệ thống được xây dựng với vai trò là công cụ hỗ trợ tham khảo trong học tập, nghiên cứu và phân tích ảnh X-quang, không thay thế kết luận chuyên môn của bác sĩ.

3.3 PHÂN TÍCH DỮ LIỆU VÀ QUY TRÌNH XỬ LÝ

3.3.1 Bộ dữ liệu sử dụng

Dữ liệu sử dụng trong nghiên cứu là bộ ảnh X-quang phổi được xây dựng nhằm phục vụ bài toán phân loại bệnh lý phổi bằng mô hình học sâu. Bộ dữ liệu bao

gồm bốn lớp chính: COVID-19, Normal, Pneumonia và Tuberculosis. Trong đó, lớp COVID-19 biểu diễn các ảnh X-quang phổi có dấu hiệu liên quan đến bệnh COVID-19, lớp Normal biểu diễn ảnh phổi bình thường, lớp Pneumonia biểu diễn ảnh viêm phổi và lớp Tuberculosis biểu diễn ảnh lao phổi.

Khác với các bài toán phân đoạn ảnh, bộ dữ liệu trong đề tài này được sử dụng cho bài toán phân loại ảnh. Vì vậy, mỗi ảnh X-quang đầu vào được gán một nhãn tương ứng với một trong bốn lớp bệnh đã xác định. Mô hình không tạo ra mặt nạ phân đoạn mà thực hiện dự đoán xác suất cho từng lớp bệnh. Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán cuối cùng của hệ thống.

Bộ dữ liệu được tổ chức theo cấu trúc thư mục, trong đó mỗi thư mục con tương ứng với một lớp ảnh cụ thể. Cách tổ chức này giúp quá trình đọc dữ liệu, tiền xử lý ảnh và huấn luyện mô hình được thực hiện thuận lợi hơn. Dữ liệu sau đó được chia thành ba tập gồm tập huấn luyện, tập kiểm định và tập kiểm thử. Tập huấn luyện được sử dụng để mô hình học các đặc trưng từ ảnh X-quang. Tập kiểm định được sử dụng để theo dõi quá trình huấn luyện, điều chỉnh mô hình và hạn chế hiện tượng quá khớp. Tập kiểm thử được sử dụng để đánh giá hiệu quả cuối cùng của mô hình trên các ảnh chưa từng xuất hiện trong quá trình huấn luyện.

Các ảnh X-quang trong bộ dữ liệu có thể khác nhau về kích thước, độ sáng, độ tương phản, góc chụp và chất lượng hình ảnh. Đây là đặc điểm thường gặp trong dữ liệu ảnh y tế do ảnh có thể được thu thập từ nhiều nguồn hoặc nhiều thiết bị khác nhau. Sự khác biệt này làm cho quá trình phân loại trở nên phức tạp hơn, nhưng đồng thời cũng giúp mô hình có cơ hội học được nhiều đặc trưng đa dạng hơn của ảnh X-quang phổi.

Trong quá trình xây dựng mô hình, các ảnh được tiền xử lý trước khi đưa vào ResNet101. Các bước tiền xử lý bao gồm thay đổi kích thước ảnh về 224x224 pixel, chuẩn hóa giá trị điểm ảnh và tăng cường dữ liệu. Việc thay đổi kích thước giúp ảnh phù hợp với đầu vào của mô hình ResNet101. Chuẩn hóa dữ liệu giúp mô hình học ổn định hơn trong quá trình huấn luyện. Tăng cường dữ liệu được áp dụng nhằm tạo thêm các biến thể ảnh từ dữ liệu ban đầu, góp phần cải thiện khả năng tổng quát hóa và hạn chế tình trạng mô hình chỉ học thuộc dữ liệu huấn luyện.

Bộ dữ liệu đóng vai trò quan trọng trong toàn bộ quá trình xây dựng hệ thống. Chất lượng và cách phân chia dữ liệu ảnh hưởng trực tiếp đến khả năng học đặc trưng, độ chính xác và độ tin cậy của mô hình ResNet101. Nếu dữ liệu không cân bằng giữa các lớp, mô hình có thể có xu hướng dự đoán tốt hơn ở những lớp có nhiều ảnh và kém hơn ở những lớp có ít ảnh. Vì vậy, trong quá trình đánh giá, đề tài không chỉ sử dụng Accuracy mà còn kết hợp các chỉ số Precision, Recall, F1-score và Confusion Matrix để đánh giá chi tiết hơn hiệu quả phân loại của mô hình trên từng lớp bệnh.

Trong phạm vi đề tài, bộ dữ liệu được sử dụng nhằm phục vụ mục tiêu nghiên cứu, huấn luyện và đánh giá mô hình AI hỗ trợ chẩn đoán bệnh phổi từ ảnh X-quang. Kết quả dự đoán của mô hình chỉ mang tính chất tham khảo, hỗ trợ quá trình học tập và nghiên cứu, không thay thế kết luận chuyên môn của bác sĩ.

Bảng 3.1 Thống kê số lượng ảnh trong bộ dữ liệu

Tập dữ liệu	Số lượng ảnh
Training	6326
Validation	38
Test	771
Tổng	7135

3.3.2 Quy trình tiền xử lý dữ liệu

Trước khi đưa dữ liệu vào quá trình huấn luyện mô hình ResNet101, các ảnh X-quang phổi cần được thực hiện một số bước tiền xử lý nhằm đảm bảo dữ liệu đầu vào có định dạng thống nhất và phù hợp với yêu cầu của mô hình học sâu. Do ảnh X-quang có thể được thu thập từ nhiều nguồn khác nhau nên thường tồn tại sự khác biệt về kích thước, độ sáng, độ tương phản, chất lượng ảnh và cách biểu diễn dữ liệu. Vì vậy, tiền xử lý dữ liệu là bước quan trọng giúp giảm sự sai lệch giữa các ảnh, hỗ trợ mô hình học ổn định hơn và nâng cao hiệu quả phân loại.

Quy trình tiền xử lý dữ liệu trong đề tài được thực hiện theo các bước chính gồm: đọc ảnh đầu vào, thay đổi kích thước ảnh, chuẩn hóa giá trị điểm ảnh và tăng cường dữ liệu. Các bước này được áp dụng trước khi ảnh được đưa vào mô hình ResNet101 để huấn luyện hoặc dự đoán.

Bước đầu tiên là đọc ảnh X-quang từ bộ dữ liệu. Mỗi ảnh trong bộ dữ liệu thuộc một trong bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Ảnh được đọc từ các thư mục tương ứng với từng nhãn bệnh, sau đó được chuyển đổi về định dạng phù hợp để mô hình có thể xử lý. Việc tổ chức dữ liệu theo từng lớp giúp quá trình huấn luyện mô hình thuận tiện hơn, đồng thời giúp hệ thống xác định đúng nhãn của từng ảnh trong quá trình học.

Sau khi đọc ảnh, hệ thống thực hiện thay đổi kích thước ảnh về 224×224 pixel. Đây là kích thước đầu vào phổ biến được sử dụng cho các mô hình mạng nơ-ron tích chập như ResNet101. Việc thay đổi kích thước ảnh giúp toàn bộ dữ liệu có cùng chiều rộng và chiều cao, từ đó đảm bảo mô hình nhận được đầu vào có cấu trúc thống nhất. Nếu không chuẩn hóa kích thước, các ảnh có kích thước khác nhau sẽ gây khó khăn trong quá trình huấn luyện và làm giảm tính ổn định của mô hình.

Tiếp theo, ảnh được chuẩn hóa giá trị điểm ảnh trước khi đưa vào mô hình. Thông thường, các giá trị điểm ảnh ban đầu nằm trong khoảng từ 0 đến 255. Quá trình chuẩn hóa giúp đưa các giá trị này về miền giá trị phù hợp hơn, chẳng hạn từ 0 đến 1, nhằm hỗ trợ mô hình học nhanh và ổn định hơn. Việc chuẩn hóa dữ liệu


còn giúp hạn chế sự chênh lệch lớn giữa các giá trị đầu vào, góp phần cải thiện quá trình tối ưu trọng số trong khi huấn luyện.

Bên cạnh việc thay đổi kích thước và chuẩn hóa ảnh, kỹ thuật Data Augmentation được áp dụng trong giai đoạn huấn luyện nhằm tăng tính đa dạng cho dữ liệu. Data Augmentation tạo ra các biến thể mới từ ảnh gốc thông qua một số phép biến đổi phù hợp như xoay nhẹ, dịch chuyển, phóng to, thu nhỏ hoặc thay đổi độ sáng ở mức hợp lý. Các phép biến đổi này giúp mô hình tiếp xúc với nhiều dạng ảnh khác nhau, từ đó hạn chế hiện tượng quá khớp và cải thiện khả năng tổng quát hóa khi dự đoán trên dữ liệu mới.

Trong quá trình áp dụng Data Augmentation, các phép biến đổi cần được lựa chọn cẩn thận để không làm thay đổi bản chất y khoa của ảnh X-quang. Đối với ảnh y tế, việc biến đổi ảnh quá mạnh có thể làm sai lệch đặc trưng bệnh lý hoặc tạo ra dữ liệu không phù hợp với thực tế. Vì vậy, các phép tăng cường dữ liệu trong đề tài chỉ được áp dụng ở mức vừa phải, nhằm giữ lại cấu trúc chính của ảnh phổi và các dấu hiệu quan trọng phục vụ cho quá trình phân loại.

Sau khi hoàn thành các bước tiền xử lý, dữ liệu ảnh đã sẵn sàng để đưa vào mô hình ResNet101. Trong giai đoạn huấn luyện, các ảnh đã xử lý được sử dụng để mô hình học đặc trưng của từng lớp bệnh. Trong giai đoạn suy luận, ảnh X-quang do người dùng cung cấp cũng được xử lý theo cùng quy trình trước khi đưa vào mô hình để dự đoán. Việc sử dụng thống nhất một quy trình tiền xử lý giữa huấn luyện và suy luận giúp đảm bảo mô hình nhận được dữ liệu có định dạng tương tự với dữ liệu đã học, từ đó nâng cao độ tin cậy của kết quả dự đoán.

Tóm lại, quy trình tiền xử lý dữ liệu trong đề tài bao gồm các bước chính: đọc ảnh X-quang đầu vào, thay đổi kích thước ảnh về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và tăng cường dữ liệu trong quá trình huấn luyện. Quy trình này giúp dữ liệu đầu vào phù hợp với mô hình ResNet101, hỗ trợ mô hình học đặc trưng hiệu quả hơn và góp phần nâng cao khả năng phân loại ảnh X-quang phổi thành bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis.



Hình 3.2 Quy trình tiền xử lý dữ liệu

3.4 THIẾT KẾ MÔ HÌNH RESNET101

3.4.1 Kiến trúc mô hình ResNet101

Mô hình ResNet101 được sử dụng trong đề tài nhằm thực hiện bài toán phân loại bệnh phổi từ ảnh X-quang ngực. Đây là một kiến trúc mạng nơ-ron tích chập sâu, có khả năng trích xuất các đặc trưng quan trọng từ ảnh đầu vào và hỗ trợ phân loại ảnh vào các nhóm bệnh đã xác định. Trong phạm vi nghiên cứu, mô hình ResNet101 được xây dựng để phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis.

Đầu vào của mô hình là ảnh X-quang phổi đã được tiền xử lý. Trước khi đưa vào mô hình, ảnh được thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và chuyển đổi về định dạng phù hợp với yêu cầu đầu vào của ResNet101. Việc chuẩn hóa dữ liệu giúp các ảnh có cấu trúc thống nhất, hỗ trợ mô hình học ổn định hơn trong quá trình huấn luyện.

Sau khi tiền xử lý, ảnh được đưa vào khối ResNet101 để trích xuất đặc trưng. Thành phần này gồm nhiều tầng tích chập sâu, có nhiệm vụ học các đặc trưng hình ảnh từ mức cơ bản đến mức phức tạp. Các tầng đầu của mô hình thường học những đặc trưng như cạnh, vùng sáng tối và đường biên. Các tầng sâu hơn có khả năng học các đặc trưng liên quan đến cấu trúc phổi, vùng mờ, dấu hiệu viêm nhiễm hoặc các bất thường có thể xuất hiện trên ảnh X-quang.

Một đặc điểm quan trọng của ResNet101 là cơ chế kết nối tắt, hay còn gọi là residual connection. Cơ chế này giúp thông tin được truyền qua các tầng sâu hiệu

quả hơn, đồng thời hạn chế hiện tượng suy giảm gradient trong quá trình huấn luyện. Nhờ đó, mô hình có thể học được các đặc trưng phức tạp của ảnh X-quang phổi mà vẫn duy trì khả năng huấn luyện ổn định.

Sau khi đi qua các tầng trích xuất đặc trưng, dữ liệu đặc trưng được đưa vào lớp Global Average Pooling. Lớp này có nhiệm vụ rút gọn bản đồ đặc trưng thành một vector đại diện, giúp giảm số lượng tham số và hạn chế hiện tượng quá khớp. Vector đặc trưng sau đó được đưa vào lớp Fully Connected để học mối quan hệ giữa các đặc trưng ảnh và các lớp bệnh cần phân loại.


Ở tầng đầu ra, mô hình sử dụng lớp Softmax để tạo ra xác suất dự đoán cho bốn lớp: COVID-19, Normal, Pneumonia và Tuberculosis. Mỗi lớp sẽ có một giá trị xác suất riêng, thể hiện mức độ tin cậy của mô hình đối với lớp đó. Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán cuối cùng của hệ thống.

Trong đề tài, ResNet101 được sử dụng theo hướng học chuyển giao. Mô hình tận dụng trọng số đã được huấn luyện trước, sau đó được tinh chỉnh trên bộ dữ liệu ảnh X-quang phổi của đề tài. Cách tiếp cận này giúp mô hình khai thác các đặc trưng hình ảnh đã học từ trước, đồng thời thích nghi với bài toán phân loại bệnh phổi trên ảnh X-quang.

Bên cạnh kết quả phân loại, mô hình còn được kết hợp với các kỹ thuật giải thích mô hình nhằm tăng tính trực quan và minh bạch cho hệ thống. Các kỹ thuật như Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion được sử dụng để thể hiện những vùng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình. Nhờ đó, hệ thống không chỉ đưa ra nhãn bệnh và xác suất dự đoán, mà còn giúp người dùng quan sát được vùng ảnh mà mô hình tập trung khi phân loại.

Đầu ra cuối cùng của hệ thống bao gồm ảnh X-quang gốc, nhãn bệnh được dự đoán, xác suất của từng lớp và hình ảnh giải thích mô hình. Các kết quả này giúp người dùng theo dõi quá trình phân tích ảnh một cách trực quan hơn, đồng thời hỗ trợ việc đánh giá kết quả dự đoán trong phạm vi học tập và nghiên cứu.

Nhìn chung, kiến trúc mô hình ResNet101 trong đề tài được thiết kế theo luồng xử lý gồm: ảnh X-quang đầu vào, tiền xử lý ảnh, khối ResNet101, trích xuất đặc trưng, gộp trung bình toàn cục, lớp kết nối đầy đủ, phân loại Softmax và kết quả dự đoán. Kiến trúc này phù hợp với mục tiêu xây dựng hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực.



Hình 3.3 Kiến trúc mô hình ResNet101

3.4.2 Đầu vào và đầu ra của mô hình

Mô hình ResNet101 trong đề tài được xây dựng nhằm thực hiện bài toán phân loại bệnh phổi từ ảnh X-quang ngực. Trong quá trình hoạt động, mô hình tiếp nhận dữ liệu đầu vào là ảnh X-quang đã được tiền xử lý và tạo ra đầu ra dưới dạng xác suất dự đoán tương ứng với từng lớp bệnh.

Đầu vào của mô hình là ảnh X-quang ngực thuộc một trong bốn nhóm dữ liệu gồm COVID-19, Normal, Pneumonia và Tuberculosis. Trước khi đưa vào mô hình, ảnh được thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và chuyển đổi thành tensor phù hợp với định dạng xử lý của mô hình học sâu. Dữ liệu đầu vào sau khi xử lý có dạng kích thước $224 \times 224 \times 3$, trong đó 224×224 là kích thước không gian của ảnh và 3 là số kênh màu.


Sau khi ảnh đầu vào được đưa vào mô hình, ResNet101 thực hiện quá trình trích xuất đặc trưng thông qua các tầng tích chập và các khối residual. Những đặc trưng này đại diện cho các thông tin quan trọng trên ảnh X-quang như vùng sáng tối, cấu trúc phổi, vùng mờ hoặc các dấu hiệu bất thường có liên quan đến bệnh lý. Các đặc trưng sau đó được đưa qua các lớp phân loại để tạo ra kết quả dự đoán.

Đầu ra chính của mô hình là một vector xác suất có kích thước 1×4 , tương ứng với bốn lớp bệnh gồm COVID-19, Normal, Pneumonia và Tuberculosis. Mỗi phần tử trong vector biểu diễn xác suất ảnh đầu vào thuộc về một lớp bệnh cụ thể. Lớp có xác suất cao nhất sẽ được chọn làm nhãn dự đoán cuối cùng của mô hình.

Ví dụ, nếu xác suất của lớp Pneumonia cao hơn các lớp còn lại, hệ thống sẽ dự đoán ảnh X-quang thuộc nhóm viêm phổi. Tuy nhiên, hệ thống vẫn hiển thị xác suất của cả bốn lớp để người dùng có thể quan sát mức độ tin cậy của mô hình đối với từng kết quả. Việc hiển thị đầy đủ xác suất giúp kết quả phân loại trở nên rõ ràng và trực quan hơn.

Ngoài nhãn bệnh và xác suất dự đoán, kết quả đầu ra còn có thể được sử dụng làm cơ sở cho các kỹ thuật giải thích mô hình như Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Các kỹ thuật này giúp trực quan hóa vùng ảnh có ảnh hưởng đến quyết định dự đoán, từ đó hỗ trợ người dùng hiểu rõ hơn cơ sở mà mô hình sử dụng khi phân loại ảnh X-quang.

Như vậy, đầu vào của mô hình là ảnh X-quang ngực đã được tiền xử lý với kích thước $224 \times 224 \times 3$, còn đầu ra là vector xác suất dự đoán cho bốn lớp bệnh. Kết quả cuối cùng của hệ thống bao gồm nhãn bệnh được dự đoán, xác suất của từng lớp và các hình ảnh giải thích mô hình nhằm hỗ trợ quá trình quan sát và đánh giá kết quả.



Hình 3.4. Đầu ra và đầu vào của mô hình


3.4.3 Quy trình huấn luyện mô hình

Mô hình ResNet101 trong đề tài được xây dựng nhằm thực hiện bài toán phân loại bệnh phổi từ ảnh X-quang ngực. Trong quá trình hoạt động, mô hình tiếp nhận dữ liệu đầu vào là ảnh X-quang đã được tiền xử lý và tạo ra đầu ra dưới dạng xác suất dự đoán tương ứng với từng lớp bệnh.

Đầu vào của mô hình là ảnh X-quang ngực thuộc một trong bốn nhóm dữ liệu gồm COVID-19, Normal, Pneumonia và Tuberculosis. Trước khi đưa vào mô hình, ảnh được thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và chuyển đổi thành tensor phù hợp với định dạng xử lý của mô hình học sâu. Dữ liệu đầu vào sau khi xử lý có dạng kích thước $224 \times 224 \times 3$, trong đó 224×224 là kích thước không gian của ảnh và 3 là số kênh màu.

Bảng 3.2. Tham số huấn luyện mô hình

Tham số	Giá trị
Kiến trúc mô hình	ResNet101
Trọng số khởi tạo	ImageNet
Kích thước ảnh đầu vào	$224 \times 224 \times 3$
Số lớp đầu ra	4
Các lớp phân loại	COVID-19, Normal, Pneumonia, Tuberculosis
Hàm kích hoạt đầu ra	Softmax
Hàm mất mát	Categorical Crossentropy
Chỉ số đánh giá	Accuracy, Precision, Recall, F1-score
Môi trường huấn luyện	Kaggle Notebook
Batch Size	4
Epochs	10
Optimizer	Theo cấu hình thực nghiệm
Learning Rate	Theo cấu hình thực nghiệm



Hình 3.5 Quy trình huấn luyện mô hình

3.5 THIẾT KẾ CÁC KỸ THUẬT GIẢI THÍCH


3.5.1 Quy trình chung khi áp dụng kỹ thuật giải thích

Quy trình giải thích kết quả dự đoán được thực hiện sau khi mô hình ResNet101 hoàn thành quá trình phân loại ảnh X-quang đầu vào. Trước tiên, ảnh X-quang ngực được tiền xử lý bằng các bước như thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và chuyển đổi về định dạng tensor phù hợp với mô hình. Sau đó, ảnh được đưa vào mô hình ResNet101 để thực hiện dự đoán.

Sau khi mô hình tạo ra vector xác suất cho bốn lớp bệnh, lớp có xác suất cao nhất được chọn làm lớp dự đoán chính. Dựa trên lớp dự đoán này, các kỹ thuật giải thích sẽ được áp dụng nhằm xác định những vùng ảnh có ảnh hưởng đến quyết định của mô hình. Mỗi kỹ thuật có cách tiếp cận khác nhau, nhưng đều hướng đến việc làm rõ mối liên hệ giữa ảnh đầu vào và kết quả phân loại.

Kết quả của quá trình giải thích được hiển thị dưới dạng hình ảnh trực quan. Đối với Grad-CAM và Grad-CAM++, hệ thống tạo bản đồ nhiệt thể hiện vùng ảnh mà mô hình quan tâm. Đối với Integrated Gradients, hệ thống biểu diễn mức độ đóng góp của các điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Đối với Occlusion, hệ thống đánh giá tầm quan trọng của từng vùng ảnh bằng cách che khuất

một phần ảnh và quan sát sự thay đổi trong xác suất dự đoán.



Hình 3.6. Thiết kế các kỹ thuật giải thích

3.5.2 Kỹ thuật Grad-CAM

Grad-CAM, viết tắt của Gradient-weighted Class Activation Mapping, là một kỹ thuật giải thích phổ biến được sử dụng cho các mô hình mạng nơ-ron tích chập. Trong đề tài, Grad-CAM được áp dụng nhằm xác định những vùng ảnh X-quang có ảnh hưởng lớn đến kết quả dự đoán của mô hình ResNet101.

Nguyên lý hoạt động của Grad-CAM dựa trên thông tin gradient của lớp dự đoán đối với các bản đồ đặc trưng tại tầng tích chập cuối của mô hình. Khi mô hình đưa ra kết quả phân loại, Grad-CAM tính toán mức độ ảnh hưởng của từng bản đồ đặc trưng đến lớp dự đoán. Sau đó, các bản đồ đặc trưng này được kết hợp lại để tạo thành một bản đồ nhiệt thể hiện vùng ảnh quan trọng.

Trong ảnh kết quả Grad-CAM, các vùng có màu nổi bật thường biểu diễn những khu vực mà mô hình tập trung nhiều khi đưa ra dự đoán. Đối với ảnh X-quang phổi, các vùng này có thể nằm ở khu vực phổi, nơi xuất hiện vùng mờ, tổn thương hoặc dấu hiệu bất thường. Nhờ đó, người dùng có thể quan sát được mô hình đang chú ý vào vùng ảnh nào khi phân loại ảnh thuộc lớp COVID-19, Normal, Pneumonia hoặc Tuberculosis.

Việc sử dụng Grad-CAM giúp tăng tính trực quan cho hệ thống. Thay vì chỉ biết mô hình dự đoán ảnh thuộc lớp nào, người dùng có thể xem bản đồ nhiệt để kiểm tra vùng ảnh có tác động đến kết quả. Đây là yếu tố quan trọng trong hệ thống

hỗ trợ phân tích ảnh y tế, vì kết quả dự đoán cần đi kèm khả năng giải thích để tăng độ tin cậy khi tham khảo.

3.5.3 Kỹ thuật Grad-CAM++

Grad-CAM++ là phiên bản cải tiến của Grad-CAM, được sử dụng nhằm nâng cao khả năng định vị các vùng ảnh quan trọng. Trong một số trường hợp, ảnh X-quang có thể chứa nhiều vùng bất thường hoặc các vùng ảnh có ảnh hưởng đến kết quả dự đoán không tập trung tại một vị trí duy nhất. Khi đó, Grad-CAM++ có thể hỗ trợ biểu diễn chi tiết hơn các vùng mà mô hình quan tâm.

Grad-CAM++ cũng sử dụng thông tin gradient để xác định mức độ quan trọng của các vùng đặc trưng, nhưng cách tính trọng số được cải tiến nhằm phản ánh tốt hơn đóng góp của từng vị trí trong bản đồ đặc trưng. Nhờ đó, bản đồ nhiệt tạo ra bởi Grad-CAM++ có thể làm nổi bật các vùng ảnh quan trọng một cách rõ ràng hơn trong một số tình huống.

Trong hệ thống, Grad-CAM++ được áp dụng sau khi mô hình ResNet101 đưa ra lớp dự đoán. Kết quả của Grad-CAM++ được hiển thị dưới dạng bản đồ nhiệt chồng lên ảnh X-quang gốc. Người dùng có thể quan sát vùng ảnh được làm nổi bật để đánh giá xem mô hình có tập trung vào khu vực hợp lý hay không.

Việc kết hợp Grad-CAM và Grad-CAM++ giúp hệ thống có thêm góc nhìn trực quan về vùng ảnh quan trọng. Grad-CAM cung cấp bản đồ nhiệt tổng quát, trong khi Grad-CAM++ hỗ trợ làm rõ hơn các vùng ảnh có đóng góp đến quyết định phân loại. Cả hai kỹ thuật đều phù hợp với bài toán phân loại ảnh X-quang phổi bằng ResNet101.

3.5.4 Kỹ thuật Integrated Gradients

Integrated Gradients là kỹ thuật giải thích mô hình dựa trên gradient, được sử dụng để đánh giá mức độ đóng góp của từng điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Kỹ thuật này không chỉ cho biết vùng ảnh nào được mô hình chú ý, mà còn giúp phân tích mức độ ảnh hưởng của các vùng ảnh đến lớp dự đoán.

Nguyên lý của Integrated Gradients là so sánh ảnh đầu vào với một ảnh nền ban đầu. Ảnh nền này thường là ảnh có giá trị thấp hoặc ảnh gần như không chứa thông tin. Sau đó, kỹ thuật này tạo ra một chuỗi các ảnh trung gian từ ảnh nền đến ảnh gốc và tính toán gradient của mô hình trên các ảnh trung gian đó. Việc tích hợp gradient theo quá trình biến đổi này giúp xác định mức độ đóng góp của các điểm ảnh đối với kết quả phân loại.

Trong đề tài, Integrated Gradients được sử dụng để giải thích kết quả dự đoán của mô hình ResNet101 trên ảnh X-quang phổi. Kết quả của kỹ thuật này giúp biểu diễn những vùng ảnh có đóng góp tích cực hoặc có ảnh hưởng rõ rệt đến quyết định của mô hình. Đối với bài toán phân loại bệnh phổi, các vùng có đóng góp lớn có thể

liên quan đến những khu vực bất thường trên ảnh X-quang hoặc các đặc trưng hình ảnh mà mô hình cho là quan trọng.

Integrated Gradients giúp bổ sung thêm thông tin phân tích cho hệ thống. Nếu Grad-CAM và Grad-CAM++ chủ yếu tạo bản đồ nhiệt dựa trên lớp tích chập cuối, thì Integrated Gradients tập trung vào mức độ đóng góp của điểm ảnh hoặc vùng ảnh đối với kết quả đầu ra. Nhờ đó, hệ thống có thể giải thích kết quả dự đoán dưới nhiều góc nhìn hơn.

3.5.5 Kỹ thuật Occlusion

Occlusion là kỹ thuật giải thích mô hình dựa trên việc che khuất từng vùng nhỏ của ảnh đầu vào và quan sát sự thay đổi trong xác suất dự đoán. Đây là một phương pháp trực quan, dễ hiểu và phù hợp để minh họa tầm quan trọng của từng vùng ảnh đối với quyết định của mô hình.

Trong quá trình thực hiện, hệ thống lần lượt che một vùng nhỏ trên ảnh X-quang bằng một giá trị nền cố định. Sau mỗi lần che khuất, ảnh mới được đưa lại vào mô hình ResNet101 để tính toán xác suất dự đoán. Nếu việc che khuất một vùng ảnh làm xác suất của lớp dự đoán giảm mạnh, điều đó cho thấy vùng ảnh đó có vai trò quan trọng trong quyết định của mô hình.

Đối với ảnh X-quang phổi, kỹ thuật Occlusion giúp xác định những khu vực mà mô hình phụ thuộc nhiều khi phân loại ảnh. Nếu mô hình dự đoán một ảnh thuộc lớp Pneumonia và khi che một vùng trong phổi thì xác suất Pneumonia giảm đáng kể, vùng đó có thể được xem là vùng ảnh có ảnh hưởng lớn đến kết quả dự đoán. Cách giải thích này giúp người dùng dễ hình dung hơn về vai trò của từng khu vực ảnh.

Ưu điểm của Occlusion là nguyên lý đơn giản và dễ quan sát. Tuy nhiên, kỹ thuật này có thể tốn nhiều thời gian hơn vì phải thực hiện nhiều lần suy luận trên các phiên bản ảnh bị che khuất khác nhau. Trong phạm vi đề tài, Occlusion được sử dụng nhằm bổ sung thêm một cách giải thích trực quan bên cạnh các kỹ thuật dựa trên gradient.

3.5.6 Thiết kế đầu ra của các kỹ thuật giải thích

Đầu ra của các kỹ thuật giải thích được thiết kế nhằm hỗ trợ người dùng quan sát kết quả một cách trực quan và dễ hiểu. Sau khi mô hình ResNet101 đưa ra nhãn bệnh và xác suất dự đoán, hệ thống tạo thêm các hình ảnh giải thích tương ứng với từng phương pháp XAI. Các hình ảnh này được hiển thị cùng với ảnh X-quang gốc để người dùng có thể so sánh và đánh giá.

Cụ thể, đầu ra của Grad-CAM và Grad-CAM++ là bản đồ nhiệt thể hiện vùng ảnh quan trọng. Bản đồ nhiệt này có thể được chồng lên ảnh X-quang gốc để làm nổi bật khu vực mà mô hình tập trung. Đầu ra của Integrated Gradients là hình ảnh

thể hiện mức độ đóng góp của các điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Đầu ra của Occlusion là bản đồ hoặc vùng ảnh thể hiện mức độ ảnh hưởng khi từng khu vực bị che khuất.

Kết quả hiển thị cuối cùng bao gồm ảnh X-quang gốc, nhãn bệnh dự đoán, xác suất của bốn lớp bệnh và các hình ảnh giải thích từ Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Cách trình bày này giúp người dùng không chỉ biết kết quả phân loại, mà còn quan sát được cơ sở trực quan mà mô hình sử dụng trong quá trình đưa ra quyết định.

3.5.7 Ý nghĩa của việc tích hợp Explainable AI

Việc tích hợp các kỹ thuật Explainable AI vào hệ thống giúp tăng tính minh bạch của mô hình ResNet101 trong bài toán phân loại ảnh X-quang phổi. Trong lĩnh vực y tế, một hệ thống AI không chỉ cần đưa ra kết quả có độ chính xác cao mà còn cần có khả năng giải thích để người dùng hiểu được mô hình đang dựa vào thông tin nào.

Các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion giúp hệ thống giải thích kết quả dự đoán dưới nhiều góc nhìn khác nhau. Grad-CAM và Grad-CAM++ giúp trực quan hóa vùng ảnh quan trọng bằng bản đồ nhiệt. Integrated Gradients phân tích mức độ đóng góp của các vùng ảnh dựa trên gradient. Occlusion kiểm tra tầm quan trọng của từng vùng ảnh thông qua việc che khuất và quan sát sự thay đổi xác suất dự đoán.

Nhờ sự kết hợp này, hệ thống không chỉ thực hiện phân loại ảnh X-quang phổi thành bốn lớp bệnh mà còn hỗ trợ người dùng quan sát vùng ảnh ảnh hưởng đến quyết định của mô hình. Điều này góp phần giảm tính “hộp đen” của mô hình học sâu, tăng khả năng kiểm tra trực quan và giúp đề tài thể hiện rõ hơn vai trò của trí tuệ nhân tạo có khả năng giải thích trong hỗ trợ phân tích ảnh y tế.

3.6 THIẾT KẾ HỆ THỐNG WEB

3.6.1 Thiết kế Backend

Backend là thành phần xử lý trung tâm của hệ thống, chịu trách nhiệm tiếp nhận dữ liệu từ giao diện người dùng, xử lý ảnh đầu vào, gọi mô hình ResNet101 để dự đoán bệnh phổi và trả kết quả phân tích về Frontend. Trong đề tài, Backend được xây dựng bằng Flask trên nền tảng Python nhằm đảm bảo khả năng tích hợp thuận lợi với mô hình học sâu, các thư viện xử lý ảnh và các kỹ thuật giải thích mô hình.

Backend đóng vai trò trung gian giữa người dùng và mô hình AI. Khi người dùng tải ảnh X-quang ngực lên hệ thống, Frontend sẽ gửi ảnh đến Backend thông qua một API xử lý ảnh. Sau khi nhận được dữ liệu, Backend thực hiện kiểm tra định dạng ảnh, kiểm tra khả năng đọc ảnh và chuẩn bị dữ liệu cho quá trình phân tích.

Các định dạng ảnh phổ biến như JPG, JPEG hoặc PNG được hỗ trợ nhằm tạo sự thuận tiện cho người dùng khi sử dụng hệ thống.

Sau bước kiểm tra dữ liệu đầu vào, Backend tiến hành tiền xử lý ảnh. Ảnh X-quang được thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và chuyển đổi về dạng tensor phù hợp với đầu vào của mô hình ResNet101. Việc tiền xử lý này đảm bảo ảnh đầu vào có cấu trúc thống nhất với dữ liệu đã sử dụng trong quá trình huấn luyện mô hình, từ đó giúp quá trình dự đoán diễn ra ổn định hơn.

Tiếp theo, Backend nạp mô hình ResNet101 đã được huấn luyện trước để thực hiện quá trình suy luận. Mô hình tiếp nhận ảnh đã tiền xử lý và tạo ra vector xác suất tương ứng với bốn lớp bệnh gồm COVID-19, Normal, Pneumonia và Tuberculosis. Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán chính của hệ thống. Ngoài nhãn bệnh được dự đoán, Backend cũng trả về xác suất của từng lớp để người dùng có thể quan sát mức độ tin cậy của mô hình.

Bên cạnh chức năng dự đoán bệnh, Backend còn tích hợp các kỹ thuật giải thích mô hình gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Sau khi có kết quả dự đoán, các kỹ thuật này được áp dụng để tạo ra các hình ảnh giải thích, thể hiện vùng ảnh có ảnh hưởng đến quyết định của mô hình. Các kết quả XAI sau đó được chuyển đổi sang định dạng ảnh phù hợp để gửi về giao diện người dùng.

Dữ liệu phản hồi từ Backend bao gồm ảnh đầu vào đã xử lý, nhãn bệnh dự đoán, xác suất dự đoán của từng lớp và các ảnh giải thích mô hình. Các ảnh giải thích có thể bao gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Việc tổ chức kết quả theo dạng dữ liệu rõ ràng giúp Frontend dễ dàng hiển thị thông tin và tạo trải nghiệm trực quan cho người dùng.

Việc tách Backend thành một thành phần riêng giúp hệ thống dễ bảo trì và mở rộng trong tương lai. Khi cần cập nhật mô hình, thay đổi kỹ thuật giải thích hoặc bổ sung lớp bệnh mới, người phát triển có thể điều chỉnh chủ yếu ở phía Backend mà không cần thay đổi toàn bộ giao diện người dùng. Đây là cách tổ chức phù hợp với các hệ thống web có tích hợp mô hình trí tuệ nhân tạo.

3.6.2 Thiết kế Frontend

Frontend là thành phần giao tiếp trực tiếp với người dùng, được xây dựng bằng HTML, CSS và JavaScript. Thành phần này có nhiệm vụ cung cấp giao diện trực quan để người dùng tải ảnh X-quang ngực, gửi ảnh đến Backend, nhận kết quả phân tích và hiển thị thông tin dự đoán một cách rõ ràng.

Giao diện hệ thống được thiết kế theo hướng đơn giản, dễ sử dụng và phù hợp với mục tiêu hỗ trợ phân tích ảnh X-quang phổi. Người dùng không cần có kiến

thức chuyên sâu về trí tuệ nhân tạo hay lập trình vẫn có thể thao tác với hệ thống. Các thành phần chính trên giao diện bao gồm khu vực tải ảnh, khu vực hiển thị ảnh X-quang đầu vào, khu vực hiển thị kết quả dự đoán và khu vực hiển thị các hình ảnh giải thích mô hình.

Chức năng đầu tiên của Frontend là cho phép người dùng chọn và tải ảnh X-quang ngực lên hệ thống. Sau khi người dùng chọn ảnh, giao diện có thể hiển thị ảnh xem trước để người dùng kiểm tra lại trước khi gửi đi phân tích. Điều này giúp hạn chế trường hợp tải nhầm ảnh hoặc sử dụng ảnh không phù hợp.

Sau khi người dùng thực hiện thao tác phân tích, Frontend gửi ảnh đến Backend thông qua API. Trong thời gian chờ xử lý, giao diện có thể hiển thị trạng thái đang phân tích để người dùng biết hệ thống đang hoạt động. Khi Backend trả kết quả về, Frontend tiếp nhận dữ liệu và hiển thị kết quả dự đoán trên trình duyệt.

Kết quả dự đoán được trình bày gồm nhãn bệnh mà mô hình dự đoán và xác suất tương ứng của từng lớp COVID-19, Normal, Pneumonia và Tuberculosis. Việc hiển thị xác suất của cả bốn lớp giúp người dùng không chỉ biết kết quả cuối cùng mà còn quan sát được mức độ tin cậy của mô hình đối với từng nhóm bệnh. Cách trình bày này làm cho kết quả phân tích rõ ràng và dễ theo dõi hơn.

Ngoài phân kết quả dự đoán, Frontend còn hiển thị các hình ảnh giải thích mô hình. Các ảnh Grad-CAM và Grad-CAM++ giúp người dùng quan sát vùng ảnh mà mô hình tập trung khi đưa ra dự đoán. Integrated Gradients thể hiện mức độ đóng góp của các vùng ảnh đối với kết quả phân loại. Occlusion giúp minh họa sự thay đổi kết quả khi một vùng ảnh bị che khuất. Việc hiển thị đồng thời các kết quả này giúp hệ thống có tính trực quan hơn, thay vì chỉ đưa ra nhãn bệnh một cách khô khan như một cái máy đoán mò mặc vest.

Giao diện Frontend cũng cần đảm bảo tính rõ ràng trong bố cục. Ảnh X-quang gốc và các ảnh giải thích nên được sắp xếp theo từng khu vực riêng để người dùng dễ so sánh. Các thông tin như nhãn dự đoán, xác suất và tên kỹ thuật giải thích cần được trình bày dễ đọc, tránh gây rối mắt. Màu sắc, kích thước chữ và bố cục giao diện cần được thiết kế nhất quán để hỗ trợ quá trình trình bày kết quả trong báo cáo và demo hệ thống.

Nhìn chung, Frontend đóng vai trò quan trọng trong việc giúp người dùng tương tác với hệ thống. Thành phần này không trực tiếp thực hiện dự đoán, nhưng là nơi thể hiện kết quả phân tích của mô hình một cách trực quan và dễ hiểu. Một giao diện rõ ràng giúp người dùng dễ dàng quan sát ảnh đầu vào, kết quả dự đoán và các vùng ảnh được mô hình quan tâm.

3.6.3 Quy trình tương tác giữa người dùng và hệ thống

Quy trình tương tác giữa người dùng và hệ thống mô tả cách dữ liệu được

trao đổi giữa Frontend, Backend và mô hình ResNet101 trong quá trình phân tích ảnh X-quang phổi. Quy trình này giúp đảm bảo dữ liệu được xử lý theo đúng thứ tự, từ lúc người dùng tải ảnh lên đến lúc hệ thống hiển thị kết quả dự đoán và giải thích mô hình.

Đầu tiên, người dùng truy cập vào hệ thống thông qua trình duyệt web. Tại giao diện chính, người dùng chọn ảnh X-quang ngực cần phân tích từ thiết bị cá nhân. Sau khi ảnh được chọn, Frontend có thể hiển thị ảnh xem trước để người dùng kiểm tra. Khi người dùng xác nhận phân tích, ảnh được gửi từ Frontend đến Backend để xử lý.

Sau khi nhận ảnh, Backend kiểm tra dữ liệu đầu vào. Nếu ảnh không đúng định dạng hoặc không thể đọc được, hệ thống sẽ trả về thông báo lỗi để người dùng thực hiện lại thao tác. Nếu ảnh hợp lệ, Backend tiếp tục thực hiện các bước tiền xử lý như thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và chuyển đổi ảnh sang dạng dữ liệu phù hợp với mô hình ResNet101.

Tiếp theo, ảnh đã tiền xử lý được đưa vào mô hình ResNet101 để thực hiện dự đoán. Mô hình phân tích ảnh và tạo ra xác suất tương ứng với bốn lớp bệnh gồm COVID-19, Normal, Pneumonia và Tuberculosis. Backend xác định lớp có xác suất cao nhất làm nhãn dự đoán chính, đồng thời giữ lại xác suất của các lớp còn lại để hiển thị cho người dùng.

Sau khi có kết quả phân loại, Backend tiếp tục áp dụng các kỹ thuật Explainable AI để giải thích quyết định của mô hình. Các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion được sử dụng để tạo ra các hình ảnh trực quan thể hiện vùng ảnh có ảnh hưởng đến kết quả dự đoán. Các hình ảnh này được xử lý và chuyển về định dạng phù hợp để gửi lại cho Frontend.

Cuối cùng, Frontend nhận kết quả từ Backend và hiển thị trên giao diện web. Kết quả hiển thị bao gồm ảnh X-quang gốc, nhãn bệnh dự đoán, xác suất của từng lớp bệnh và các ảnh giải thích mô hình. Người dùng có thể quan sát kết quả dự đoán cùng với các vùng ảnh mà mô hình tập trung, từ đó có thêm cơ sở trực quan để tham khảo trong quá trình đánh giá.

Quy trình tương tác giữa người dùng và hệ thống có thể tóm tắt như sau: người dùng tải ảnh X-quang lên giao diện, Frontend gửi ảnh đến Backend, Backend tiền xử lý ảnh và đưa vào mô hình ResNet101, mô hình trả về kết quả dự đoán, các kỹ thuật XAI tạo ảnh giải thích, Backend gửi kết quả về Frontend và Frontend hiển thị kết quả cho người dùng.

3.7 TỔNG KẾT CHƯƠNG

Chương 3 đã trình bày quá trình phân tích và thiết kế hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực. Nội dung chương tập trung vào

các thành phần chính của hệ thống gồm yêu cầu chức năng, yêu cầu phi chức năng, kiến trúc tổng quan, bộ dữ liệu, quy trình tiền xử lý, mô hình ResNet101, các kỹ thuật giải thích mô hình và thiết kế hệ thống web.

Trong chương này, bộ dữ liệu ảnh X-quang phổi được mô tả với bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Dữ liệu được chia thành các tập Training, Validation và Test để phục vụ quá trình huấn luyện, theo dõi và đánh giá mô hình. Trước khi đưa vào mô hình, ảnh được thay đổi kích thước về 224×224 pixel, chuẩn hóa giá trị điểm ảnh và tăng cường dữ liệu nhằm giúp mô hình học ổn định hơn.

Mô hình ResNet101 được thiết kế để thực hiện bài toán phân loại ảnh X-quang phổi. Đầu vào của mô hình là ảnh đã được tiền xử lý, đầu ra là xác suất dự đoán tương ứng với bốn lớp bệnh. Bên cạnh kết quả phân loại, hệ thống còn tích hợp các kỹ thuật giải thích gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion để trực quan hóa vùng ảnh có ảnh hưởng đến quyết định của mô hình.

Ngoài ra, chương cũng trình bày thiết kế hệ thống web gồm Backend, Frontend và quy trình tương tác giữa người dùng với hệ thống. Backend đảm nhiệm việc tiếp nhận ảnh, tiền xử lý, gọi mô hình ResNet101 và tạo kết quả giải thích. Frontend hỗ trợ người dùng tải ảnh, gửi yêu cầu phân tích và hiển thị kết quả dự đoán cùng các hình ảnh giải thích.

Tóm lại, Chương 3 đã xây dựng cơ sở thiết kế cho toàn bộ hệ thống, làm nền tảng cho quá trình triển khai, huấn luyện mô hình, tích hợp kỹ thuật giải thích và đánh giá kết quả trong các chương tiếp theo.

CHƯƠNG 4

TRIỂN KHAI VÀ KẾT QUẢ THỰC NGHIỆM

4.1 GIỚI THIỆU CHƯƠNG

Chương 4 trình bày quá trình triển khai và kết quả thực nghiệm của hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực. Nội dung chương tập trung vào việc mô tả môi trường triển khai, quá trình huấn luyện mô hình ResNet101, kết quả đánh giá mô hình trên tập dữ liệu kiểm thử và minh họa kết quả giải thích mô hình bằng các kỹ thuật Explainable AI.

Trong chương này, mô hình ResNet101 được triển khai để thực hiện bài toán phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Quá trình thực nghiệm bao gồm các bước chuẩn bị dữ liệu, tiền xử lý ảnh, huấn luyện mô hình, đánh giá kết quả dự đoán và phân tích hiệu quả của mô hình thông qua các chỉ số Accuracy, Precision, Recall và F1-score.

Bên cạnh kết quả phân loại, chương này cũng trình bày kết quả giải thích mô hình bằng các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Các kỹ thuật này được sử dụng nhằm trực quan hóa những vùng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình, từ đó giúp kết quả phân loại trở nên dễ quan sát và có tính minh bạch hơn.

Ngoài ra, chương còn mô tả kết quả triển khai hệ thống web hỗ trợ người dùng tải ảnh X-quang ngực, gửi ảnh đến Backend để xử lý, nhận kết quả dự đoán từ mô hình ResNet101 và hiển thị các hình ảnh giải thích mô hình trên giao diện Frontend. Việc triển khai hệ thống web giúp minh họa khả năng ứng dụng mô hình vào một quy trình sử dụng thực tế.

Các kết quả trong chương được trình bày nhằm đánh giá mức độ hiệu quả của mô hình ResNet101 trong bài toán phân loại bệnh phổi từ ảnh X-quang, đồng thời làm rõ vai trò của các kỹ thuật giải thích mô hình trong việc hỗ trợ người dùng quan sát cơ sở dự đoán của hệ thống. Đây là cơ sở để nhận xét ưu điểm, hạn chế và khả năng phát triển của đề tài trong các phần tiếp theo.

4.2 KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH RESNET101

4.2.1 Các chỉ số đánh giá mô hình

Để đánh giá hiệu quả phân loại của mô hình ResNet101, đề tài sử dụng bốn chỉ số chính gồm Accuracy, Precision, Recall và F1-score. Đây là các chỉ số phổ biến trong bài toán phân loại ảnh, đặc biệt phù hợp khi cần đánh giá khả năng dự đoán đúng của mô hình đối với từng nhóm dữ liệu.

Accuracy là chỉ số thể hiện tỷ lệ số mẫu được mô hình dự đoán đúng trên tổng số mẫu trong tập kiểm thử. Chỉ số này cho biết hiệu quả tổng thể của mô hình khi phân loại ảnh X-quang vào bốn lớp bệnh. Accuracy càng cao thì tỷ lệ ảnh được

phân loại đúng càng lớn.

Công thức tính Accuracy được biểu diễn như sau:

$$Accuracy = \text{Số mẫu dự đoán đúng} / \text{Tổng số mẫu đánh giá}$$

Trong bài toán phân loại bốn lớp bệnh phổi, Accuracy cho biết mô hình ResNet101 dự đoán đúng bao nhiêu ảnh trong toàn bộ tập kiểm thử. Tuy nhiên, Accuracy chỉ phản ánh hiệu quả tổng quát và chưa cho biết chi tiết mô hình có nhận diện tốt từng lớp bệnh hay không.

Precision là chỉ số thể hiện mức độ chính xác của các dự đoán dương tính. Nói cách khác, Precision cho biết trong số các ảnh được mô hình dự đoán thuộc một lớp bệnh cụ thể, có bao nhiêu ảnh thật sự thuộc lớp đó. Precision cao cho thấy mô hình ít dự đoán nhầm ảnh của lớp khác thành lớp đang xét.

Công thức tính Precision được biểu diễn như sau:

$$Precision = TP / (TP + FP)$$

Trong đó, TP là số mẫu được dự đoán đúng thuộc lớp đang xét, còn FP là số mẫu không thuộc lớp đang xét nhưng bị mô hình dự đoán nhầm vào lớp đó. Đối với bài toán y tế, Precision có ý nghĩa quan trọng vì nó phản ánh mức độ tin cậy của các kết quả mà mô hình đưa ra.

Recall là chỉ số thể hiện khả năng mô hình nhận diện đúng các mẫu thật sự thuộc một lớp bệnh. Recall cho biết trong số các ảnh thật sự thuộc một lớp bệnh, mô hình đã phát hiện đúng được bao nhiêu ảnh. Recall càng cao thì khả năng bỏ sót mẫu thuộc lớp đó càng thấp.

Công thức tính Recall được biểu diễn như sau:

$$Recall = TP / (TP + FN)$$

Trong đó, FN là số mẫu thật sự thuộc lớp đang xét nhưng bị mô hình dự đoán sai sang lớp khác. Trong bài toán phân loại bệnh phổi, Recall là chỉ số quan trọng vì nó phản ánh khả năng nhận diện đúng các trường hợp bệnh trong tập dữ liệu.

F1-score là chỉ số kết hợp giữa Precision và Recall. Chỉ số này được sử dụng để đánh giá sự cân bằng giữa khả năng dự đoán chính xác và khả năng nhận diện đầy đủ của mô hình. F1-score có giá trị cao khi cả Precision và Recall đều cao.

Công thức tính F1-score được biểu diễn như sau:

$$F1\text{-score} = 2 \times Precision \times Recall / (Precision + Recall)$$

F1-score đặc biệt hữu ích trong các bài toán phân loại có nhiều lớp hoặc dữ liệu có sự khác biệt về số lượng giữa các lớp. Đối với đề tài này, F1-score giúp đánh giá tổng hợp khả năng phân loại của mô hình ResNet101 trên bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis.

Bảng 4.1. Ý nghĩa các chỉ số đánh giá mô hình

Chỉ số	Ý nghĩa
Accuracy	Đánh giá tỷ lệ dự đoán đúng trên toàn bộ tập kiểm thử
Precision	Đánh giá độ chính xác của các mẫu được mô hình dự đoán thuộc một lớp
Recall	Đánh giá khả năng mô hình nhận diện đúng các mẫu thật sự thuộc một lớp
F1-score	Đánh giá cân bằng giữa Precision và Recall
TP	Số mẫu thuộc lớp đang xét và được dự đoán đúng
FP	Số mẫu không thuộc lớp đang xét nhưng bị dự đoán nhầm vào lớp đó
FN	Số mẫu thuộc lớp đang xét nhưng bị dự đoán sai sang lớp khác

Như vậy, việc sử dụng đồng thời nhiều chỉ số đánh giá giúp kết quả thực nghiệm trở nên đầy đủ hơn. Accuracy cho biết hiệu quả tổng thể, Precision cho biết độ tin cậy của dự đoán, Recall cho biết khả năng phát hiện đúng các mẫu thuộc từng lớp, còn F1-score thể hiện sự cân bằng giữa Precision và Recall.

4.2.2 Kết quả đánh giá trên tập kiểm thử

Sau khi thực hiện đánh giá mô hình ResNet101 trên tập kiểm thử, hệ thống thu được các chỉ số Accuracy, Precision, Recall và F1-score. Đây là các giá trị tổng hợp phản ánh hiệu quả chung của mô hình trong bài toán phân loại ảnh X-quang phổi thành bốn lớp.

Bảng 4.2. Kết quả đánh giá mô hình ResNet101 trên tập kiểm thử

Chỉ số	Giá trị
Accuracy	0.948119
Precision	0.963359
Recall	0.956805
F1-score	0.959712

Dựa trên Bảng 4.2, mô hình ResNet101 đạt Accuracy là 0.948. Kết quả này cho thấy mô hình có khả năng dự đoán đúng phần lớn các ảnh trong tập kiểm thử. Với giá trị Accuracy xấp xỉ 94,8%, mô hình thể hiện hiệu quả tổng thể tốt trong bài toán phân loại ảnh X-quang phổi bốn lớp.

Precision của mô hình đạt 0.963, tương đương khoảng 96,3%. Đây là chỉ số cao, cho thấy khi mô hình dự đoán một ảnh thuộc một lớp bệnh cụ thể, khả năng dự đoán đó là đúng tương đối lớn. Điều này phản ánh mô hình có khả năng hạn chế tình trạng dự đoán nhầm ảnh của lớp khác thành lớp bệnh đang xét.

Recall của mô hình đạt 0.956, tương đương khoảng 95,6%. Kết quả này cho thấy mô hình có khả năng nhận diện đúng phần lớn các ảnh thật sự thuộc từng lớp bệnh. Trong bài toán ảnh y tế, Recall là chỉ số có ý nghĩa quan trọng vì nó liên quan đến khả năng phát hiện các trường hợp bệnh trong dữ liệu đầu vào.

F1-score của mô hình đạt 0.959, tương đương khoảng 95,9%. Đây là chỉ số kết hợp giữa Precision và Recall, cho thấy mô hình đạt được sự cân bằng tốt giữa khả năng dự đoán chính xác và khả năng nhận diện đầy đủ. Việc F1-score đạt giá trị cao cho thấy mô hình ResNet101 hoạt động ổn định trên tập kiểm thử.

Bảng 4.3. Diễn giải kết quả đánh giá mô hình

Chỉ số	Giá trị	Nhận xét
Accuracy	0.948119	Mô hình dự đoán đúng phần lớn ảnh trong tập kiểm thử
Precision	0.963359	Các dự đoán của mô hình có độ tin cậy cao
Recall	0.956805	Mô hình nhận diện tốt các mẫu thuộc từng lớp bệnh
F1-score	0.959712	Mô hình đạt sự cân bằng tốt giữa Precision và Recall

Từ các kết quả trên, có thể nhận thấy mô hình ResNet101 đạt hiệu quả tốt trong bài toán phân loại ảnh X-quang phổi. Các chỉ số Precision, Recall và F1-score đều đạt trên 0.95, cho thấy mô hình không chỉ có khả năng dự đoán đúng nhiều mẫu mà còn duy trì được sự ổn định trong quá trình phân loại.

Kết quả này cho thấy mô hình đã học được các đặc trưng quan trọng từ ảnh X-quang phổi. Các đặc trưng này có thể bao gồm cấu trúc vùng phổi, độ mờ, sự thay đổi mật độ ảnh, vùng bất thường hoặc các dấu hiệu hình ảnh liên quan đến từng nhóm bệnh. Nhờ khả năng trích xuất đặc trưng của ResNet101, mô hình có thể phân biệt tương đối hiệu quả giữa các lớp COVID-19, Normal, Pneumonia và Tuberculosis.

Tuy nhiên, cần lưu ý rằng kết quả đánh giá trên tập kiểm thử chỉ phản ánh hiệu quả của mô hình trong phạm vi bộ dữ liệu được sử dụng trong đề tài. Trong thực tế, ảnh X-quang có thể đến từ nhiều nguồn khác nhau, có sự khác biệt về thiết bị chụp, chất lượng ảnh, độ tương phản, tư thế chụp và đặc điểm bệnh lý. Do đó, kết quả mô hình cần được xem là cơ sở thực nghiệm trong phạm vi nghiên cứu, không thay thế cho kết luận chẩn đoán của bác sĩ.

4.2.3 Ma trận nhầm lẫn


Bên cạnh các chỉ số đánh giá tổng hợp, ma trận nhầm lẫn được sử dụng để phân tích chi tiết hơn kết quả phân loại của mô hình ResNet101. Ma trận nhầm lẫn cho biết số lượng ảnh được mô hình dự đoán đúng và số lượng ảnh bị dự đoán nhầm

giữa các lớp.

Trong bài toán phân loại bốn lớp, ma trận nhầm lẫn có dạng bảng gồm bốn hàng và bốn cột, tương ứng với bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis. Các hàng thường biểu diễn nhãn thực tế, còn các cột biểu diễn nhãn dự đoán của mô hình. Mỗi ô trong ma trận thể hiện số lượng ảnh thuộc một lớp thực tế nhưng được mô hình dự đoán vào một lớp cụ thể.

Các giá trị nằm trên đường chéo chính của ma trận thể hiện số lượng mẫu được mô hình dự đoán đúng. Ví dụ, ô giao giữa hàng COVID-19 và cột COVID-19 thể hiện số lượng ảnh COVID-19 được mô hình dự đoán đúng là COVID-19. Tương tự, các ô trên đường chéo chính của lớp Normal, Pneumonia và Tuberculosis cũng thể hiện số lượng mẫu dự đoán đúng của từng lớp.

Các giá trị nằm ngoài đường chéo chính thể hiện các trường hợp mô hình dự đoán sai. Ví dụ, nếu một ảnh thực tế thuộc lớp Pneumonia nhưng bị mô hình dự đoán thành COVID-19, giá trị này sẽ xuất hiện ở hàng Pneumonia và cột COVID-19. Việc phân tích các giá trị ngoài đường chéo giúp xác định những lớp nào dễ bị nhầm lẫn với nhau.



Hình 4.1. Ma trận nhầm lẫn của mô hình ResNet101

Ma trận nhầm lẫn giúp đánh giá trực quan hiệu quả phân loại của mô hình đối với từng lớp bệnh. Nếu phần lớn giá trị tập trung trên đường chéo chính, điều đó cho thấy mô hình phân loại tốt. Ngược lại, nếu có nhiều giá trị lớn nằm ngoài đường chéo chính, điều đó cho thấy mô hình còn nhầm lẫn giữa một số lớp nhất định.

Đối với bài toán phân loại bệnh phổi từ ảnh X-quang, một số lớp bệnh có thể có biểu hiện hình ảnh tương đối giống nhau. Ví dụ, COVID-19 và Pneumonia đều có thể xuất hiện các vùng mờ hoặc bất thường trên ảnh phổi. Vì vậy, mô hình có thể gặp khó khăn trong một số trường hợp ảnh có biểu hiện không rõ ràng hoặc chất lượng ảnh thấp. Ma trận nhầm lẫn giúp phát hiện các trường hợp này để có nhận xét chính xác hơn về hiệu quả của mô hình.

Ngoài ra, ma trận nhầm lẫn còn hỗ trợ phân tích sâu hơn về từng lớp bệnh. Nếu một lớp có số lượng dự đoán đúng cao và số lượng dự đoán sai thấp, có thể nhận xét rằng mô hình học tốt đặc trưng của lớp đó. Ngược lại, nếu một lớp thường xuyên bị dự đoán nhầm sang lớp khác, cần xem xét lại chất lượng dữ liệu, số lượng mẫu, đặc trưng ảnh hoặc quá trình tiền xử lý.

Thông qua ma trận nhầm lẫn, đề tài có thể đánh giá không chỉ hiệu quả tổng thể của mô hình mà còn khả năng phân biệt cụ thể giữa từng nhóm bệnh. Đây là cơ sở quan trọng để nhận xét ưu điểm và hạn chế của mô hình ResNet101 trong phạm vi thực nghiệm.

4.2.4 Nhận xét kết quả phân loại

Từ kết quả đánh giá trên tập kiểm thử, có thể nhận xét rằng mô hình ResNet101 đạt hiệu quả tốt trong bài toán phân loại ảnh X-quang phổi thành bốn lớp. Các chỉ số Accuracy, Precision, Recall và F1-score đều đạt giá trị cao, cho thấy mô hình có khả năng học và trích xuất các đặc trưng quan trọng từ ảnh đầu vào.

Accuracy đạt 0.948 cho thấy mô hình có tỷ lệ dự đoán đúng tổng thể cao. Điều này phản ánh mô hình ResNet101 có khả năng phân loại tốt trên tập kiểm thử. Với bài toán gồm bốn lớp bệnh, kết quả Accuracy cao cho thấy mô hình đã phân biệt được phần lớn các ảnh thuộc các nhóm COVID-19, Normal, Pneumonia và Tuberculosis.

Precision đạt 0.963 cho thấy các kết quả dự đoán của mô hình có độ chính xác cao. Khi mô hình đưa ra dự đoán một ảnh thuộc một lớp bệnh cụ thể, khả năng dự đoán đó đúng là tương đối lớn. Điều này giúp tăng độ tin cậy của kết quả phân loại khi hệ thống hiển thị nhãn bệnh dự đoán cho người dùng.

Recall đạt 0.956 cho thấy mô hình có khả năng nhận diện tốt các mẫu thật sự thuộc từng lớp bệnh. Chỉ số này có ý nghĩa quan trọng vì trong bài toán y tế, việc bỏ sót các trường hợp bệnh là vấn đề cần hạn chế. Recall cao cho thấy mô hình đã

nhận diện được phần lớn các ảnh thuộc các lớp bệnh trong tập kiểm thử.

F1-score đạt 0.959 cho thấy mô hình có sự cân bằng tốt giữa Precision và Recall. Điều này chứng tỏ mô hình không chỉ dự đoán chính xác mà còn có khả năng nhận diện đầy đủ các mẫu thuộc từng lớp. F1-score cao cũng phản ánh hiệu quả ổn định của mô hình trong quá trình phân loại ảnh X-quang phổi.

Nhìn chung, kết quả thực nghiệm cho thấy ResNet101 phù hợp với bài toán phân loại bệnh phổi từ ảnh X-quang trong phạm vi đề tài. Mô hình có khả năng trích xuất đặc trưng từ ảnh y tế và đưa ra kết quả phân loại với độ chính xác cao. Các kết quả này là cơ sở để tích hợp mô hình vào hệ thống web hỗ trợ người dùng tải ảnh, nhận kết quả dự đoán và quan sát các hình ảnh giải thích mô hình.

Tuy nhiên, mô hình vẫn tồn tại một số hạn chế nhất định. Ảnh X-quang phổi có thể khác nhau về chất lượng, độ sáng, độ tương phản, tư thế chụp và nguồn dữ liệu. Những yếu tố này có thể ảnh hưởng đến khả năng dự đoán của mô hình. Bên cạnh đó, một số bệnh lý phổi có biểu hiện hình ảnh tương đồng, khiến mô hình có thể nhầm lẫn trong các trường hợp đặc trưng bệnh không rõ ràng.

Ngoài ra, kết quả dự đoán của mô hình cần được xem là kết quả hỗ trợ tham khảo trong phạm vi nghiên cứu và thử nghiệm. Hệ thống không có chức năng thay thế bác sĩ hoặc đưa ra kết luận y khoa cuối cùng. Việc sử dụng mô hình AI trong bài toán ảnh y tế cần được kết hợp với kiến thức chuyên môn và đánh giá của người có chuyên môn trong lĩnh vực y tế.

Từ các kết quả đạt được, có thể thấy mô hình ResNet101 là thành phần quan trọng trong hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang. Mô hình cung cấp kết quả phân loại làm cơ sở cho các bước tiếp theo, bao gồm hiển thị xác suất dự đoán và áp dụng các kỹ thuật giải thích như Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Sự kết hợp giữa kết quả phân loại và kết quả giải thích giúp hệ thống trở nên trực quan, minh bạch và dễ quan sát hơn đối với người dùng.

Tóm lại, mục 4.3 đã trình bày kết quả đánh giá mô hình ResNet101 trên tập kiểm thử thông qua các chỉ số Accuracy, Precision, Recall và F1-score, đồng thời phân tích vai trò của ma trận nhầm lẫn trong việc đánh giá chi tiết khả năng phân loại của mô hình. Kết quả thực nghiệm cho thấy mô hình đạt hiệu quả tốt trong phạm vi bộ dữ liệu sử dụng, tạo nền tảng cho việc triển khai hệ thống web và tích hợp các kỹ thuật giải thích mô hình ở các mục tiếp theo.


4.3 KẾT QUẢ GIẢI THÍCH MÔ HÌNH BẰNG XAI

Sau khi mô hình ResNet101 đưa ra kết quả dự đoán cho ảnh X-quang ngực, hệ thống tiếp tục áp dụng các kỹ thuật giải thích mô hình nhằm trực quan hóa vùng ảnh có ảnh hưởng đến quyết định phân loại. Trong đề tài, bốn kỹ thuật Explainable

AI được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion.

Việc hiển thị kết quả giải thích giúp người dùng không chỉ biết mô hình dự đoán ảnh thuộc lớp bệnh nào, mà còn có thể quan sát được những vùng ảnh mà mô hình tập trung trong quá trình đưa ra quyết định. Đây là thành phần quan trọng trong hệ thống hỗ trợ phân tích ảnh y tế, vì kết quả phân loại của mô hình học sâu thường khó quan sát trực tiếp nếu chỉ dựa vào nhãn dự đoán và xác suất.

Trong hệ thống, kết quả giải thích được hiển thị cùng với ảnh X-quang gốc. Các hình ảnh giải thích gồm bản đồ nhiệt hoặc bản đồ mức độ ảnh hưởng của vùng ảnh đối với kết quả dự đoán. Cách trình bày này giúp người dùng dễ dàng so sánh giữa ảnh gốc và các kết quả XAI, từ đó có thêm cơ sở trực quan để nhận xét về quyết định của mô hình.



Hình 4.2. Kết quả giải thích mô hình bằng các kỹ thuật XAI

4.3.1 Kết quả giải thích bằng Grad-CAM

Grad-CAM được sử dụng để tạo bản đồ nhiệt thể hiện những vùng ảnh có ảnh hưởng lớn đến kết quả dự đoán của mô hình ResNet101. Kỹ thuật này dựa trên thông tin gradient tại các tầng tích chập cuối của mô hình để xác định khu vực ảnh mà mô hình quan tâm khi phân loại.


Trong kết quả hiển thị, ảnh Grad-CAM thường được thể hiện dưới dạng bản đồ nhiệt chồng lên ảnh X-quang gốc. Các vùng có màu nổi bật biểu diễn khu vực có mức độ ảnh hưởng cao đối với quyết định của mô hình. Đối với ảnh X-quang phổi, các vùng này thường nằm trong khu vực phổi, nơi có thể xuất hiện các dấu hiệu bất thường liên quan đến bệnh lý.

Kết quả Grad-CAM giúp người dùng quan sát được mô hình ResNet101 đang tập trung vào vùng nào trên ảnh khi đưa ra dự đoán. Nếu vùng nổi bật nằm trong khu vực phổi hoặc vùng có dấu hiệu bất thường, điều này cho thấy mô hình có xu hướng khai thác các đặc trưng liên quan đến nội dung ảnh y tế thay vì tập trung vào vùng nền hoặc khu vực không quan trọng.

Trong hệ thống, Grad-CAM đóng vai trò cung cấp bản đồ giải thích tổng quan. Bản đồ này giúp người dùng nhanh chóng nhận biết vùng ảnh có ảnh hưởng đến kết quả phân loại. Đây là một trong những kỹ thuật trực quan dễ quan sát nhất

khi trình bày kết quả giải thích mô hình học sâu trên ảnh X-quang.

Tuy nhiên, kết quả Grad-CAM chỉ mang tính chất hỗ trợ trực quan. Bản đồ nhiệt không khẳng định chắc chắn vùng ảnh được làm nổi bật là vùng bệnh lý thật sự, mà chỉ cho biết mô hình đã sử dụng vùng đó như một phần thông tin để đưa ra dự đoán. Do đó, kết quả này cần được hiểu là cơ sở tham khảo trong phạm vi hệ thống hỗ trợ phân tích ảnh.



Hình 4.3. Kết quả giải thích bằng Grad-CAM

4.3.2 Kết quả giải thích bằng Grad-CAM++

Grad-CAM++ được sử dụng nhằm tạo ra bản đồ nhiệt chi tiết hơn trong một số trường hợp ảnh có nhiều vùng ảnh hưởng đến kết quả dự đoán. Tương tự Grad-CAM, kỹ thuật này cũng dựa trên thông tin gradient của mô hình, nhưng cách tính trọng số được cải tiến để làm rõ hơn mức độ đóng góp của từng vùng ảnh.

Trong kết quả hiển thị, Grad-CAM++ cũng tạo bản đồ nhiệt chồng lên ảnh X-quang gốc. Các vùng có màu nổi bật cho biết những vị trí mà mô hình ResNet101 xem là quan trọng đối với lớp dự đoán. So với bản đồ Grad-CAM, kết quả Grad-CAM++ có thể thể hiện chi tiết hơn các vùng ảnh liên quan trong một số tình huống, đặc biệt khi ảnh có nhiều vùng bất thường hoặc đặc trưng phân bố không tập trung tại một vị trí duy nhất.

Đối với bài toán phân loại bệnh phổi từ ảnh X-quang, Grad-CAM++ giúp hỗ trợ quan sát rõ hơn vùng ảnh có đóng góp đến quyết định phân loại. Nếu mô hình dự đoán ảnh thuộc lớp Pneumonia, COVID-19 hoặc Tuberculosis, bản đồ Grad-CAM++ có thể làm nổi bật các khu vực trong phổi mà mô hình cho là có liên quan đến kết quả dự đoán. Đối với lớp Normal, bản đồ nhiệt có thể ít tập trung vào vùng bất thường rõ rệt hơn, tùy thuộc vào đặc trưng ảnh đầu vào.

Kết quả Grad-CAM++ giúp bổ sung thêm góc nhìn trực quan bên cạnh Grad-CAM. Việc hiển thị cả hai kết quả giúp người dùng có thêm cơ sở để quan sát vùng ảnh mà mô hình chú ý. Nếu cả Grad-CAM và Grad-CAM++

cùng làm nổi bật các vùng tương tự trong ảnh, kết quả giải thích có thể được xem là nhất quán hơn về mặt trực quan.

Tương tự các kỹ thuật XAI khác, Grad-CAM++ không thay thế cho đánh giá chuyên môn y tế. Kết quả bản đồ nhiệt chỉ phản ánh vùng ảnh có ảnh hưởng đến mô hình, không phải là kết luận lâm sàng. Trong phạm vi đề tài, Grad-CAM++ được sử dụng để tăng tính minh bạch và hỗ trợ trình bày kết quả phân loại của mô hình ResNet101.



Hình 4.4. Kết quả giải thích bằng Grad-CAM++

4.3.3 Kết quả giải thích bằng Integrated Gradients

Integrated Gradients được sử dụng để phân tích mức độ đóng góp của từng điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán của mô hình. Kỹ thuật này đánh giá sự thay đổi đầu ra của mô hình khi ảnh đầu vào được biến đổi dần từ một ảnh nền đến ảnh gốc, từ đó xác định những vùng ảnh có ảnh hưởng đến lớp dự đoán.


Trong kết quả hiển thị, Integrated Gradients tạo ra hình ảnh thể hiện mức độ đóng góp của các vùng ảnh đối với quyết định phân loại. Những vùng có mức độ đóng góp cao thường được thể hiện rõ hơn trên bản đồ giải thích. Đối với ảnh X-quang phổi, các vùng này có thể nằm trong khu vực phổi hoặc vùng xuất hiện đặc trưng bất thường mà mô hình sử dụng trong quá trình phân loại.

Khác với Grad-CAM và Grad-CAM++ chủ yếu dựa trên bản đồ đặc trưng ở tầng tích chập cuối, Integrated Gradients tập trung vào mức độ đóng góp của điểm ảnh đầu vào đối với kết quả dự đoán. Vì vậy, kỹ thuật này giúp cung cấp một cách nhìn khác về quá trình ra quyết định của mô hình ResNet101. Thay vì chỉ biết vùng nào được mô hình chú ý, người dùng có thể quan sát được mức độ đóng góp của vùng ảnh đó đối với kết quả đầu ra.

Kết quả Integrated Gradients trong hệ thống giúp làm rõ hơn vai trò của các vùng ảnh đối với nhãn dự đoán. Nếu một vùng ảnh có đóng góp cao và nằm trong khu vực phổi, điều đó cho thấy mô hình có thể đã khai thác thông

tin từ vùng này để phân loại ảnh. Ngược lại, nếu vùng đóng góp cao nằm ngoài khu vực phổi hoặc ở vùng nền, kết quả đó cần được xem xét cẩn thận vì mô hình có thể đang học các đặc trưng không mong muốn.

Kỹ thuật Integrated Gradients góp phần tăng khả năng giải thích của hệ thống bằng cách cung cấp thông tin ở mức điểm ảnh hoặc vùng ảnh. Khi kết hợp với Grad-CAM và Grad-CAM++, kỹ thuật này giúp kết quả giải thích trở nên đa chiều hơn, hỗ trợ người dùng quan sát được nhiều khía cạnh khác nhau trong quá trình dự đoán của mô hình.



Hình 4.5. Kết quả giải thích bằng Integrated Gradients

4.3.4 Kết quả giải thích bằng Occlusion

Occlusion là kỹ thuật giải thích dựa trên việc che khuất từng vùng nhỏ của ảnh đầu vào và quan sát sự thay đổi trong xác suất dự đoán của mô hình. Nếu việc che khuất một vùng ảnh làm giảm đáng kể xác suất của lớp dự đoán, vùng đó được xem là có ảnh hưởng quan trọng đến quyết định của mô hình.


Trong hệ thống, Occlusion được áp dụng sau khi mô hình ResNet101 đưa ra kết quả phân loại. Ảnh X-quang đầu vào được chia thành nhiều vùng nhỏ. Hệ thống lần lượt che từng vùng ảnh và đưa ảnh đã bị che vào mô hình để tính lại xác suất dự đoán. Sự thay đổi của xác suất được sử dụng để xác định mức độ quan trọng của từng vùng ảnh.

Kết quả Occlusion giúp người dùng quan sát được vùng ảnh nào khi bị che khuất sẽ làm ảnh hưởng nhiều đến kết quả phân loại. Đối với ảnh X-quang phổi, nếu một vùng trong phổi bị che và xác suất lớp dự đoán giảm mạnh, điều đó cho thấy mô hình đã phụ thuộc nhiều vào thông tin tại vùng này khi đưa ra quyết định. Đây là cách giải thích khá trực quan vì nguyên lý hoạt động dễ hiểu: che một vùng ảnh và kiểm tra phản ứng của mô hình.

Kỹ thuật Occlusion có ưu điểm là dễ diễn giải và không phụ thuộc hoàn toàn vào gradient. Do đó, nó có thể được sử dụng như một cách kiểm tra bổ sung bên cạnh các kỹ thuật Grad-CAM, Grad-CAM++ và Integrated Gradients. Tuy nhiên, Occlusion thường tốn nhiều thời gian xử lý hơn vì hệ thống phải thực hiện nhiều lần

suy luận trên các phiên bản ảnh bị che khuất khác nhau.

Trong phạm vi đề tài, Occlusion được sử dụng nhằm bổ sung thêm một hình thức giải thích trực quan cho kết quả dự đoán của mô hình ResNet101. Kết quả Occlusion giúp người dùng nhận biết những vùng ảnh có vai trò quan trọng đối với mô hình, từ đó hỗ trợ quá trình quan sát và phân tích kết quả trên giao diện web.



Hình 4.6. Kết quả giải thích bằng Occlusion

4.3.5 Kết quả giải thích bằng Grad-CAM

Từ các kết quả giải thích bằng Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion, có thể nhận thấy hệ thống đã cung cấp được nhiều góc nhìn trực quan về quyết định dự đoán của mô hình ResNet101. Thay vì chỉ hiển thị nhãn bệnh và xác suất, hệ thống còn thể hiện các vùng ảnh có ảnh hưởng đến kết quả phân loại.

Grad-CAM giúp tạo bản đồ nhiệt tổng quan, làm nổi bật vùng ảnh mà mô hình tập trung khi dự đoán. Đây là kỹ thuật dễ quan sát và phù hợp để hiển thị nhanh trên giao diện web. Grad-CAM++ tiếp tục hỗ trợ làm rõ hơn các vùng ảnh quan trọng, đặc biệt trong những trường hợp vùng ảnh có ảnh hưởng phân bố ở nhiều vị trí khác nhau.

Integrated Gradients cung cấp thông tin về mức độ đóng góp của các điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Kỹ thuật này giúp bổ sung thêm cách nhìn từ dữ liệu đầu vào, hỗ trợ phân tích xem vùng ảnh nào đóng góp nhiều vào lớp được mô hình dự đoán. Trong khi đó, Occlusion kiểm tra tầm quan trọng của từng vùng ảnh thông qua việc che khuất và quan sát sự thay đổi xác suất. Đây là cách tiếp cận trực quan, dễ hiểu và có giá trị tham khảo khi phân tích phản ứng của mô hình.

Việc sử dụng đồng thời nhiều kỹ thuật giải thích giúp hệ thống có khả năng trình bày kết quả đầy đủ hơn. Mỗi kỹ thuật có cách tiếp cận riêng, do đó kết quả giải thích có thể bổ sung cho nhau. Nếu nhiều kỹ thuật cùng làm nổi bật các vùng tương tự trên ảnh X-quang, điều này cho thấy mô hình có sự tập trung tương đối nhất quán vào các vùng ảnh quan trọng. Ngược lại, nếu các kỹ thuật cho kết quả khác nhau nhiều, người dùng cần xem xét kỹ hơn ảnh đầu vào, kết quả dự đoán và khả năng

mô hình bị ảnh hưởng bởi các đặc trưng không mong muốn.

Trong quá trình quan sát kết quả XAI, các vùng được làm nổi bật cần được hiểu là vùng ảnh có ảnh hưởng đến quyết định của mô hình, không phải là kết luận chắc chắn về vị trí bệnh lý. Điều này đặc biệt quan trọng trong lĩnh vực y tế, vì mô hình AI chỉ đóng vai trò hỗ trợ phân tích và tham khảo. Kết quả giải thích giúp tăng tính minh bạch cho hệ thống, nhưng không thay thế cho đánh giá của bác sĩ hoặc chuyên gia y tế.

Các kết quả giải thích cũng cho thấy việc tích hợp XAI vào hệ thống là cần thiết. Nếu chỉ có nhãn dự đoán, người dùng khó biết mô hình đã dựa vào thông tin nào để phân loại ảnh. Khi có thêm bản đồ nhiệt và bản đồ đóng góp, người dùng có thể quan sát được vùng ảnh mà mô hình sử dụng trong quá trình dự đoán. Điều này giúp hệ thống trở nên dễ hiểu hơn, đặc biệt khi được trình bày trong giao diện web.

Bên cạnh ưu điểm, các kỹ thuật giải thích vẫn có một số hạn chế. Bản đồ nhiệt có thể chưa thể hiện chính xác hoàn toàn vùng tổn thương thực tế. Kết quả giải thích có thể bị ảnh hưởng bởi chất lượng ảnh, độ tương phản, bước tiền xử lý hoặc đặc điểm dữ liệu huấn luyện. Ngoài ra, một số kỹ thuật như Occlusion có thể làm tăng thời gian xử lý do phải thực hiện nhiều lần suy luận. Vì vậy, kết quả XAI cần được sử dụng với vai trò hỗ trợ quan sát, không nên xem là kết luận y khoa độc lập.

Nhìn chung, việc tích hợp Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion đã giúp hệ thống AI hỗ trợ chẩn đoán bệnh phổi từ ảnh X-quang trở nên trực quan và minh bạch hơn. Các kỹ thuật này giúp người dùng quan sát được vùng ảnh có ảnh hưởng đến quyết định phân loại của mô hình ResNet101, đồng thời góp phần giảm tính “hộp đen” của mô hình học sâu. Đây là một phần quan trọng trong đề tài, vì hệ thống không chỉ hướng đến dự đoán bệnh mà còn hỗ trợ giải thích kết quả dự đoán một cách dễ quan sát hơn.

Tóm lại, mục 4.4 đã trình bày kết quả giải thích mô hình bằng bốn kỹ thuật XAI gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Các kết quả này được hiển thị cùng với ảnh X-quang gốc, nhãn bệnh dự đoán và xác suất phân loại trên giao diện web. Qua đó, hệ thống cung cấp thêm thông tin trực quan giúp người dùng hiểu rõ hơn cơ sở dự đoán của mô hình ResNet101 trong bài toán phân loại bệnh phổi từ ảnh X-quang.

4.4 KẾT QUẢ TRIỂN KHAI HỆ THỐNG PHẦN MỀM


4.4.1 Tổng quan hệ thống web

Hệ thống web được xây dựng nhằm cung cấp một môi trường trực quan để người dùng tương tác với mô hình AI. Thay vì chỉ chạy mô hình thông qua mã lệnh hoặc notebook, hệ thống web cho phép người dùng thao tác thông qua trình duyệt. Điều này giúp quá trình thử nghiệm và minh họa kết quả trở nên dễ quan sát hơn.

Về tổng thể, hệ thống gồm ba luồng xử lý chính. Thứ nhất, người dùng tải ảnh X-quang ngực lên giao diện Frontend. Thứ hai, ảnh được gửi đến Backend để kiểm tra, tiền xử lý và đưa vào mô hình ResNet101. Thứ ba, kết quả dự đoán và các hình ảnh giải thích mô hình được gửi ngược lại Frontend để hiển thị cho người dùng.

Backend của hệ thống được xây dựng bằng Flask trên nền tảng Python. Thành phần này có nhiệm vụ tiếp nhận ảnh từ người dùng, xử lý dữ liệu đầu vào, gọi mô hình ResNet101 đã huấn luyện và tạo kết quả giải thích bằng các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Frontend được xây dựng bằng HTML, CSS và JavaScript, giúp người dùng thao tác tải ảnh, gửi yêu cầu phân tích và xem kết quả trực tiếp trên trình duyệt.

Việc triển khai hệ thống web giúp đề tài không chỉ dừng lại ở việc huấn luyện mô hình mà còn thể hiện được khả năng ứng dụng của mô hình vào một quy trình sử dụng thực tế. Thông qua giao diện web, người dùng có thể quan sát toàn bộ quá trình từ ảnh đầu vào đến kết quả dự đoán và giải thích mô hình.



Hình 4.7. Giao diện tổng quan của hệ thống web

4.4.2 Giao diện tải ảnh X-quang

Giao diện tải ảnh X-quang là chức năng đầu tiên người dùng tương tác khi sử dụng hệ thống. Tại giao diện này, người dùng có thể chọn ảnh X-quang ngực từ thiết bị cá nhân và gửi ảnh đến hệ thống để phân tích. Giao diện được thiết kế đơn giản, dễ sử dụng, giúp người dùng nhanh chóng thực hiện thao tác mà không cần cài đặt thêm phần mềm chuyên dụng.

Hệ thống hỗ trợ các định dạng ảnh phổ biến như JPG, JPEG và PNG. Sau khi người dùng chọn ảnh, giao diện có thể hiển thị ảnh xem trước để người dùng kiểm tra lại trước khi gửi đi phân tích. Chức năng này giúp hạn chế trường hợp tải nhầm ảnh hoặc sử dụng ảnh không phù hợp.

Khi người dùng nhấn nút phân tích, ảnh sẽ được gửi từ Frontend đến Backend thông qua API. Trong quá trình chờ xử lý, giao diện có thể hiển thị trạng thái đang phân tích để người dùng biết hệ thống đang thực hiện xử lý ảnh. Sau khi Backend hoàn tất quá trình dự đoán, kết quả sẽ được trả về và hiển thị trên cùng giao diện web.

Giao diện tải ảnh đóng vai trò quan trọng trong việc kết nối người dùng với mô hình AI. Đây là bước đầu tiên trong quy trình xử lý, đảm bảo ảnh đầu vào được tiếp nhận đúng cách và gửi đến Backend để phục vụ quá trình phân loại bệnh phổi.



Hình 4.8. Giao diện tải ảnh X-quang ngược lên hệ thống

4.4.3 Giao diện hiển thị kết quả dự đoán

Sau khi ảnh X-quang được xử lý bởi Backend và mô hình ResNet101, hệ thống sẽ trả về kết quả dự đoán cho người dùng. Giao diện hiển thị kết quả dự đoán được thiết kế nhằm trình bày rõ nhãn bệnh mà mô hình dự đoán, giúp người dùng dễ dàng nhận biết kết quả phân loại.

Kết quả dự đoán chính của hệ thống là lớp bệnh có xác suất cao nhất trong bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Ví dụ, nếu mô hình tính toán xác suất của lớp Pneumonia cao hơn các lớp còn lại, hệ thống sẽ hiển thị kết quả dự đoán là Pneumonia. Kết quả này được trình bày nổi bật trên giao diện để người dùng dễ quan sát.

Bên cạnh nhãn bệnh dự đoán, giao diện cũng có thể hiển thị ảnh X-quang gốc đã được người dùng tải lên. Việc hiển thị đồng thời ảnh đầu vào và nhãn dự đoán giúp người dùng dễ theo dõi mối liên hệ giữa dữ liệu đưa vào và kết quả do hệ thống

trả về.

Giao diện kết quả dự đoán giúp người dùng tiếp cận kết quả phân loại một cách trực quan hơn. Thay vì chỉ nhận kết quả dưới dạng dữ liệu thô, người dùng có thể xem nhãn bệnh dự đoán ngay trên giao diện web, phù hợp với mục tiêu xây dựng hệ thống hỗ trợ phân tích ảnh X-quang phổi.



Hình 4.9. Giao diện hiển thị kết quả dự đoán bệnh phổi


4.4.4 Giao diện hiển thị xác suất phân loại

Ngoài nhãn bệnh dự đoán cuối cùng, hệ thống còn hiển thị xác suất phân loại của từng lớp bệnh. Đây là thành phần quan trọng giúp người dùng quan sát mức độ tin cậy của mô hình đối với từng kết quả. Thay vì chỉ hiển thị một nhãn duy nhất, hệ thống cung cấp thêm thông tin xác suất để kết quả trở nên rõ ràng hơn.

Xác suất phân loại được biểu diễn tương ứng với bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Mỗi lớp có một giá trị xác suất riêng, thể hiện mức độ mô hình đánh giá ảnh đầu vào thuộc về lớp đó. Lớp có xác suất cao nhất sẽ được chọn làm kết quả dự đoán chính.

Việc hiển thị xác suất giúp người dùng đánh giá được mức độ chênh lệch giữa các lớp. Trong trường hợp một lớp có xác suất vượt trội so với các lớp còn lại, kết quả dự đoán có thể được xem là rõ ràng hơn. Ngược lại, nếu xác suất giữa các lớp gần nhau, người dùng có thể nhận thấy rằng mô hình chưa thật sự chắc chắn trong quá trình phân loại.

Giao diện hiển thị xác suất có thể được trình bày dưới dạng bảng hoặc biểu đồ để người dùng dễ quan sát. Các thông tin này góp phần làm tăng tính minh bạch cho hệ thống, đồng thời hỗ trợ quá trình phân tích kết quả thực nghiệm trong đề tài.



Hình 4.10. Giao diện hiển thị xác suất phân loại của bốn lớp bệnh

4.4.5 Giao diện hiển thị kết quả giải thích mô hình

Bên cạnh kết quả phân loại, hệ thống còn hiển thị các hình ảnh giải thích mô hình nhằm giúp người dùng quan sát vùng ảnh có ảnh hưởng đến quyết định dự đoán. Đây là điểm quan trọng của hệ thống, vì mô hình học sâu thường khó giải thích trực tiếp quá trình đưa ra kết quả. Việc tích hợp các kỹ thuật Explainable AI giúp hệ thống trở nên trực quan và minh bạch hơn.

Trong đề tài, các kỹ thuật giải thích được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Sau khi mô hình ResNet101 đưa ra kết quả dự đoán, Backend sẽ áp dụng các kỹ thuật này để tạo ra hình ảnh giải thích tương ứng. Các ảnh giải thích sau đó được gửi về Frontend và hiển thị cùng với ảnh X-quang gốc.

Kết quả Grad-CAM và Grad-CAM++ được thể hiện dưới dạng bản đồ nhiệt, giúp làm nổi bật vùng ảnh mà mô hình tập trung khi đưa ra dự đoán. Integrated Gradients biểu diễn mức độ đóng góp của các vùng ảnh hoặc điểm ảnh đối với kết quả phân loại. Occlusion minh họa ảnh hưởng của từng vùng ảnh bằng cách che khuất một phần ảnh và quan sát sự thay đổi trong xác suất dự đoán.

Giao diện hiển thị kết quả giải thích mô hình cần được bố trí rõ ràng để người dùng có thể so sánh giữa ảnh gốc và các kết quả XAI. Mỗi kỹ thuật giải thích nên được đặt tên cụ thể để tránh nhầm lẫn. Việc hiển thị đồng thời nhiều phương pháp giải thích giúp người dùng có thêm nhiều góc nhìn khi quan sát kết quả dự đoán của mô hình.



Hình 4.11. Giao diện hiển thị kết quả giải thích mô hình bằng Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion


4.4.6 Giao diện lịch sử chẩn đoán

Giao diện lịch sử chẩn đoán được xây dựng nhằm hỗ trợ người dùng theo dõi lại các kết quả phân tích ảnh X-quang đã thực hiện trước đó trên hệ thống. Sau mỗi lần người dùng tải ảnh và thực hiện dự đoán, hệ thống có thể lưu lại các thông tin liên quan đến phiên phân tích, bao gồm ảnh X-quang đầu vào, thời gian thực hiện, nhãn bệnh dự đoán, xác suất phân loại và kết quả giải thích mô hình.

Chức năng lịch sử chẩn đoán giúp người dùng dễ dàng xem lại các lần phân tích trước mà không cần tải lại ảnh hoặc thực hiện dự đoán nhiều lần. Điều này đặc biệt hữu ích trong quá trình thử nghiệm hệ thống, so sánh kết quả giữa nhiều ảnh khác nhau và kiểm tra lại kết quả dự đoán của mô hình ResNet101.

Trên giao diện lịch sử, các bản ghi chẩn đoán có thể được trình bày dưới dạng danh sách hoặc bảng dữ liệu. Mỗi bản ghi hiển thị các thông tin cơ bản như mã hoặc số thứ tự phiên chẩn đoán, tên ảnh, thời gian phân tích, nhãn bệnh được dự đoán và xác suất cao nhất. Khi người dùng chọn một bản ghi cụ thể, hệ thống có thể hiển thị chi tiết ảnh X-quang, kết quả dự đoán của bốn lớp bệnh và các hình ảnh giải thích tương ứng.

Việc bổ sung giao diện lịch sử chẩn đoán giúp hệ thống web trở nên đầy đủ và thuận tiện hơn trong quá trình sử dụng. Người dùng không chỉ thực hiện được chức năng dự đoán bệnh phổi từ ảnh X-quang, mà còn có thể quản lý và tra cứu lại các kết quả đã phân tích. Đây là một thành phần hỗ trợ quan trọng trong việc nâng cao tính thực tế và khả năng sử dụng của hệ thống.



Hình 4.12. Giao diện lịch sử chẩn đoán


4.4.7 Quy trình xử lý thực tế trên hệ thống web

Quy trình xử lý thực tế trên hệ thống web bắt đầu từ thao tác người dùng tải ảnh X-quang ngực lên giao diện. Sau khi ảnh được chọn, Frontend hiển thị ảnh xem trước và gửi ảnh đến Backend khi người dùng yêu cầu phân tích. Backend tiếp nhận ảnh, kiểm tra định dạng và thực hiện các bước tiền xử lý cần thiết.

Ảnh sau khi tiền xử lý được đưa vào mô hình ResNet101 để thực hiện dự đoán. Mô hình trả về vector xác suất tương ứng với bốn lớp bệnh gồm COVID-19, Normal, Pneumonia và Tuberculosis. Backend xác định lớp có xác suất cao nhất làm kết quả dự đoán chính, đồng thời giữ lại xác suất của các lớp còn lại để hiển thị trên giao diện.

Sau bước dự đoán, Backend tiếp tục áp dụng các kỹ thuật giải thích mô hình. Các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion được sử dụng để tạo ra các ảnh giải thích, giúp người dùng quan sát vùng ảnh có ảnh hưởng đến quyết định của mô hình. Các kết quả này được xử lý về định dạng phù hợp và gửi lại cho Frontend.

Cuối cùng, Frontend nhận dữ liệu phản hồi từ Backend và hiển thị kết quả cho người dùng. Kết quả bao gồm ảnh X-quang đầu vào, nhãn bệnh dự đoán, xác suất phân loại của từng lớp và các hình ảnh giải thích mô hình. Quy trình này giúp hệ thống thể hiện đầy đủ chức năng từ tiếp nhận ảnh, dự đoán bệnh phổi đến giải thích kết quả dự đoán.



Hình 4.13. Quy trình xử lý thực tế trên hệ thống web

4.5 THẢO LUẬN VÀ PHÂN TÍCH TỔNG HỢP

Sau khi trình bày kết quả triển khai hệ thống web, kết quả đánh giá mô hình ResNet101 và kết quả giải thích mô hình bằng các kỹ thuật XAI, mục này tiến hành thảo luận và phân tích tổng hợp các kết quả đạt được. Nội dung thảo luận tập trung vào hiệu quả của mô hình ResNet101 trong bài toán phân loại bệnh phổi từ ảnh X-quang, vai trò của các kỹ thuật giải thích mô hình, đóng góp của hệ thống web, các hạn chế còn tồn tại và định hướng phát triển trong tương lai.

Việc phân tích tổng hợp giúp làm rõ hơn ý nghĩa của các kết quả thực nghiệm. Nếu các mục trước chủ yếu trình bày kết quả dưới dạng giao diện, bảng số liệu và hình ảnh giải thích, thì mục này tập trung nhận xét, đánh giá và rút ra các kết luận liên quan đến hiệu quả hoạt động của toàn bộ hệ thống.

4.5.1 Hiệu quả của mô hình ResNet101 trong bài toán phân loại bệnh phổi

Mô hình ResNet101 được sử dụng trong đề tài nhằm phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Kết quả thực nghiệm cho thấy mô hình đạt hiệu quả tương đối tốt thông qua các chỉ số Accuracy, Precision, Recall và F1-score. Các chỉ số này phản ánh khả năng dự đoán tổng thể, độ tin cậy của kết quả dự đoán, khả năng nhận diện đúng các mẫu bệnh và sự cân bằng giữa Precision và Recall.

Accuracy đạt 0.948 cho thấy mô hình có khả năng dự đoán đúng phần lớn các ảnh trong tập kiểm thử. Đây là kết quả tích cực đối với bài toán phân loại ảnh X-quang phổi bốn lớp, vì mô hình không chỉ cần phân biệt ảnh bình thường với ảnh bệnh mà còn phải phân biệt giữa các nhóm bệnh khác nhau. Điều này cho thấy ResNet101 đã học được các đặc trưng hình ảnh có ý nghĩa từ dữ liệu đầu vào

Precision đạt 0.963 cho thấy khi mô hình đưa ra dự đoán một ảnh thuộc một

lớp bệnh cụ thể, khả năng dự đoán đó đúng là khá cao. Đây là chỉ số quan trọng trong hệ thống hỗ trợ phân tích ảnh y tế, vì người dùng cần quan sát được kết quả dự đoán có mức độ tin cậy phù hợp. Precision cao giúp hạn chế tình trạng mô hình dự đoán nhầm ảnh của lớp khác thành lớp bệnh đang xét.

Recall đạt 0.956 cho thấy mô hình có khả năng nhận diện đúng phần lớn các ảnh thật sự thuộc từng lớp bệnh. Trong bài toán y tế, Recall có ý nghĩa quan trọng vì nó phản ánh khả năng phát hiện đúng các trường hợp bệnh. Recall cao cho thấy mô hình hạn chế được tình trạng bỏ sót mẫu thuộc các lớp bệnh trong phạm vi tập kiểm thử.

F1-score đạt 0.959 cho thấy mô hình có sự cân bằng tốt giữa Precision và Recall. Điều này chứng tỏ mô hình không chỉ dự đoán chính xác mà còn có khả năng nhận diện đầy đủ các mẫu thuộc từng lớp. F1-score cao cũng cho thấy mô hình hoạt động ổn định, không bị lệ thuộc quá nhiều vào một chỉ số riêng lẻ.

Kết quả trên cho thấy ResNet101 phù hợp với bài toán phân loại ảnh X-quang phổi trong phạm vi đề tài. Với kiến trúc mạng sâu và cơ chế kết nối tắt, mô hình có khả năng trích xuất các đặc trưng ảnh ở nhiều mức độ khác nhau. Các tầng đầu có thể học các đặc trưng cơ bản như cạnh, đường biên, vùng sáng tối và kết cấu ảnh. Các tầng sâu hơn có thể học các đặc trưng phức tạp hơn liên quan đến cấu trúc vùng phổi hoặc các dấu hiệu bất thường trên ảnh X-quang.

Tuy nhiên, hiệu quả của mô hình vẫn cần được hiểu trong phạm vi dữ liệu thực nghiệm. Khi áp dụng trên ảnh thực tế từ nhiều nguồn khác nhau, kết quả có thể bị ảnh hưởng bởi chất lượng ảnh, thiết bị chụp, tư thế bệnh nhân, độ tương phản và đặc điểm bệnh lý. Vì vậy, mô hình trong đề tài phù hợp với mục tiêu nghiên cứu, thử nghiệm và hỗ trợ tham khảo, chưa thể thay thế cho chẩn đoán chuyên môn của bác sĩ.

4.5.2 Vai trò của các kỹ thuật Explainable AI trong hệ thống

Các kỹ thuật Explainable AI đóng vai trò quan trọng trong việc tăng tính minh bạch cho hệ thống. Nếu hệ thống chỉ đưa ra nhãn bệnh và xác suất dự đoán, người dùng sẽ khó biết mô hình đã dựa vào vùng ảnh nào để đưa ra kết quả. Điều này làm cho mô hình học sâu trở nên khó giải thích, đặc biệt trong lĩnh vực y tế, nơi kết quả phân tích cần có cơ sở trực quan để hỗ trợ đánh giá.

Trong đề tài, bốn kỹ thuật giải thích được sử dụng gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Mỗi kỹ thuật có cách tiếp cận khác nhau nhưng đều hướng đến mục tiêu chung là giúp người dùng quan sát vùng ảnh hoặc đặc trưng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình ResNet101.

Grad-CAM giúp tạo bản đồ nhiệt thể hiện vùng ảnh mà mô hình tập trung khi đưa ra kết quả phân loại. Kết quả này thường được chồng lên ảnh X-quang gốc,

giúp người dùng dễ dàng quan sát khu vực có ảnh hưởng lớn đến quyết định của mô hình. Đây là kỹ thuật trực quan, dễ hiểu và phù hợp để hiển thị trong hệ thống web.

Grad-CAM++ có vai trò bổ sung cho Grad-CAM bằng cách làm rõ hơn các vùng ảnh quan trọng trong một số trường hợp. Khi ảnh có nhiều vùng ảnh hưởng đến kết quả dự đoán, Grad-CAM++ có thể hỗ trợ thể hiện chi tiết hơn các khu vực có đóng góp đến quyết định phân loại. Việc sử dụng cả Grad-CAM và Grad-CAM++ giúp người dùng có thêm cơ sở quan sát và so sánh.

Integrated Gradients cung cấp thông tin về mức độ đóng góp của từng điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Kỹ thuật này giúp phân tích sâu hơn mối liên hệ giữa ảnh đầu vào và đầu ra của mô hình. Thông qua Integrated Gradients, người dùng có thể quan sát những vùng ảnh đóng góp tích cực vào lớp được mô hình dự đoán.

Occlusion là kỹ thuật có cách diễn giải trực quan thông qua việc che khuất từng vùng ảnh và quan sát sự thay đổi xác suất dự đoán. Nếu một vùng ảnh khi bị che làm giảm xác suất của lớp dự đoán, vùng đó có thể được xem là quan trọng đối với mô hình. Cách tiếp cận này giúp kiểm tra phản ứng của mô hình đối với từng khu vực ảnh một cách dễ hiểu.

Việc tích hợp nhiều kỹ thuật XAI giúp hệ thống cung cấp kết quả giải thích dưới nhiều góc nhìn khác nhau. Grad-CAM và Grad-CAM++ tập trung vào bản đồ nhiệt dựa trên đặc trưng của mô hình. Integrated Gradients phân tích mức độ đóng góp từ dữ liệu đầu vào. Occlusion kiểm tra ảnh hưởng của từng vùng ảnh thông qua thao tác che khuất. Nhờ đó, kết quả giải thích trở nên phong phú và trực quan hơn.

Tuy nhiên, cần nhấn mạnh rằng các kỹ thuật XAI không đưa ra kết luận y khoa cuối cùng. Các vùng được làm nổi bật chỉ thể hiện khu vực có ảnh hưởng đến quyết định của mô hình, không khẳng định chắc chắn đó là vùng bệnh lý thật sự. Vì vậy, kết quả XAI cần được xem là thông tin hỗ trợ quan sát, không thay thế cho đánh giá chuyên môn.

4.5.3 Đóng góp của hệ thống web trong quá trình triển khai

Hệ thống web là thành phần giúp đưa mô hình AI từ môi trường lập trình sang một giao diện có thể tương tác trực tiếp với người dùng. Thay vì chỉ chạy mô hình trong notebook hoặc thông qua mã lệnh, người dùng có thể tải ảnh X-quang lên giao diện web, gửi yêu cầu phân tích và nhận kết quả dự đoán một cách trực quan.

Frontend của hệ thống được xây dựng bằng HTML, CSS và JavaScript, đóng vai trò là nơi người dùng thực hiện các thao tác chính như tải ảnh, xem ảnh đầu vào, gửi yêu cầu phân tích và quan sát kết quả. Backend được xây dựng bằng Flask, đảm nhiệm việc tiếp nhận ảnh, kiểm tra dữ liệu, tiền xử lý ảnh, gọi mô hình ResNet101,

tạo ảnh giải thích bằng XAI và trả kết quả về giao diện.

Việc triển khai hệ thống web giúp đề tài thể hiện được quy trình ứng dụng mô hình vào một hệ thống phần mềm hoàn chỉnh. Người dùng không cần thao tác trực tiếp với mã nguồn hoặc mô hình học sâu, mà có thể sử dụng hệ thống thông qua các chức năng được thiết kế sẵn. Điều này làm tăng tính thực tế của đề tài và giúp quá trình demo trở nên dễ hiểu hơn.

Hệ thống web còn hỗ trợ hiển thị nhiều thành phần kết quả cùng lúc, bao gồm ảnh X-quang gốc, nhãn bệnh dự đoán, xác suất của từng lớp và các hình ảnh giải thích mô hình. Cách trình bày này giúp người dùng dễ dàng so sánh giữa ảnh đầu vào và kết quả đầu ra, đồng thời quan sát được vùng ảnh mà mô hình tập trung khi dự đoán.

Ngoài ra, chức năng lịch sử chẩn đoán giúp hệ thống có tính tiện dụng hơn. Sau mỗi lần phân tích, hệ thống có thể lưu lại thông tin về ảnh đầu vào, thời gian phân tích, nhãn dự đoán, xác suất và kết quả giải thích. Người dùng có thể xem lại các lần phân tích trước mà không cần tải lại ảnh hoặc thực hiện lại toàn bộ quy trình.

Nhìn chung, hệ thống web đóng vai trò quan trọng trong việc minh họa khả năng ứng dụng của mô hình ResNet101 và các kỹ thuật XAI. Đây là cầu nối giữa mô hình học sâu và người dùng cuối, giúp kết quả nghiên cứu không chỉ dừng lại ở mức huấn luyện mô hình mà còn được thể hiện thành một sản phẩm phần mềm có thể sử dụng và quan sát trực tiếp.

4.5.4 Phân tích kết quả dự đoán và xác suất phân loại

Kết quả dự đoán của hệ thống được thể hiện thông qua nhãn bệnh có xác suất cao nhất và xác suất của cả bốn lớp bệnh. Việc hiển thị đồng thời nhãn dự đoán và xác suất phân loại giúp người dùng hiểu rõ hơn mức độ tin cậy của mô hình đối với từng kết quả.

Trong bài toán phân loại ảnh X-quang phổi, mô hình ResNet101 tạo ra vector xác suất gồm bốn giá trị tương ứng với bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis. Lớp có xác suất cao nhất được chọn làm kết quả dự đoán cuối cùng. Tuy nhiên, việc hiển thị thêm xác suất của các lớp còn lại là cần thiết vì nó giúp người dùng quan sát sự chênh lệch giữa các khả năng dự đoán.

Nếu một lớp có xác suất vượt trội so với các lớp còn lại, kết quả dự đoán có thể được xem là rõ ràng hơn. Ví dụ, nếu xác suất của lớp Pneumonia cao hơn hẳn ba lớp còn lại, mô hình có mức độ tự tin cao hơn khi dự đoán ảnh thuộc nhóm viêm phổi. Ngược lại, nếu xác suất giữa hai hoặc nhiều lớp gần nhau, điều đó cho thấy mô hình chưa thật sự chắc chắn và kết quả cần được xem xét cẩn thận hơn.

Việc hiển thị xác suất phân loại có ý nghĩa quan trọng trong hệ thống hỗ trợ phân tích ảnh y tế. Người dùng không chỉ nhận được một nhãn bệnh duy nhất mà

còn có thể quan sát được mức độ phân bố xác suất giữa các lớp. Điều này giúp kết quả dự đoán trở nên minh bạch hơn và hỗ trợ quá trình nhận xét kết quả thực nghiệm.

Trong phạm vi đề tài, các lớp bệnh như COVID-19 và Pneumonia có thể có một số đặc điểm hình ảnh tương đồng trên ảnh X-quang, chẳng hạn như vùng mờ hoặc dấu hiệu bất thường trong phổi. Vì vậy, trong một số trường hợp, xác suất giữa các lớp này có thể không chênh lệch quá lớn. Đây là lý do cần kết hợp thêm ma trận nhầm lẫn và kết quả XAI để đánh giá sâu hơn hành vi của mô hình.

Kết quả xác suất cũng hỗ trợ việc thiết kế giao diện hệ thống web. Thay vì chỉ hiển thị một dòng kết quả, hệ thống có thể trình bày xác suất dưới dạng bảng hoặc biểu đồ. Cách trình bày này giúp người dùng dễ quan sát hơn, đồng thời làm cho kết quả phân tích trở nên rõ ràng và có tính trực quan cao hơn.

4.5.5 Phân tích kết quả giải thích mô hình bằng XAI

Kết quả giải thích mô hình bằng XAI giúp bổ sung thông tin trực quan cho kết quả dự đoán của ResNet101. Nếu kết quả dự đoán cho biết mô hình phân loại ảnh thuộc lớp nào, thì kết quả XAI giúp người dùng quan sát được vùng ảnh nào có ảnh hưởng đến quyết định đó.

Grad-CAM và Grad-CAM++ tạo ra bản đồ nhiệt thể hiện vùng ảnh mà mô hình tập trung khi phân loại. Các vùng có màu nổi bật thường được xem là khu vực có ảnh hưởng lớn hơn đến quyết định của mô hình. Trong ảnh X-quang phổi, các vùng này nên tập trung chủ yếu ở khu vực phổi để cho thấy mô hình đang khai thác thông tin phù hợp với bài toán.

Integrated Gradients giúp biểu diễn mức độ đóng góp của các điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Kỹ thuật này có thể cho thấy vùng nào trong ảnh đóng góp nhiều vào lớp được dự đoán. Khi kết hợp với Grad-CAM và Grad-CAM++, Integrated Gradients giúp kết quả giải thích trở nên đa chiều hơn.

Occlusion giúp phân tích vai trò của từng vùng ảnh bằng cách che khuất một phần ảnh và quan sát sự thay đổi xác suất dự đoán. Nếu che một vùng ảnh làm xác suất lớp dự đoán giảm mạnh, vùng đó có thể được xem là có ảnh hưởng quan trọng đến mô hình. Đây là kỹ thuật dễ diễn giải vì nguyên lý hoạt động tương đối trực quan.

Việc so sánh kết quả giữa nhiều kỹ thuật XAI giúp người dùng có thêm cơ sở đánh giá. Nếu nhiều kỹ thuật cùng làm nổi bật những vùng tương tự trên ảnh, có thể nhận xét rằng mô hình có sự tập trung tương đối nhất quán. Ngược lại, nếu các kỹ thuật làm nổi bật các vùng khác nhau, người dùng cần xem xét lại ảnh đầu vào, chất lượng ảnh, kết quả dự đoán và khả năng mô hình bị ảnh hưởng bởi đặc trưng không mong muốn.

Các kết quả XAI cũng giúp phát hiện một số vấn đề tiềm ẩn. Nếu bản đồ

nhật tập trung vào vùng ngoài phổi hoặc vùng nền, điều đó có thể cho thấy mô hình đang học các đặc trưng không liên quan đến bệnh lý. Trong trường hợp này, cần xem xét lại dữ liệu huấn luyện, bước tiền xử lý hoặc cách mô hình học đặc trưng từ ảnh.

Tuy vậy, các bản đồ XAI không nên được xem là bằng chứng chẩn đoán. Chúng chỉ phản ánh vùng ảnh có ảnh hưởng đến quyết định của mô hình, không xác nhận vùng đó là tổn thương thật sự. Đây là điểm cần được nhấn mạnh khi ứng dụng XAI trong lĩnh vực y tế.

Nhìn chung, kết quả giải thích mô hình đã giúp hệ thống trở nên dễ hiểu hơn. Người dùng có thể quan sát ảnh gốc, kết quả dự đoán, xác suất phân loại và các bản đồ giải thích trong cùng một giao diện. Điều này giúp giảm tính “hộp đen” của mô hình học sâu và tăng tính minh bạch cho hệ thống.

4.5.6 Ý nghĩa thực tiễn của hệ thống

Kết quả nghiên cứu cho thấy việc kết hợp mô hình học sâu ResNet101 với các kỹ thuật giải thích mô hình có thể tạo ra một hệ thống hỗ trợ phân loại bệnh phổi từ ảnh X-quang ngực một cách trực quan và dễ quan sát. Hệ thống không chỉ đưa ra kết quả dự đoán lớp bệnh mà còn cung cấp xác suất phân loại và các hình ảnh giải thích, giúp người dùng có thêm cơ sở để xem xét kết quả.

Về mặt thực tiễn, hệ thống có thể hỗ trợ quá trình học tập, nghiên cứu và thử nghiệm các mô hình trí tuệ nhân tạo trong lĩnh vực ảnh y tế. Thông qua giao diện web, người dùng có thể tải ảnh X-quang lên hệ thống, nhận kết quả dự đoán và quan sát vùng ảnh có ảnh hưởng đến quyết định của mô hình. Điều này giúp mô hình AI trở nên dễ tiếp cận hơn so với việc chỉ chạy trong môi trường lập trình hoặc notebook.

Việc tích hợp các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion giúp tăng tính minh bạch cho kết quả dự đoán. Trong các bài toán liên quan đến ảnh y tế, mô hình học sâu thường bị xem là “hộp đen” vì người dùng khó biết mô hình dựa vào thông tin nào để đưa ra kết quả. Các kỹ thuật giải thích trong đề tài giúp trực quan hóa vùng ảnh mà mô hình tập trung, từ đó hỗ trợ người dùng hiểu rõ hơn quá trình phân tích của hệ thống.

Bên cạnh đó, hệ thống web được triển khai với các chức năng như tải ảnh X-quang, hiển thị kết quả dự đoán, hiển thị xác suất phân loại, hiển thị ảnh giải thích mô hình và lưu lịch sử chẩn đoán. Các chức năng này giúp hệ thống có tính ứng dụng hơn trong quá trình demo, kiểm thử và trình bày kết quả nghiên cứu. Người dùng có thể xem lại các lần phân tích trước đó, so sánh kết quả giữa nhiều ảnh và theo dõi quá trình dự đoán của mô hình một cách thuận tiện hơn.

Mặc dù hệ thống hiện tại chỉ phục vụ mục tiêu nghiên cứu và hỗ trợ tham

khảo, kết quả đạt được cho thấy tính khả thi của việc ứng dụng trí tuệ nhân tạo vào phân tích ảnh X-quang phổi. Trong tương lai, nếu được mở rộng dữ liệu, kiểm chứng bởi chuyên gia y tế và cải thiện các chức năng bảo mật, hệ thống có thể phát triển thành công cụ hỗ trợ sàng lọc ban đầu hoặc hỗ trợ tham khảo trong quá trình phân tích ảnh y tế.

Như vậy, ý nghĩa thực tiễn của đề tài nằm ở việc xây dựng được một hệ thống AI có khả năng phân loại ảnh X-quang phổi, hiển thị kết quả trực quan và giải thích được phần nào cơ sở dự đoán của mô hình. Điều này góp phần làm rõ tiềm năng ứng dụng của học sâu và Explainable AI trong lĩnh vực y tế, đồng thời tạo nền tảng cho các nghiên cứu tiếp theo về hệ thống hỗ trợ chẩn đoán bệnh từ ảnh y khoa.

4.6 TỔNG KẾT CHƯƠNG

Chương 4 đã trình bày quá trình triển khai và kết quả thực nghiệm của hệ thống AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang ngực. Nội dung chương tập trung vào kết quả triển khai hệ thống phần mềm, kết quả đánh giá mô hình ResNet101, kết quả giải thích mô hình bằng các kỹ thuật Explainable AI và phần thảo luận tổng hợp về hiệu quả cũng như ý nghĩa thực tiễn của hệ thống.

Trước hết, chương đã trình bày kết quả triển khai hệ thống web với các chức năng chính như tải ảnh X-quang ngực, hiển thị ảnh đầu vào, thực hiện dự đoán bệnh phổi, hiển thị xác suất phân loại, hiển thị kết quả giải thích mô hình và quản lý lịch sử chẩn đoán. Hệ thống được xây dựng với Frontend phục vụ giao tiếp trực tiếp với người dùng và Backend đảm nhiệm việc xử lý ảnh, gọi mô hình ResNet101, tạo kết quả dự đoán, tạo ảnh giải thích và trả dữ liệu về giao diện. Việc triển khai hệ thống web giúp mô hình AI có thể được sử dụng một cách trực quan hơn, thay vì chỉ hoạt động trong môi trường lập trình hoặc notebook.

Tiếp theo, chương đã trình bày kết quả đánh giá mô hình ResNet101 trên tập kiểm thử. Mô hình được đánh giá thông qua các chỉ số Accuracy, Precision, Recall và F1-score. Kết quả thực nghiệm cho thấy mô hình đạt Accuracy là 0.948119, Precision là 0.963359, Recall là 0.956805 và F1-score là 0.959712. Các chỉ số này cho thấy mô hình có khả năng phân loại hiệu quả ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Đồng thời, việc trình bày ma trận nhầm lẫn giúp quan sát chi tiết hơn các trường hợp dự đoán đúng và dự đoán sai giữa các lớp bệnh.

Bên cạnh kết quả phân loại, chương cũng trình bày kết quả giải thích mô hình bằng các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Các kỹ thuật này giúp trực quan hóa những vùng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình ResNet101. Nhờ đó, hệ thống không chỉ đưa ra nhãn bệnh và xác suất phân loại mà còn hỗ trợ người dùng quan sát được vùng ảnh mà mô hình tập trung khi đưa ra kết quả. Đây là thành phần quan trọng giúp tăng tính minh bạch

và giảm tính “hộp đen” của mô hình học sâu.

Phản thảo luận tổng hợp đã phân tích hiệu quả của mô hình ResNet101, vai trò của các kỹ thuật Explainable AI, đóng góp của hệ thống web và ý nghĩa thực tiễn của nghiên cứu. Kết quả cho thấy việc kết hợp mô hình học sâu với các kỹ thuật giải thích mô hình giúp hệ thống không chỉ có khả năng dự đoán bệnh phổi từ ảnh X-quang mà còn cung cấp thêm cơ sở trực quan để người dùng quan sát và đánh giá kết quả. Việc triển khai hệ thống web cũng giúp mô hình trở nên dễ tiếp cận hơn trong quá trình học tập, nghiên cứu, thử nghiệm và demo.

Tóm lại, Chương 4 đã thể hiện kết quả triển khai thực tế của đề tài, từ hệ thống web đến mô hình phân loại và các kỹ thuật giải thích. Các kết quả đạt được cho thấy mô hình ResNet101 có khả năng hỗ trợ phân loại bệnh phổi từ ảnh X-quang, đồng thời các kỹ thuật XAI giúp kết quả dự đoán trở nên trực quan và dễ quan sát hơn. Đây là cơ sở quan trọng để đánh giá mức độ hoàn thành của đề tài và làm nền tảng cho phần kết luận cũng như hướng phát triển trong chương tiếp theo.

CHƯƠNG 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 GIỚI THIỆU CHƯƠNG

Chương 5 trình bày kết luận tổng quát của đề tài “Xây dựng mô hình AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang”. Nội dung chương tập trung tổng kết các kết quả đã đạt được, nêu các đóng góp chính, phân tích những hạn chế còn tồn tại và đề xuất hướng phát triển trong tương lai.

Thông qua các chương trước, đề tài đã trình bày cơ sở lý thuyết, phân tích thiết kế hệ thống, xây dựng mô hình ResNet101, tích hợp các kỹ thuật giải thích mô hình và triển khai hệ thống web. Chương này có vai trò tổng hợp lại toàn bộ quá trình thực hiện, từ đó đánh giá mức độ hoàn thành mục tiêu của đề tài.

5.2 TỔNG KẾT KẾT QUẢ NGHIÊN CỨU

5.2.1 Đối chiếu mục tiêu và kết quả đạt được

Mục tiêu chính của đề tài là xây dựng một hệ thống AI có khả năng hỗ trợ phân loại bệnh phổi từ ảnh X-quang ngực, đồng thời tích hợp các kỹ thuật giải thích mô hình nhằm giúp người dùng quan sát cơ sở dự đoán của mô hình học sâu. Để thực hiện mục tiêu này, đề tài đã sử dụng mô hình ResNet101 cho bài toán phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis.

Về mục tiêu xây dựng mô hình phân loại, đề tài đã hoàn thành việc thiết kế, huấn luyện và đánh giá mô hình ResNet101 trên bộ dữ liệu ảnh X-quang phổi. Mô hình nhận đầu vào là ảnh X-quang ngực đã được tiền xử lý với kích thước $224 \times 224 \times 3$ và tạo ra đầu ra là vector xác suất tương ứng với bốn lớp bệnh. Lớp có xác suất cao nhất được chọn làm kết quả dự đoán cuối cùng.

Về mục tiêu đánh giá mô hình, đề tài đã sử dụng các chỉ số Accuracy, Precision, Recall và F1-score để đánh giá hiệu quả phân loại. Kết quả thực nghiệm cho thấy mô hình đạt Accuracy là 0.948119, Precision là 0.963359, Recall là 0.956805 và F1-score là 0.959712. Các chỉ số này cho thấy mô hình ResNet101 có khả năng phân loại tương đối tốt ảnh X-quang phổi trong phạm vi bộ dữ liệu thực nghiệm.

Về mục tiêu giải thích mô hình, đề tài đã tích hợp bốn kỹ thuật Explainable AI gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion. Các kỹ thuật này giúp trực quan hóa hoặc phân tích những vùng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình. Nhờ đó, hệ thống không chỉ hiển thị nhãn bệnh và xác suất dự đoán, mà còn cung cấp thêm hình ảnh giải thích để người dùng quan sát vùng ảnh mà mô hình tập trung.

Về mục tiêu triển khai hệ thống phần mềm, đề tài đã xây dựng hệ thống web

gồm Frontend và Backend. Frontend hỗ trợ người dùng tải ảnh X-quang, xem ảnh đầu vào, nhận kết quả dự đoán và quan sát các hình ảnh giải thích mô hình. Backend được xây dựng bằng Flask, có nhiệm vụ tiếp nhận ảnh, tiền xử lý ảnh, gọi mô hình ResNet101, tạo kết quả XAI và trả dữ liệu về giao diện. Hệ thống cũng bổ sung giao diện lịch sử chẩn đoán nhằm hỗ trợ người dùng xem lại các lần phân tích trước đó.

Nhìn chung, đề tài đã hoàn thành các mục tiêu chính đã đề ra. Hệ thống có khả năng tiếp nhận ảnh X-quang ngực, phân loại ảnh vào một trong bốn lớp bệnh, hiển thị xác suất dự đoán và cung cấp kết quả giải thích mô hình. Đây là cơ sở quan trọng để chứng minh tính khả thi của việc kết hợp mô hình học sâu và Explainable AI trong bài toán hỗ trợ phân tích ảnh X-quang phổi.

5.2.2 Tổng kết kết quả thực nghiệm cốt lõi

Kết quả thực nghiệm cho thấy mô hình ResNet101 đạt hiệu quả tốt trên tập kiểm thử. Accuracy đạt 0.948, cho thấy mô hình dự đoán đúng phần lớn các ảnh trong tập kiểm thử. Precision đạt 0.963, thể hiện các dự đoán của mô hình có độ tin cậy cao. Recall đạt 0.9568, cho thấy mô hình nhận diện được phần lớn các ảnh thật sự thuộc từng lớp bệnh. F1-score đạt 0.959, phản ánh sự cân bằng tốt giữa Precision và Recall.

Các kết quả này cho thấy ResNet101 có khả năng trích xuất đặc trưng hiệu quả từ ảnh X-quang phổi. Với cơ chế residual connection, mô hình có thể học các đặc trưng hình ảnh ở nhiều mức độ khác nhau, từ các đặc trưng cơ bản như cạnh, vùng sáng tối, kết cấu ảnh đến các đặc trưng phức tạp hơn liên quan đến vùng phổi hoặc dấu hiệu bất thường.

Bên cạnh kết quả phân loại, các kỹ thuật giải thích mô hình cũng cho thấy vai trò quan trọng trong việc tăng tính trực quan cho hệ thống. Grad-CAM và Grad-CAM++ giúp tạo bản đồ nhiệt thể hiện vùng ảnh mà mô hình tập trung. Integrated Gradients giúp phân tích mức độ đóng góp của điểm ảnh hoặc vùng ảnh đối với kết quả dự đoán. Occlusion giúp đánh giá tầm quan trọng của từng vùng ảnh thông qua việc che khuất và quan sát sự thay đổi xác suất dự đoán.

Hệ thống web đã minh họa được quy trình sử dụng thực tế của mô hình. Người dùng có thể tải ảnh X-quang lên giao diện, gửi ảnh đến Backend để xử lý, nhận kết quả dự đoán và quan sát các ảnh giải thích mô hình. Việc triển khai hệ thống web giúp kết quả nghiên cứu không chỉ dừng lại ở mức huấn luyện mô hình mà còn được thể hiện thành một sản phẩm phần mềm có thể sử dụng và trình bày trực quan.

5.2.3 Mức độ hoàn thành các chức năng của hệ thống

Hệ thống đã hoàn thành các chức năng chính phục vụ cho mục tiêu nghiên cứu. Chức năng tải ảnh X-quang cho phép người dùng chọn ảnh từ thiết bị cá nhân

và gửi ảnh đến hệ thống. Chức năng tiền xử lý ảnh giúp chuẩn hóa ảnh đầu vào về kích thước và định dạng phù hợp với mô hình ResNet101. Chức năng dự đoán bệnh phổi giúp phân loại ảnh thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis.

Chức năng hiển thị xác suất phân loại giúp người dùng quan sát mức độ tin cậy của mô hình đối với từng lớp bệnh. Đây là thành phần quan trọng vì người dùng không chỉ biết kết quả cuối cùng mà còn có thể xem sự phân bố xác suất giữa các lớp. Nếu xác suất của lớp dự đoán cao hơn rõ rệt so với các lớp còn lại, kết quả dự đoán có thể được xem là rõ ràng hơn. Nếu xác suất giữa các lớp gần nhau, người dùng có thêm cơ sở để xem xét kỹ kết quả.

Chức năng giải thích mô hình giúp hệ thống trực quan hơn. Thông qua các ảnh Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion, người dùng có thể quan sát vùng ảnh có ảnh hưởng đến quyết định dự đoán của mô hình. Điều này góp phần giảm tính “hộp đen” của mô hình học sâu và tăng khả năng kiểm tra trực quan khi sử dụng hệ thống.

Chức năng lịch sử chẩn đoán giúp hệ thống có tính tiện dụng hơn trong quá trình thử nghiệm. Sau mỗi lần phân tích, hệ thống có thể lưu lại các thông tin như ảnh đầu vào, thời gian phân tích, nhãn dự đoán, xác suất và kết quả giải thích. Người dùng có thể xem lại các lần phân tích trước mà không cần thực hiện lại toàn bộ quy trình.

Từ các chức năng đã triển khai, có thể thấy hệ thống đáp ứng được yêu cầu cơ bản của một ứng dụng AI hỗ trợ phân tích ảnh X-quang phổi trong phạm vi đề tài. Hệ thống có khả năng xử lý ảnh đầu vào, đưa ra kết quả dự đoán, hiển thị xác suất và cung cấp hình ảnh giải thích mô hình.

5.3 CÁC ĐÓNG GÓP CỦA ĐỀ TÀI

5.3.1 Đóng góp về mặt học thuật

Về mặt học thuật, đề tài đã vận dụng kiến thức về học sâu, xử lý ảnh và trí tuệ nhân tạo có khả năng giải thích vào bài toán phân loại bệnh phổi từ ảnh X-quang. Mô hình ResNet101 được sử dụng để trích xuất đặc trưng và phân loại ảnh X-quang ngực thành bốn lớp bệnh. Việc áp dụng ResNet101 giúp đề tài khai thác được khả năng học đặc trưng sâu của mạng nơ-ron tích chập trong lĩnh vực ảnh y tế.

Đề tài cũng góp phần làm rõ vai trò của các kỹ thuật Explainable AI trong bài toán phân loại ảnh X-quang. Thay vì chỉ đánh giá mô hình bằng các chỉ số định lượng, đề tài còn tích hợp các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion để giải thích kết quả dự đoán. Điều này giúp người nghiên cứu quan sát được vùng ảnh có ảnh hưởng đến quyết định của mô hình, từ đó hiểu rõ hơn cách mô hình phản ứng với ảnh đầu vào.

Ngoài ra, đề tài đã trình bày một quy trình tương đối đầy đủ cho việc xây dựng hệ thống AI trong ảnh y tế, bao gồm chuẩn bị dữ liệu, tiền xử lý ảnh, thiết kế mô hình, đánh giá kết quả, tích hợp XAI và triển khai hệ thống web. Quy trình này có thể được sử dụng làm tài liệu tham khảo cho các nghiên cứu hoặc đồ án tương tự trong lĩnh vực phân loại ảnh y tế bằng học sâu.

5.3.2 Đóng góp về mặt thực tiễn

Về mặt thực tiễn, đề tài đã xây dựng được một hệ thống web có khả năng tiếp nhận ảnh X-quang ngực và trả về kết quả phân tích trực quan. Người dùng có thể thao tác thông qua giao diện web mà không cần chạy mã nguồn trực tiếp. Điều này giúp mô hình học sâu trở nên dễ tiếp cận hơn trong quá trình thử nghiệm và demo.

Hệ thống cung cấp kết quả dự đoán bệnh phổi cùng với xác suất của từng lớp bệnh. Cách trình bày này giúp người dùng quan sát được mức độ tin cậy của mô hình đối với từng khả năng phân loại. Việc hiển thị xác suất cũng giúp kết quả dự đoán trở nên minh bạch hơn so với việc chỉ hiển thị một nhãn bệnh duy nhất.

Việc tích hợp các kỹ thuật XAI giúp hệ thống hỗ trợ quan sát vùng ảnh mà mô hình tập trung khi đưa ra quyết định. Đây là điểm có ý nghĩa thực tiễn vì trong các hệ thống AI liên quan đến ảnh y tế, người dùng thường cần có thêm cơ sở trực quan để xem xét kết quả. Dù kết quả XAI không thay thế cho chẩn đoán y khoa, nó vẫn giúp quá trình phân tích và trình bày kết quả trở nên dễ hiểu hơn.

Chức năng lịch sử chẩn đoán cũng góp phần nâng cao tính tiện dụng của hệ thống. Người dùng có thể xem lại các kết quả đã phân tích, so sánh nhiều ảnh khác nhau và theo dõi thông tin từng phiên chẩn đoán. Đây là bước bổ sung cần thiết để hệ thống web trở nên hoàn chỉnh hơn trong phạm vi đồ án.

5.4 HẠN CHẾ CỦA NGHIÊN CỨU

5.4.1 Hạn chế về dữ liệu

Hạn chế đầu tiên của đề tài liên quan đến phạm vi dữ liệu. Bộ dữ liệu sử dụng trong đề tài chỉ tập trung vào bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Trong thực tế, bệnh lý phổi có nhiều dạng khác nhau và có thể có biểu hiện phức tạp hơn trên ảnh X-quang. Vì vậy, hệ thống hiện tại chỉ phù hợp với phạm vi bốn lớp đã được huấn luyện.

Ngoài ra, dữ liệu ảnh X-quang có thể khác nhau về nguồn thu thập, thiết bị chụp, chất lượng ảnh, độ sáng, độ tương phản và tư thế bệnh nhân. Những yếu tố này có thể ảnh hưởng đến khả năng tổng quát hóa của mô hình khi áp dụng trên dữ liệu thực tế từ nhiều nguồn khác nhau.

Một hạn chế khác là sự khác biệt về số lượng ảnh giữa các lớp có thể ảnh hưởng đến hiệu quả huấn luyện. Nếu một lớp có số lượng ảnh nhiều hơn các lớp còn

lại, mô hình có thể học tốt hơn lớp đó và gặp khó khăn hơn với lớp có ít dữ liệu. Vì vậy, việc cân bằng dữ liệu và mở rộng tập dữ liệu là hướng cần được xem xét trong tương lai.

5.4.2 Hạn chế về mô hình

Mô hình ResNet101 đạt kết quả tốt trong phạm vi thực nghiệm, tuy nhiên vẫn có thể xảy ra nhầm lẫn trong một số trường hợp. Các bệnh lý như COVID-19 và Pneumonia có thể có một số biểu hiện tương đồng trên ảnh X-quang, chẳng hạn như vùng mờ hoặc dấu hiệu bất thường trong phổi. Điều này có thể khiến mô hình gặp khó khăn khi phân biệt các ảnh có đặc trưng không rõ ràng.

Mô hình cũng có thể bị ảnh hưởng bởi chất lượng tiền xử lý ảnh. Nếu ảnh đầu vào quá mờ, nhiễu, thiếu vùng phổi hoặc không đúng loại ảnh X-quang ngực, kết quả dự đoán có thể không ổn định. Do đó, cần có thêm bước kiểm tra chất lượng ảnh trước khi đưa vào mô hình.

Ngoài ra, mô hình hiện tại chỉ thực hiện phân loại ảnh toàn cục. Hệ thống chưa thực hiện phát hiện chính xác vị trí tổn thương hoặc phân đoạn vùng bất thường trên ảnh. Vì vậy, kết quả đầu ra chỉ dừng lại ở mức nhận bệnh, xác suất dự đoán và ảnh giải thích mô hình, chưa cung cấp được thông tin định lượng về vị trí hoặc kích thước vùng tổn thương.

5.4.3 Hạn chế về kỹ thuật giải thích mô hình

Các kỹ thuật Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion giúp hệ thống trực quan hơn, tuy nhiên các kết quả giải thích vẫn có hạn chế. Bản đồ nhiệt hoặc bản đồ đóng góp chỉ phản ánh vùng ảnh có ảnh hưởng đến quyết định của mô hình, không khẳng định chắc chắn vùng đó là vùng bệnh lý thật sự.

Trong một số trường hợp, vùng ảnh được làm nổi bật có thể không hoàn toàn trùng với khu vực mà chuyên gia y tế quan tâm. Điều này có thể xảy ra khi mô hình học phải các đặc trưng không mong muốn từ dữ liệu, chẳng hạn như vùng nền, ký hiệu trên ảnh hoặc khác biệt do nguồn dữ liệu. Vì vậy, kết quả XAI cần được xem là công cụ hỗ trợ quan sát, không phải bằng chứng chẩn đoán.

Ngoài ra, một số kỹ thuật giải thích có thể làm tăng thời gian xử lý. Đặc biệt, Occlusion cần thực hiện nhiều lần suy luận trên các phiên bản ảnh bị che khuất khác nhau, nên có thể tốn thời gian hơn so với Grad-CAM hoặc Grad-CAM++. Khi triển khai trên hệ thống web, yếu tố thời gian phản hồi cần được cân nhắc để đảm bảo trải nghiệm người dùng.

5.4.4 Hạn chế về hệ thống triển khai

Hệ thống web đã triển khai được các chức năng chính, tuy nhiên vẫn chủ yếu phục vụ mục tiêu nghiên cứu, thử nghiệm và demo. Một số chức năng cần thiết cho

môi trường thực tế như quản lý người dùng nâng cao, phân quyền truy cập, bảo mật dữ liệu y tế, kiểm soát nhật ký hoạt động và chuẩn hóa quy trình lưu trữ hồ sơ chưa được phát triển đầy đủ.

Hệ thống hiện tại cũng chưa được kiểm thử trên quy mô lớn với nhiều người dùng đồng thời. Nếu triển khai thực tế, cần đánh giá thêm khả năng chịu tải, tốc độ phản hồi và độ ổn định của Backend khi xử lý nhiều yêu cầu phân tích ảnh. Đây là yếu tố quan trọng nếu hệ thống được mở rộng từ mức demo sang mức ứng dụng thật.

Ngoài ra, hệ thống chưa được tích hợp với các hệ thống quản lý y tế hoặc cơ sở dữ liệu bệnh viện. Vì vậy, kết quả phân tích hiện chỉ phục vụ mục đích hiển thị và lưu trữ trong phạm vi hệ thống, chưa thể liên thông với quy trình khám chữa bệnh thực tế.

5.5 HƯỚNG PHÁT TRIỂN

5.5.1 Mở rộng bộ dữ liệu và số lớp bệnh

Trong tương lai, hệ thống có thể được phát triển bằng cách mở rộng bộ dữ liệu huấn luyện. Việc bổ sung thêm ảnh X-quang từ nhiều nguồn khác nhau giúp mô hình học được các đặc trưng đa dạng hơn, từ đó cải thiện khả năng tổng quát hóa trên dữ liệu thực tế. Dữ liệu mở rộng cần được kiểm tra chất lượng và gán nhãn chính xác để đảm bảo độ tin cậy trong quá trình huấn luyện.

Bên cạnh việc tăng số lượng ảnh, có thể mở rộng thêm số lớp bệnh phổi. Hiện tại, hệ thống tập trung vào bốn lớp COVID-19, Normal, Pneumonia và Tuberculosis. Nếu có dữ liệu phù hợp, hệ thống có thể bổ sung thêm các nhóm bệnh khác để tăng tính ứng dụng. Tuy nhiên, việc mở rộng lớp bệnh cần được thực hiện cẩn thận, vì số lớp càng nhiều thì bài toán phân loại càng phức tạp và yêu cầu dữ liệu càng cao.

5.5.2 Cải thiện chất lượng tiền xử lý và kiểm tra ảnh đầu vào

Một hướng phát triển quan trọng là bổ sung chức năng kiểm tra chất lượng ảnh đầu vào. Hệ thống có thể kiểm tra ảnh có đúng là ảnh X-quang ngực hay không, ảnh có bị lỗi, quá mờ, quá tối hoặc không thể đọc được hay không. Nếu ảnh không phù hợp, hệ thống có thể hiển thị cảnh báo để người dùng chọn ảnh khác.

Ngoài ra, có thể cải thiện quy trình tiền xử lý ảnh bằng các kỹ thuật chuẩn hóa độ sáng, cân bằng tương phản hoặc giảm nhiễu. Tuy nhiên, các bước tiền xử lý cần được lựa chọn cẩn thận để không làm mất đi đặc trưng quan trọng trên ảnh X-quang. Việc cải thiện tiền xử lý có thể giúp mô hình hoạt động ổn định hơn trên ảnh từ nhiều nguồn khác nhau.

5.5.3 Tối ưu mô hình và nâng cao hiệu quả phân loại

Trong tương lai, mô hình ResNet101 có thể được tối ưu thêm về tham số

huấn luyện, tốc độ suy luận và khả năng tổng quát hóa. Có thể thử nghiệm thêm các chiến lược như fine-tuning sâu hơn, điều chỉnh learning rate, tăng cường dữ liệu hợp lý hoặc áp dụng các kỹ thuật regularization để hạn chế quá khớp.

Ngoài ra, có thể nghiên cứu thêm các phương pháp cải thiện hiệu quả mô hình như cân bằng dữ liệu, xử lý mất cân bằng lớp hoặc sử dụng thêm các tiêu chí đánh giá theo từng lớp. Việc phân tích kỹ hơn các lớp dễ bị nhầm lẫn cũng giúp xác định hướng cải thiện phù hợp cho mô hình.

Khi triển khai trên hệ thống web, tốc độ suy luận cũng là yếu tố cần quan tâm. Có thể tối ưu mô hình để giảm thời gian xử lý, chẳng hạn như chuyển đổi định dạng mô hình, sử dụng GPU hoặc tối ưu quy trình tiền xử lý và dự đoán. Điều này giúp hệ thống phản hồi nhanh hơn khi người dùng tải ảnh lên phân tích.

5.5.4 Nâng cấp các kỹ thuật giải thích mô hình

Các kỹ thuật XAI hiện tại đã giúp hệ thống trực quan hơn, tuy nhiên vẫn có thể tiếp tục được cải thiện. Trong tương lai, hệ thống có thể bổ sung thêm các phương pháp giải thích khác hoặc cải thiện cách hiển thị kết quả XAI trên giao diện. Việc so sánh kết quả giữa nhiều kỹ thuật giải thích cũng có thể được trình bày rõ ràng hơn để người dùng dễ quan sát.

Đối với Occlusion, có thể tối ưu kích thước vùng che hoặc số lần suy luận nhằm giảm thời gian xử lý. Đối với Grad-CAM và Grad-CAM++, có thể cải thiện cách chồng bản đồ nhiệt lên ảnh gốc để vùng ảnh quan trọng hiển thị rõ hơn nhưng không làm che mất cấu trúc ảnh X-quang. Đối với Integrated Gradients, có thể điều chỉnh cách trực quan hóa để kết quả dễ đọc hơn với người dùng phổ thông.

Ngoài ra, có thể bổ sung phần chú thích giải thích ý nghĩa từng bản đồ XAI ngay trên giao diện web. Điều này giúp người dùng hiểu rõ hơn rằng các vùng được làm nổi bật là vùng có ảnh hưởng đến mô hình, không phải kết luận chắc chắn về vị trí tổn thương.

5.5.5 Hoàn thiện hệ thống web và lịch sử chẩn đoán

Hệ thống web có thể được phát triển thêm nhiều chức năng để tăng tính hoàn chỉnh. Trước hết, giao diện người dùng có thể được cải thiện về bố cục, màu sắc, khả năng hiển thị kết quả và trải nghiệm thao tác. Các khu vực như ảnh đầu vào, kết quả dự đoán, xác suất phân loại và ảnh XAI cần được sắp xếp rõ ràng để người dùng dễ quan sát.

Chức năng lịch sử chẩn đoán cũng có thể được nâng cấp. Hệ thống có thể cho phép người dùng xem lại các lần phân tích trước, tìm kiếm theo thời gian, lọc theo nhãn bệnh dự đoán và xem chi tiết từng kết quả. Ngoài ra, có thể bổ sung chức năng xóa lịch sử, tải lại ảnh đã phân tích hoặc so sánh nhiều kết quả chẩn đoán với nhau.

Nếu hệ thống phát triển theo hướng nhiều người dùng, cần bổ sung chức năng đăng nhập, quản lý tài khoản và phân quyền truy cập. Mỗi người dùng có thể có lịch sử chẩn đoán riêng, giúp dữ liệu được quản lý rõ ràng và an toàn hơn.

5.5.6 Định hướng ứng dụng trong môi trường thực tế

Nếu muốn phát triển hệ thống theo hướng ứng dụng thực tế, cần có sự đánh giá và kiểm chứng từ chuyên gia y tế. Mô hình cần được thử nghiệm trên bộ dữ liệu lớn hơn, đa dạng hơn và phản ánh tốt hơn điều kiện thực tế. Ngoài ra, kết quả dự đoán cần được so sánh với đánh giá của bác sĩ hoặc chuyên gia chẩn đoán hình ảnh để xác định mức độ tin cậy.

Bên cạnh đó, các vấn đề về bảo mật và quyền riêng tư dữ liệu cần được quan tâm nghiêm túc. Ảnh X-quang và thông tin người dùng là dữ liệu nhạy cảm, vì vậy hệ thống cần có cơ chế bảo vệ dữ liệu, kiểm soát truy cập và lưu trữ an toàn nếu triển khai trong môi trường y tế.

Trong phạm vi hiện tại, hệ thống phù hợp với mục tiêu học tập, nghiên cứu và demo. Tuy nhiên, với các hướng phát triển phù hợp, hệ thống có thể được mở rộng thành công cụ hỗ trợ phân tích ảnh X-quang phổi, phục vụ cho nghiên cứu AI y tế hoặc hỗ trợ tham khảo trong các tình huống cần phân tích ảnh ban đầu.

5.6 KẾT LUẬN CHUNG

Đề tài “Xây dựng mô hình AI hỗ trợ chẩn đoán và giải thích bệnh phổi từ ảnh X-quang” đã hoàn thành các mục tiêu cơ bản đặt ra. Hệ thống đã xây dựng được mô hình ResNet101 để phân loại ảnh X-quang phổi thành bốn lớp gồm COVID-19, Normal, Pneumonia và Tuberculosis. Mô hình đạt kết quả thực nghiệm tích cực với Accuracy, Precision, Recall và F1-score ở mức cao trong phạm vi tập dữ liệu kiểm thử.

Bên cạnh kết quả phân loại, đề tài đã tích hợp các kỹ thuật Explainable AI gồm Grad-CAM, Grad-CAM++, Integrated Gradients và Occlusion nhằm hỗ trợ giải thích quyết định dự đoán của mô hình. Các kỹ thuật này giúp người dùng quan sát được vùng ảnh hoặc đặc trưng ảnh có ảnh hưởng đến kết quả phân loại, từ đó tăng tính trực quan và minh bạch cho hệ thống.

Đề tài cũng đã triển khai hệ thống web với các chức năng chính như tải ảnh X-quang, dự đoán bệnh phổi, hiển thị xác suất phân loại, hiển thị kết quả giải thích mô hình và lưu lịch sử chẩn đoán. Hệ thống web giúp mô hình AI có thể được sử dụng một cách trực quan hơn, phù hợp với mục tiêu demo, nghiên cứu và học tập.

Mặc dù vẫn còn một số hạn chế về dữ liệu, phạm vi lớp bệnh, khả năng tổng quát hóa, thời gian xử lý XAI và mức độ hoàn thiện của hệ thống web, kết quả đạt được cho thấy đề tài có tính khả thi và có thể tiếp tục phát triển trong tương lai. Với việc mở rộng dữ liệu, cải thiện mô hình, tối ưu kỹ thuật giải thích và nâng cấp hệ

thống web, đề tài có thể trở thành nền tảng cho các nghiên cứu tiếp theo về ứng dụng trí tuệ nhân tạo có khả năng giải thích trong phân tích ảnh y tế.

TÀI LIỆU THAM KHẢO

- [1] Khiem, N. M., Quyen, P. N., Quang, T. D., & Anh-Khoi, N. H. (2026). Leveraging deep learning for lung disease diagnosis and classification through X-ray imaging. In N. Goyal, T. N. Nguyen, M. Lata, & G. A. Ogunmola (Eds.), *Proceedings of the International Conference on Sustainable Computing, ICSC 2025. Lecture Notes in Electrical Engineering*, 1530. Springer, Singapore. https://doi.org/10.1007/978-981-95-6063-9_16
- [2] Kiche, J., Mwaniki, I., Orowe, I., & Weke, P. (2024). Classification of pneumonia, tuberculosis and COVID-19 from chest X-ray images using convolution neural network model. *International Journal of Statistics and Probability*, 13(4), 42–63. <https://doi.org/10.5539/ijsp.v13n4p42>
- [3] Kabir, M. M., Mridha, M. F., Rahman, A., Hamid, M. A., & Monowar, M. M. (2024). Detection of COVID-19, pneumonia, and tuberculosis from radiographs using AI-driven knowledge distillation. *Heliyon*, 10(5), e26801. <https://doi.org/10.1016/j.heliyon.2024.e26801>
- [4] Jain, R., Bekele, S. K., Palaniappan, D., Parmar, K., P, R. B., & Trivedi, A. M. (2025). Detection of COVID-19, pneumonia, and tuberculosis using convolutional neural networks and ensemble of deep learning architectures. *ASEAN Journal of Science and Technology Report*, 28(1), e253662. <https://doi.org/10.55164/ajstr.v28i1.253662>
- [5] Bhandari, M., Shahi, T. B., Siku, B., & Neupane, A. (2022). Explanatory classification of CXR images into COVID-19, pneumonia and tuberculosis using deep learning and XAI. *Computers in Biology and Medicine*, 150, 106156. <https://doi.org/10.1016/j.compbiomed.2022.106156>
- [6] Patel, A. N., Murugan, R., Srivastava, G., Maddikunta, P. K. R., Yenduri, G., Gadekallu, T. R., & Chengoden, R. (2024). An explainable transfer learning framework for multi-classification of lung diseases in chest X-rays. *Alexandria Engineering Journal*, 98, 328–343. <https://doi.org/10.1016/j.aej.2024.04.072>
- [7] Sarker, S., Refat, S. R., Preotee, F. F., Shawon, T. R., & Tanvir, R. (2025). Comprehensive lung disease detection using deep learning models and hybrid chest X-ray data with explainable AI. *arXiv preprint arXiv:2505.16028*. <https://arxiv.org/abs/2505.16028>
- [8] Shah, S. T. H., Ashraf, M., et al. (2024). Data-driven classification and explainable-AI in the field of lung disease classification: A review. *Frontiers in Big Data*, 7, 1393758. <https://doi.org/10.3389/fdata.2024.1393758>
- [9] Ifty, T. T., Shafin, S. A., Shahriar, S. M., & Towhid, T. (2024). Explainable lung disease classification from chest X-ray images utilizing deep learning and XAI. *arXiv preprint arXiv:2404.11428*. <https://arxiv.org/abs/2404.11428>
- [10] Naz, Z., Khan, M. A., Tariq, U., Armghan, A., Alenezi, F., & Kadry, S. (2023). An explainable AI-enabled framework for interpreting pulmonary diseases from chest radiographs. *Frontiers in Medicine*, 9, 1116756. <https://doi.org/10.3389/fmed.2022.1116756>

- [11] Ihongbe, I. E., Fouad, H., Mahmoud, A., Elsayed, A., et al. (2024). Evaluating explainable artificial intelligence techniques in chest radiology imaging through a human-centered lens. PLOS ONE, 19(10), e0308758. <https://doi.org/10.1371/journal.pone.0308758>
- [12] Chatterjee, S., Saad, F., Sarasaen, C., Ghosh, S., Krug, V., Khatun, R., Mishra, R., Desai, N., Radeva, P., Rose, G., Stober, S., Speck, O., & Nürnberger, A. (2024). Exploration of interpretability techniques for deep COVID-19 classification using chest X-ray images. Journal of Imaging, 10(2), 45. <https://doi.org/10.3390/jimaging10020045>
- [13] Sufian, M. A., Ghosh, A., Sadi, M. S., et al. (2024). AI-driven thoracic X-ray diagnostics: Transformative transfer learning and explainable AI for chest disease classification. Journal of Personalized Medicine, 14(8), 856. <https://doi.org/10.3390/jpm14080856>
- [14] Termritthikun, C., Umer, A., Suwanwimolkul, S., Xia, F., & Lee, I. (2023). Explainable knowledge distillation for on-device chest X-ray classification. arXiv preprint arXiv:2305.06244. <https://arxiv.org/abs/2305.06244>
- [15] Rafferty, A., Ramaesh, R., & Rajan, A. (2024). Transparent and clinically interpretable AI for lung cancer detection in chest X-rays. arXiv preprint arXiv:2403.19444. <https://arxiv.org/abs/2403.19444>
- [16] Sriramkumar, R., et al. (2025). An explainable deep transfer learning approach with ensemble technique for chest X-ray classification. Telehealth and Medicine Today.
- [17] Rahman, T. (2021). Tuberculosis (TB) chest X-ray database. Kaggle. <https://www.kaggle.com/datasets/tawsifurrahman/tuberculosis-tb-chest-xray-dataset>
- [18] Jtiptj. (2020). Chest X-Ray: Pneumonia, COVID-19, Tuberculosis. Kaggle. <https://www.kaggle.com/datasets/jtiptj/chest-xray-pneumoniacovid19tuberculosis>
- [19] Mooney, P. (2018). Chest X-Ray Images (Pneumonia). Kaggle. <https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia>
- [20] TensorFlow. (2024). ResNet and ResNetV2 applications. TensorFlow Keras Applications Documentation. https://www.tensorflow.org/api_docs/python/tf/keras/applications
- [21] Flask. (2024). Uploading files. Flask Documentation. <https://flask.palletsprojects.com/en/stable/patterns/fileuploads/>
- [22] Pham, N. N., Trang, P. T. X., Thuy, T. T., & Khoi, N. H. A. (2023). Predicting edible and toxic mushrooms with multi-layer perceptron method in streaming data. Journal of Science and Development Economics, (25), 62–74.
- [23] Tri, H. V. H., Trang, P. T. X., Duy, N. A., & Khoi, N. H. A. (2025). Predicting stress levels in the Stress-Lysis dataset using Sliding Window approach. Journal of Science and Development Economics, (33), 41–52.